ĐẠI HỌC QUỐC GIA HÀ NỘI

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

Vũ Thị Thu Trang

TĂNG CƯỜNG KHẢ NĂNG HIỂU Ý ĐỊNH NGƯỜI DÙNG CHO ROBOT CỘNG TÁC DỰA TRÊN MÔ HÌNH VLA

ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC HỆ CHÍNH QUY

Ngành: Kỹ thuật Robot

HÀ NỘI – 2026

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

Vũ Thị Thu Trang

TĂNG CƯỜNG KHẢ NĂNG HIỂU Ý ĐỊNH NGƯỜI DÙNG CHO ROBOT CỘNG TÁC DỰA TRÊN MÔ HÌNH VLA

ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC HỆ CHÍNH QUY

Ngành: Kỹ thuật Robot

Cán bộ hướng dẫn: PGS.TS. Hoàng Văn Xiêm

HÀ NỘI – 2026

LỜI CAM ĐOAN

Tôi xin cam đoan đồ án tốt nghiệp "*Tăng cường khả năng hiểu ý định người dùng cho robot cộng tác dựa trên mô hình VLA*" là công trình nghiên cứu của bản thân, được thực hiện dưới sự hướng dẫn của PGS.TS. Hoàng Văn Xiêm. Các số liệu và kết quả trình bày trong đồ án được tính trực tiếp từ các tệp kết quả thực nghiệm do tôi thực hiện, chưa từng được công bố trong công trình nào khác. Các nội dung tham khảo đều được trích dẫn đầy đủ trong danh mục tài liệu tham khảo.

Hà Nội, ngày ... tháng ... năm 2026
Sinh viên

Vũ Thị Thu Trang

LỜI CẢM ƠN

[CẦN ĐIỀN: Lời cảm ơn giảng viên hướng dẫn, phòng thí nghiệm, gia đình và bạn bè. Khoảng 5–8 dòng.]

TÓM TẮT

Tóm tắt: Robot cộng tác làm việc cạnh con người sẽ hữu ích hơn nếu tự đoán được người đó *định làm gì*, thay vì chờ một câu lệnh. Các mô hình Thị giác–Ngôn ngữ–Hành động (VLA) như SmolVLA chỉ biết mục tiêu qua câu lệnh: trên bộ mô phỏng LIBERO-10, SmolVLA thành công 19/100 lượt khi có câu lệnh đúng nhưng 0/100 lượt khi câu lệnh bị bỏ trống. Đồ án đề xuất kiến trúc VLIA (Vision–Language–Intention–Action): một *mô-đun ý định* xem vài khung hình đầu của video góc nhìn thứ nhất, chọn ra mục đích của bước thao tác người đang làm, rồi đưa mục đích đó vào SmolVLA dưới dạng một *token ý định*.

Mô-đun ý định được xây dựng qua năm giai đoạn thực nghiệm trên 2.503 bước thao tác (27 video, 13 khung cảnh) của bộ dữ liệu EgoIntent, mỗi giai đoạn trả lời một câu hỏi và dẫn tới giai đoạn sau. (1) Huấn luyện một lớp đọc trên đặc trưng của chính backbone SmolVLM2 chỉ cho kết quả gần bằng đoán mò. (2) Thay bằng bộ mã hóa ảnh–văn bản SigLIP dùng nguyên, không huấn luyện, độ chính xác chọn đúng mục đích trong 5 câu tăng lên 27,5–28,9% (đoán mò 20%). (3) Dùng SigLIP cỡ lớn và bỏ đi phần khung cảnh chung của các bước trước, độ chính xác đạt 34,1–38,7%; cấu hình này được chọn giống nhau ở cả 8 lần kiểm tra chéo. (4) Trên tập test riêng chỉ chạy một lần, cấu hình đề xuất đạt 30,2% so với 21,4% của SigLIP cơ bản khi xem 8 khung hình. (5) Nếu chỉ trả lời một nửa số trường hợp chắc chắn nhất, độ chính xác tăng thêm 6,9–7,9 điểm, nên robot biết khi nào cần hỏi lại. Phía robot, token ý định đã được cài vào SmolVLA và vượt qua mọi kiểm thử cài đặt. Bước tiếp theo là huấn luyện SmolVLA với câu lệnh luôn để trống để kiểm tra token ý định có thay được câu lệnh hay không.

Từ khóa: robot cộng tác, dự đoán ý định, mô hình VLA, video góc nhìn thứ nhất, SmolVLA, SigLIP.

ABSTRACT

Abstract: A collaborative robot is more useful when it can infer what a person *intends* to do instead of waiting for a command. Vision–Language–Action (VLA) models such as SmolVLA learn the goal only from the instruction: on LIBERO-10, SmolVLA succeeds in 19/100 episodes with the correct instruction and in 0/100 when the instruction is empty. This thesis proposes VLIA (Vision–Language–Intention–Action), in which an *intention module* watches the first frames of a first-person video, selects the purpose of the current manipulation step, and passes it to SmolVLA as one *intention token*.

The intention module is developed in five experimental stages on 2,503 steps (27 videos, 13 scenes) of the EgoIntent dataset; each stage answers one question and motivates the next. (1) A readout trained on features of SmolVLA's own backbone, SmolVLM2, stays close to chance. (2) A pretrained SigLIP image–text encoder used as is, without training, raises 5-way accuracy to 27.5–28.9% (chance 20%). (3) A larger SigLIP encoder together with removing the scene context shared with earlier steps reaches 34.1–38.7%, and the same configuration is selected in all 8 cross-validation folds. (4) On a separate test split evaluated once, the proposed configuration reaches 30.2% versus 21.4% for the base SigLIP pipeline with 8 frames. (5) Answering only the most confident half of the queries adds 6.9–7.9 points, so the robot can tell when to ask. On the robot side, the intention token is implemented in SmolVLA and passes all implementation tests. The next step is to train SmolVLA with an always-empty instruction and test whether the intention token can replace it.

Keywords: collaborative robots, intention prediction, vision–language–action models, egocentric video, SmolVLA, SigLIP.

MỤC LỤC

Lời cam đoan **i**

Lời cảm ơn **ii**

Tóm tắt **iii**

Abstract **iv**

Danh sách hình vẽ **vi**

Danh sách bảng **vii**

Danh mục từ viết tắt và thuật ngữ **viii**

1 Giới thiệu **1**

1.1 Bối cảnh 1

1.2 Vấn đề 1

1.3 Mục tiêu của đồ án 1

1.4 Đóng góp chính 2

1.5 Cấu trúc đồ án 2

2 Kiến thức nền tảng **3**

2.1 Video góc nhìn thứ nhất và ý định 3

2.2 Mô hình VLA và SmolVLA 3

2.3 Bộ mã hóa ảnh–văn bản 4

2.4 Nghiên cứu liên quan 4

3 Bài toán, kiến trúc và cách đánh giá **5**

3.1 Phát biểu bài toán 5

3.2 Kiến trúc VLIA 5

3.3 Dữ liệu EgoIntent 5

3.4 Cách đánh giá 6

4 Các giai đoạn thực nghiệm **8**

4.1 Giai đoạn 0: Khảo sát ban đầu với mô hình có cấu trúc 8

4.2 Giai đoạn 1: Lớp đọc trên đặc trưng của backbone VLA 9

4.3 Giai đoạn 2: Bộ mã hóa ảnh–văn bản SigLIP, không huấn luyện 10
4.4 Giai đoạn 3: Chọn cấu hình tốt nhất, không huấn luyện 11
4.5 Giai đoạn 4: Kiểm tra một lần trên tập test riêng 13
4.6 Giai đoạn 5: Biết khi nào nên hỏi lại 14
4.7 Giai đoạn 6: Nối mô-đun ý định vào SmolVLA 15
4.7.1 Token ý định 15
4.7.2 SmolVLA phụ thuộc vào câu lệnh đến mức nào 15
4.8 Tổng hợp 16

5 Kết luận và hướng phát triển **18**
5.1 Kết luận 18
5.2 Hạn chế 18
5.3 Hướng phát triển 18

Tài liệu tham khảo **20**

DANH SÁCH HÌNH VẼ

1.1 Cùng một động tác quan sát được có thể dẫn tới nhiều mục đích khác nhau. Robot cần phân biệt các mục đích này khi mới thấy phần đầu của động tác. 1

2.1 Sơ đồ đơn giản của SmolVLA. Mục tiêu của nhiệm vụ chỉ đi vào mô hình qua câu lệnh. 4

3.1 Kiến trúc VLIA. Mô-đun ý định (trên) chọn mục đích từ phần đầu video góc nhìn thứ nhất; vector của mục đích được đổi thành một token và chèn vào đầu vào của SmolVLA (dưới). 6

3.2 Tám khung hình của một bước trong EgoIntent (bếp, nhào bột). WHAT: "grasping basin"; WHY: "positioning basin". Các khung màu là khung phát hiện bàn tay do công cụ hiển thị của đồ án vẽ lên; mô-đun ý định không dùng chúng. 6

4.1 Các giai đoạn thực nghiệm của đồ án. Mỗi hàng: việc đã làm (trái) và kết quả cùng quyết định cho giai đoạn sau (phải). 8

4.2 MRR toàn tập (gấp mức ngẫu nhiên) theo số khung được xem. Thanh sai số: khoảng tin cậy 95%. Đường xám nét đứt: mức ngẫu nhiên. 11

4.3 Tỉ lệ chọn đúng mục đích trong 5 câu. (a) Kiểm tra chéo trên 2.503 bước (giai đoạn 3); (b) tập test riêng 407 bước, chạy một lần (giai đoạn 4). Thanh đen: khoảng tin cậy 95%. 13

4.4 Sơ đồ chi tiết hệ thống VLIA với cấu hình đề xuất. Đường đi của thông tin ý định tô đỏ; khối viền nét đứt được đóng băng. 16

DANH SÁCH BẢNG

3.1 Dữ liệu dùng để phát triển mô-đun ý định (phần train + val của EgoIntent). 7

4.1 Giai đoạn 1: lớp đọc trên cách chia gốc (MRR toàn tập, trung bình ± độ lệch chuẩn qua 3 seed). 9

4.2 Giai đoạn 1: lớp đọc trên đặc trưng SmolVLM2, kiểm tra chéo 8 nhóm theo khung cảnh, 2.503 bước. Mức ngẫu nhiên: MRR 0,0298; chọn 1 trong 5 là 20%. 10

4.3 Giai đoạn 2: SigLIP cơ bản, không huấn luyện, cùng kiểm tra chéo và cùng tập ứng viên như giai đoạn 1. 11

4.4 Giai đoạn 3: cấu hình đề xuất so với SigLIP cơ bản (giai đoạn 2), 2.503 bước, kiểm tra chéo. Hiệu ghép cặp trên cùng bước, khoảng tin cậy 95%. 12

4.5 Giai đoạn 4: tập test riêng (407 bước, 4 video), chạy một lần. Đoán mò: chọn 1 trong 5 là 20%, MRR 0,0318. 13

4.6 Giai đoạn 5: độ chính xác chọn 1 trong 5 của cấu hình đề xuất theo độ phủ (kiểm tra chéo, 2.503 bước). 14

4.7 Giai đoạn 6: kiểm thử cài đặt token ý định trong SmolVLA ($d \in \{256, 768, 1152\}$). . . 17

4.8 Giai đoạn 6: SmolVLA trên LIBERO-10 với ba loại câu lệnh (10 nhiệm vụ × 10 lượt mỗi điều kiện). 17

4.9 Tóm tắt các giai đoạn thực nghiệm. “Chọn 1/5”: tỉ lệ chọn đúng mục đích trong 5 câu cùng video (đoán mò 20%). 17

DANH MỤC TỪ VIẾT TẮT VÀ THUẬT NGỮ

Viết tắt / Thuật ngữ	Ý nghĩa trong đồ án
VLA	Vision–Language–Action: mô hình nhận ảnh và câu lệnh, sinh ra hành động cho robot
VLM	Vision–Language Model: mô hình hiểu đồng thời ảnh và văn bản
VLIA	Vision–Language–Intention–Action: kiến trúc đề xuất, VLA có thêm token ý định
Góc nhìn thứ nhất	Video quay từ camera gắn trên đầu hoặc ngực người thực hiện (egocentric)
WHAT / WHY	Hành động con quan sát được / mục đích của bước thao tác hiện tại
Ý định	Trong đồ án: câu WHY của bước thao tác đang diễn ra
Mô-đun ý định	Khối đọc video người và chọn ra câu mục đích
Lớp đọc	Mạng nhỏ được huấn luyện để biến đặc trưng ảnh thành vector so được với câu
Token ý định	Một vector 960 chiều chứa ý định, được chèn vào đầu vào của SmolVLA
k **khung đầu**	Phần video mô hình được thấy: $k \in \{2, 4, 6, 8\}$ khung đầu tiên của bước
Chọn 1 trong 5	Phép đo chính: chọn câu đúng trong 5 câu cùng video; đoán mò đúng 20%
MRR toàn tập	Thứ hạng trung bình (nghịch đảo) của câu đúng khi xếp với mọi câu trong tập
Gấp x **lần ngẫu nhiên**	Kết quả của mô hình chia cho kết quả đoán mò (1 = ngang đoán mò)
Khoảng tin cậy 95%	Khoảng giá trị ước lượng bằng bootstrap theo video
Bỏ khung cảnh chung	Trừ đi trung bình ảnh của các bước trước trong cùng video
Kiểm tra chéo	Chia 27 video thành 8 nhóm theo khung cảnh, lần lượt giữ một nhóm để kiểm tra
Tập test riêng	407 bước của 4 video khác, chỉ chạy một lần ở cuối
LIBERO-10	Bộ 10 nhiệm vụ mô phỏng để đánh giá robot thao tác

CHƯƠNG 1

GIỚI THIỆU

1.1 Bối cảnh

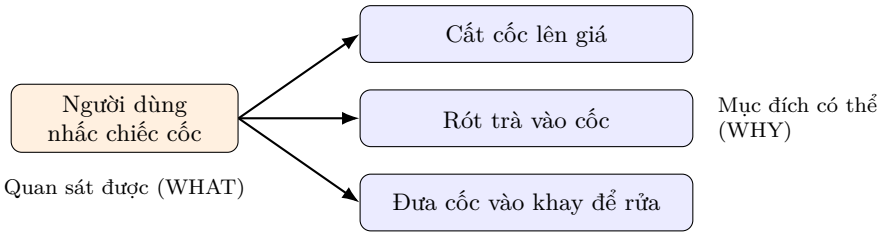
Robot công nghiệp truyền thống làm việc trong lồng an toàn và lặp lại các động tác đã lập trình sẵn. *Robot cộng tác* (cobot) thì làm việc cùng không gian với con người: đưa dụng cụ cho thợ, giữ chi tiết khi người lắp ráp, hay dọn bàn cùng người dùng. Muốn phối hợp nhịp nhàng, robot không thể chỉ phản ứng sau khi người đã làm xong; nó cần đoán được người đó *đang định làm gì*.

Các mô hình *Thị giác–Ngôn ngữ–Hành động* (VLA) như RT-2 [2] hay SmolVLA [4] đang là hướng phổ biến cho robot thao tác. Một mô hình VLA nhận ảnh camera, một câu lệnh (ví dụ "đặt cái bát vào ngăn kéo") và trạng thái robot, rồi sinh ra chuỗi lệnh điều khiển. VLA giả định rằng mục tiêu đã được nói rõ trong câu lệnh. Khi cộng tác thật, con người hiếm khi nói hết ý định của mình.

1.2 Vấn đề

Robot VLA phụ thuộc hoàn toàn vào câu lệnh. Đồ án đo trực tiếp điều này trên bộ mô phỏng LIBERO-10 (Mục 4.7.2): SmolVLA làm xong 19/100 lượt khi có câu lệnh đúng, nhưng 0/100 lượt khi câu lệnh bị bỏ trống. Nếu người không nói, robot không biết phải làm gì.

Đoán ý định từ hình ảnh rất nhập nhằng. Cách tự nhiên để bù vào chỗ câu lệnh là cho robot nhìn người và tự đoán mục đích. Khó khăn là một động tác ban đầu thường phù hợp với nhiều mục đích khác nhau (Hình 1.1), và các bước trong cùng một hoạt động lại diễn ra trong cùng một khung cảnh, với cùng đồ vật.



Hình 1.1. Cùng một động tác quan sát được có thể dẫn tới nhiều mục đích khác nhau. Robot cần phân biệt các mục đích này khi mới thấy phần đầu của động tác.

1.3 Mục tiêu của đồ án

Tên đề tài "Tăng cường khả năng hiểu ý định người dùng cho robot cộng tác dựa trên mô hình VLA" được cụ thể hóa thành hai việc:

1. **Xây dựng mô-đun ý định**: từ vài khung hình đầu của video góc nhìn thứ nhất, chọn ra câu mục đích của bước thao tác người đang làm. Chất lượng được đo bằng tỉ lệ chọn đúng mục đích trong 5 câu cùng video.

2. **Nối mô-đun ý định vào robot VLA**: đưa mục đích đã chọn vào SmolVLA dưới dạng một token ý định, đặt vào chỗ của câu lệnh.

Chữ "tăng cường" được hiểu là *bổ sung cho VLA một nguồn thông tin mục tiêu* khi người không nói ra, và *cải thiện dần chất lượng của nguồn đó* qua từng giai đoạn. Đồ án chưa khẳng định robot thao tác tốt hơn nhờ token ý định; thí nghiệm này là bước tiếp theo (Mục 5.3).

1.4 Đóng góp chính

1. **Chỉ ra rằng backbone của VLA không tự đọc ra được ý định.** Một lớp đọc huấn luyện trên đặc trưng của SmolVLM2 (backbone của SmolVLA) chỉ gấp 1,13–1,19 lần mức ngẫu nhiên, và khoảng tin cậy đều chứa mức ngẫu nhiên.
2. **Đề xuất mô-đun ý định không cần huấn luyện**, dùng SigLIP cỡ lớn và bỏ phần khung cảnh chung của các bước trước. Trên tập test riêng chạy một lần, mô-đun đạt **30,2%** chọn đúng trong 5 câu, so với 21,4% của SigLIP cơ bản và 20% của đoán mò.
3. **Đo mức phụ thuộc của SmolVLA vào thông tin mục tiêu và cài đặt token ý định.** SmolVLA đạt 19/100 với câu lệnh đúng và 0/100 khi bỏ câu lệnh; token ý định đã được cài vào SmolVLA và vượt qua 7/7 kiểm thử cài đặt, sẵn sàng cho thí nghiệm thay câu lệnh.

1.5 Cấu trúc đồ án

Chương 2 giới thiệu kiến thức nền cho người đọc chưa quen lĩnh vực. Chương 3 phát biểu bài toán, mô tả kiến trúc VLIA, dữ liệu và cách đánh giá dùng chung cho mọi thí nghiệm. Chương 4 là phần chính: trình bày lần lượt các giai đoạn thực nghiệm, mỗi giai đoạn gồm câu hỏi, cách làm, kết quả và lý do chuyển sang giai đoạn sau. Chương 5 tổng kết, nêu hạn chế và hướng phát triển.

CHƯƠNG 2

KIẾN THỨC NỀN TẢNG

2.1 Video góc nhìn thứ nhất và ý định

Video góc nhìn thứ nhất (egocentric video) được quay từ camera gắn trên đầu hoặc ngực người đang làm việc, nên cho thấy đúng bàn tay, vật đang cầm và vùng làm việc phía trước. Đây là nguồn dữ liệu tự nhiên để học ý định của người. Các bộ dữ liệu lớn như Ego4D [10] và Ego-Exo4D [11] thúc đẩy mạnh hướng nghiên cứu này.

Bộ dữ liệu EgoIntent [12] chia mỗi video thành các bước thao tác ngắn và gán ba nhãn cho mỗi bước:

- **WHAT**: hành động con nhìn thấy được, ví dụ "grasping basin" (cầm cái chậu).
- **WHY**: mục đích của bước, ví dụ "positioning basin" (đặt lại vị trí chậu). Đồ án gọi đây là *ý định*.
- **NEXT**: bước tiếp theo trong quy trình.

WHAT thường nhìn thấy trực tiếp, còn WHY phải suy ra. Hai bước có WHAT gần giống nhau vẫn có thể có WHY khác nhau.

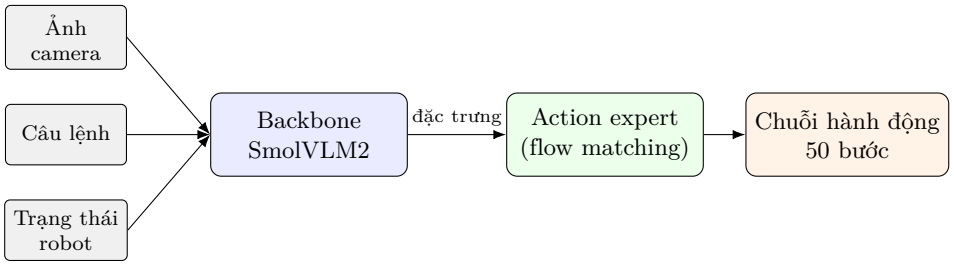
2.2 Mô hình VLA và SmolVLA

Một mô hình VLA gồm hai phần: một *mô hình ngôn ngữ–thị giác* (VLM) đọc ảnh và câu lệnh, và một *bộ sinh hành động* biến kết quả đọc thành lệnh điều khiển [1–3].

SmolVLA [4] là một VLA mã nguồn mở, cỡ nhỏ, xây dựng trong thư viện LeRobot [5]. Đồ án chọn SmolVLA vì nó chạy được trên một GPU thông thường và có mã nguồn đầy đủ. SmolVLA xử lý như sau (Hình 2.1):

1. Ảnh camera, câu lệnh và trạng thái robot được biến thành các *token*, tức các vector cùng kích thước 960 chiều, rồi ghép thành một dãy đầu vào.
2. Dãy này đi qua backbone SmolVLM2 [7, 8].
3. Một *action expert* nhỏ hơn đọc kết quả và sinh ra 50 bước hành động bằng phương pháp *flow matching* [6]: bắt đầu từ nhiễu ngẫu nhiên, sau 10 bước tinh chỉnh thì thu được chuỗi hành động.

Điều quan trọng cho đồ án: SmolVLA **không có thành phần nào ước lượng ý định của người**. Mục tiêu chỉ đến từ câu lệnh.



Hình 2.1. Sơ đồ đơn giản của SmolVLA. Mục tiêu của nhiệm vụ chỉ đi vào mô hình qua câu lệnh.

2.3 Bộ mã hóa ảnh–văn bản

Để so một đoạn video với một câu mô tả mục đích, cần đưa cả hai về cùng một không gian vector, sao cho video và câu mô tả *đúng* nằm gần nhau. Độ gần được đo bằng *độ tương đồng cosine*:

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \, \|\mathbf{v}\|} \in [-1, 1]. \tag{2.1}$$

CLIP [16] và SigLIP [17] học hai bộ mã hóa, một cho ảnh và một cho văn bản, trên hàng trăm triệu cặp ảnh–chú thích từ Internet. Cách học gọi là *học tương phản*: kéo ảnh và chú thích đúng lại gần, đẩy các cặp sai ra xa. Vì đã học rất nhiều khái niệm, các bộ mã hóa này dùng được ngay mà không cần huấn luyện thêm (*zero-shot*): chỉ cần mã hóa ảnh và các câu ứng viên rồi chọn câu có cosine cao nhất.

Hàm mất mát tương phản InfoNCE, dùng khi đồ án tự huấn luyện lớp đọc ở Mục 4.2, có dạng

$$\mathcal{L} = -\log \frac{\exp(\cos(\mathbf{z}, \mathbf{t}^+)/\tau)}{\exp(\cos(\mathbf{z}, \mathbf{t}^+)/\tau) + \sum_j \exp(\cos(\mathbf{z}, \mathbf{t}_j^-)/\tau)}, \tag{2.2}$$

trong đó $\mathbf{z}$ là vector của video, $\mathbf{t}^+$ là câu đúng, $\mathbf{t}_j^-$ là các câu sai và τ là hệ số "nhiệt độ".

2.4 Nghiên cứu liên quan

Bài toán gần nhất trong thị giác máy tính là *dự đoán hành động tương lai*: từ đoạn video đã thấy, đoán các hành động sắp tới. Valls Mascaro và cộng sự [13] mô hình hóa ý định như một biến ẩn điều khiển chuỗi hành động tương lai; AntGPT [14] dùng mô hình ngôn ngữ lớn để suy ra mục tiêu; INSIGHT [15] kết hợp suy luận ý định với dự đoán dài hạn. Các công trình này chủ yếu đoán *nhãn hành động kế tiếp*. Đồ án tập trung vào câu hỏi hẹp hơn nhưng sát với robot cộng tác hơn: *phân biệt các mục đích cạnh tranh trong cùng một hoạt động* khi mới thấy phần đầu của bước thao tác, và *đưa kết quả vào một chính sách VLA*.

CHƯƠNG 3

BÀI TOÁN, KIẾN TRÚC VÀ CÁCH ĐÁNH GIÁ

Chương này mô tả những gì dùng chung cho mọi giai đoạn ở Chương 4: bài toán, kiến trúc tổng thể, dữ liệu và cách đo.

3.1 Phát biểu bài toán

Mỗi video gồm nhiều bước thao tác. Từ đoạn video của bước i lấy đều 8 khung hình $(x_{i,1}, \ldots, x_{i,8})$. Với $k \in \{2, 4, 6, 8\}$, mô-đun ý định chỉ được xem k khung đầu $x_{i,1:k}$. Mô-đun có một hàm mã hóa video f và một hàm mã hóa câu g, và cho mỗi câu ứng viên c một điểm

$$s(i, c) = \cos\big(f(x_{i,1:k}),\, g(c)\big). \tag{3.1}$$

Câu có điểm cao nhất là ý định được chọn.

Ví dụ cụ thể

Video nhào bột, bước "positioning basin". Mô-đun xem 8 khung đầu (Hình 3.2) và phải chọn đúng câu này trong 5 câu: *positioning basin*, *add salt to flour*, *prepare to pour water into flour*, *clean the table surface*, *forming dough*. Cả 5 câu đều thuộc cùng video nhào bột, nên đồ vật và khung cảnh trong ảnh không đủ để phân biệt.

3.2 Kiến trúc VLIA

Kiến trúc VLIA (Hình 3.1) gồm hai khối nối tiếp:

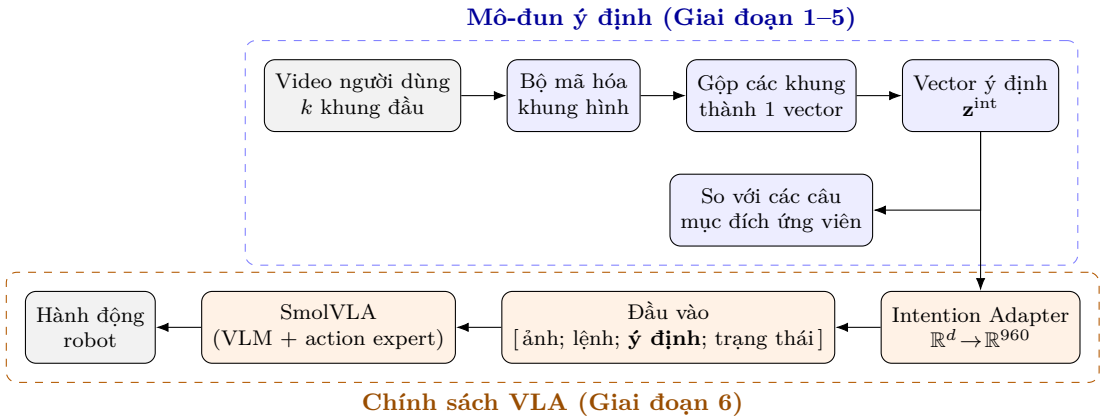
1. **Mô-đun ý định** đọc k khung đầu của video người và tạo ra vector ý định $\mathbf{z}^{\text{int}}$, cũng là vector của câu mục đích được chọn.
2. **SmolVLA** nhận $\mathbf{z}^{\text{int}}$ qua một lớp tuyến tính (Intention Adapter) dưới dạng một token, cùng với ảnh camera robot, câu lệnh và trạng thái, rồi sinh hành động.

Hai khối chỉ giao tiếp qua vector $\mathbf{z}^{\text{int}}$, nên có thể thay đổi mô-đun ý định qua từng giai đoạn mà không phải sửa SmolVLA.

3.3 Dữ liệu EgoIntent

EgoIntent [12] được xây dựng từ video Ego4D [10]. Mỗi video là một hoạt động (nhào bột, sửa xe đạp, hái quả...) được chia thành các bước ngắn; mỗi bước kết thúc *trước* khi kết cục xảy ra (Hình 3.2).

Đồ án dùng phần huấn luyện và kiểm định của bản đầy đủ, gồm 2.503 bước (Bảng 3.1), cho mọi giai đoạn phát triển. Phần test của bộ dữ liệu được giữ riêng (Mục 3.4).



Hình 3.1. Kiến trúc VLIA. Mô-đun ý định (trên) chọn mục đích từ phần đầu video góc nhìn thứ nhất; vector của mục đích được đổi thành một token và chèn vào đầu vào của SmolVLA (dưới).



Hình 3.2. Tám khung hình của một bước trong EgoIntent (bếp, nhào bột). WHAT: "grasping basin"; WHY: "positioning basin". Các khung màu là khung phát hiện bàn tay do công cụ hiển thị của đồ án vẽ lên; mô-đun ý định không dùng chúng.

Các khung cảnh gồm xưởng mộc, bếp, gara, trang trại, phòng khách, phòng ngủ, xưởng vẽ, tủ quần áo, hiên nhà, hành lang, phòng giặt, sân và ngoài trời. Gần như mọi câu WHY là duy nhất, nên mô hình không thể học thuộc một danh sách nhãn mà phải so ý nghĩa giữa video và câu.

3.4 Cách đánh giá

Phép đo chính: chọn 1 trong 5. Với mỗi bước, tập ứng viên gồm câu đúng và 4 câu WHY *khác của cùng video*. Đoán mò đúng 20%. Bộ câu nhiễu được cố định theo mã của bước, nên giống hệt nhau giữa mọi giai đoạn. Đây là phép đo sát với robot cộng tác nhất, vì các ứng viên có cùng khung cảnh và đồ vật.

Phép đo phụ: MRR toàn tập. Câu đúng được xếp hạng giữa *mọi* câu WHY trong nhóm kiểm tra (vài trăm câu). MRR là trung bình của 1/thứ hạng: đứng đầu được 1 điểm, thứ hai được 0,5, thứ mười được 0,1. Vì MRR tuyệt đối phụ thuộc số câu, đồ án báo cáo thêm *số lần gấp mức ngẫu nhiên*: 1 nghĩa là ngang đoán mò.

Kiểm tra chéo theo khung cảnh. Robot phải dùng được ở nơi chưa từng thấy. Vì vậy 13

Bảng 3.1. Dữ liệu dùng để phát triển mô-đun ý định (phần train + val của EgoIntent).

Thuộc tính	Giá trị
Số bước thao tác	2.503
Số video	27
Số khung cảnh	13
Số câu WHY khác nhau	2.032
Số bước mỗi video	19 – 125
Số khung lấy đều mỗi bước	8

khung cảnh được chia thành 8 nhóm có số bước gần bằng nhau. Mỗi lần, một nhóm được giữ lại để kiểm tra và 7 nhóm còn lại dùng để huấn luyện hoặc để chọn cấu hình; lặp lại 8 lần. Mỗi bước được đánh giá đúng một lần, trên khung cảnh mà mô hình chưa thấy.

Tập test riêng. Phần test của EgoIntent, sau khi bỏ một video từng dùng trong thử nghiệm ban đầu, còn 407 bước từ 4 video. Tập này không dùng trong lúc phát triển và chỉ chạy *một lần* cho cấu hình cuối cùng (Mục 4.5).

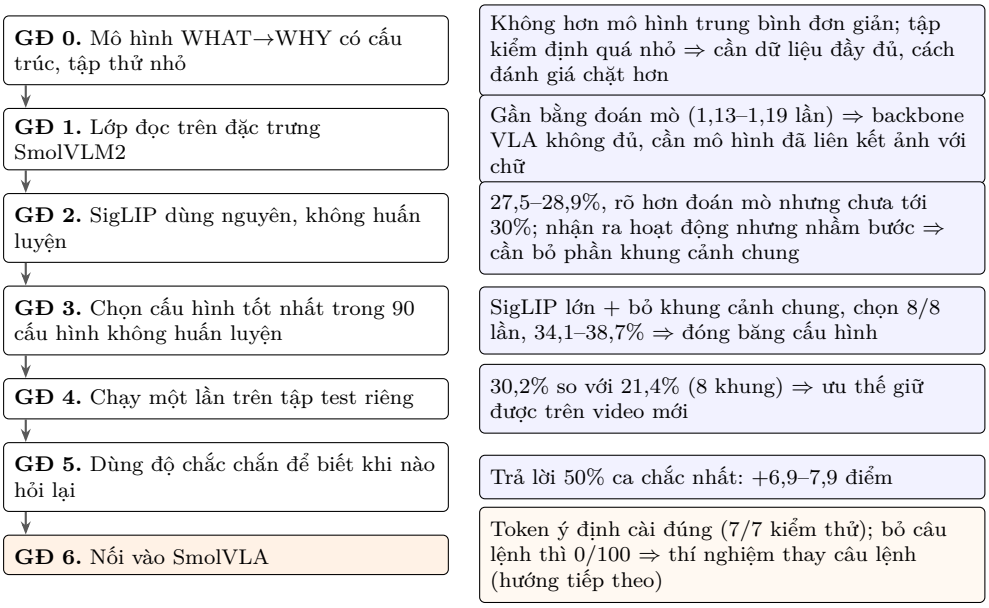
Khoảng tin cậy. Các bước trong cùng video có chung người, khung cảnh và ánh sáng, nên không độc lập. Khoảng tin cậy 95% được tính bằng *bootstrap theo video*: lấy mẫu lại cả video, tính lại kết quả 10.000 lần. Khi so hai cách trên cùng các bước, đồ án tính hiệu trên từng bước rồi mới bootstrap (hiệu ghép cặp). Một kết quả được coi là "rõ ràng" khi cả khoảng tin cậy nằm về một phía (trên mức ngẫu nhiên, hoặc trên 0 với hiệu).

Ngưỡng đạt đặt trước. Trước mỗi giai đoạn, tiêu chí đạt/không đạt được ghi vào kho mã, để kết luận không bị ảnh hưởng bởi số liệu vừa thấy. Ngưỡng thực dụng cho mô-đun ý định là **30%** chọn đúng trong 5 câu.

CHƯƠNG 4

CÁC GIAI ĐOẠN THỰC NGHIỆM

Chương này trình bày quá trình xây dựng mô-đun ý định theo thứ tự đã thực hiện. Mỗi giai đoạn bắt đầu bằng một câu hỏi, sau đó là cách làm, kết quả, và kết luận dẫn tới giai đoạn sau. Hình 4.1 tóm tắt toàn bộ quá trình.



Hình 4.1. Các giai đoạn thực nghiệm của đồ án. Mỗi hàng: việc đã làm (trái) và kết quả cùng quyết định cho giai đoạn sau (phải).

4.1 Giai đoạn 0: Khảo sát ban đầu với mô hình có cấu trúc

Câu hỏi. Nếu mô hình học đoán hành động con (WHAT) trước, rồi dùng nó để đoán mục đích (WHY), thì có tốt hơn đoán thẳng mục đích không?

Cách làm. Đồ án bắt đầu trên một tập thử nghiệm nhỏ của EgoIntent (556 bước để huấn luyện, 215 bước để kiểm định), với đặc trưng khung hình của SmolVLM2. Nhiều mô hình đã được thử: đoán thẳng WHY; thêm nhánh phụ đoán WHAT và NEXT; cho dự đoán WHAT đi vào đường suy luận WHY; thêm mẫu âm khó trong cùng tác vụ; và một bộ xếp hạng lại nhỏ phía sau. Mô hình đơn giản nhất để so sánh là lấy trung bình 8 khung rồi qua một mạng hai lớp.

Kết quả. Mô hình trung bình đơn giản đạt MRR toàn tập 0,0589 ở 8 khung (mức ngẫu nhiên 0,0422). Các mô hình có cấu trúc phức tạp hơn *không vượt rõ* mức này. Hai vấn đề khiến kết quả khó tin cậy: tập kiểm định chỉ có 215 bước từ 2 video, và mọi lựa chọn (số epoch, trọng số các nhánh) đều được làm trên chính tập đó.

Kết luận giai đoạn 0

Cấu trúc WHAT→WHY không cho lợi ích đo được trên dữ liệu nhỏ. Đồ án quyết định: (i) giữ mô hình đơn giản nhất (trung bình các khung + mạng hai lớp) làm điểm xuất phát; (ii) chuyển sang toàn bộ 2.503 bước với kiểm tra chéo theo khung cảnh (Mục 3.4) để kết quả đáng tin hơn.

4.2 Giai đoạn 1: Lớp đọc trên đặc trưng của backbone VLA

Câu hỏi. SmolVLA đã "nhìn" ảnh qua backbone SmolVLM2. Đặc trưng của backbone này có chứa đủ thông tin để đoán mục đích của người không?

Cách làm. Mỗi khung hình đi qua SmolVLM2-500M-Video-Instruct [8] (đóng băng, không cập nhật trọng số), cho một vector 960 chiều. Lấy trung bình k khung đầu, rồi đưa qua một lớp đọc hai lớp (lớp ẩn 512 chiều):

$$\mathbf{z}_i = \mathrm{MLP}\Big(\tfrac{1}{k}\textstyle\sum_{j=1}^{k} \mathbf{X}_{i,j}\Big). \tag{4.1}$$

Câu WHY được biểu diễn theo hai cách: bằng bộ mã hóa câu all-MiniLM-L6-v2 [18], hoặc bằng đặc trưng văn bản của chính SmolVLM2 (giảm còn 256 chiều bằng PCA). Lớp đọc được huấn luyện bằng InfoNCE (công thức (2.2), $\tau = 0{,}07$) cộng 0,1× mất mát cosine, AdamW, tốc độ học 10^{-3}, tối đa 100 epoch, 3 seed. Số epoch được chọn trên một phần khung cảnh tách ra từ dữ liệu huấn luyện, không bao giờ nhìn nhóm kiểm tra.

Kết quả trên cách chia gốc. Trước tiên, lớp đọc được đánh giá theo cách chia gốc của bộ dữ liệu (Bảng 4.1). Trên tập kiểm định, MRR gấp khoảng 1,7–1,9 lần mức ngẫu nhiên; nhưng trên tập test riêng, MRR cao nhất (0,0314) gần như bằng mức ngẫu nhiên (0,0318).

Bảng 4.1. Giai đoạn 1: lớp đọc trên cách chia gốc (MRR toàn tập, trung bình ± độ lệch chuẩn qua 3 seed).

	Kiểm định (412 bước, 4 video)		Test riêng (407 bước, 4 video)	
k	MRR	Top-1	MRR	Top-1
2	0,0440 ± 0,0064	0,0162	0,0290 ± 0,0028	0,0057
4	0,0448 ± 0,0072	0,0162	0,0288 ± 0,0033	0,0082
6	0,0474 ± 0,0010	0,0218	0,0294 ± 0,0045	0,0090
8	0,0429 ± 0,0053	0,0146	0,0314 ± 0,0035	0,0098
Mức ngẫu nhiên	0,0249	0,0047	0,0318	0,0071

Kết quả với kiểm tra chéo. Kiểm tra chéo dùng cả 27 video để đánh giá (Bảng 4.2). Lớp đọc chỉ gấp 1,13–1,19 lần mức ngẫu nhiên về MRR, và khoảng tin cậy đều chứa 1. Ở phép chọn 1 trong 5, cách biểu diễn bằng SmolVLM2 đạt 21,9–23,0%, chỉ hơn đoán mò 2–3 điểm. Hai cách biểu diễn câu không khác nhau rõ ràng.

Kiểm tra thêm: để SmolVLM2 tự chấm điểm. Một cách khác không cần huấn luyện là để chính SmolVLM2 đọc khung hình rồi chấm xác suất của từng câu ứng viên. Cách này đạt 23,5% ($k = 2$) và 24,6% ($k = 8$) ở phép chọn 1 trong 5, rõ hơn đoán mò nhưng vẫn thấp.

Bảng 4.2. Giai đoạn 1: lớp đọc trên đặc trưng SmolVLM2, kiểm tra chéo 8 nhóm theo khung cảnh, 2.503 bước. Mức ngẫu nhiên: MRR 0,0298; chọn 1 trong 5 là 20%.

Biểu diễn câu	k	MRR	Gấp ngẫu nhiên [CI 95%]	Chọn 1/5	Gấp ngẫu nhiên [CI 95%]
MiniLM	2	0,0335	1,13 [0,86; 1,43]	21,6%	1,08 [1,00; 1,16]
	4	0,0345	1,16 [0,88; 1,48]	21,5%	1,07 [1,00; 1,16]
	6	0,0353	1,18 [0,90; 1,52]	21,2%	1,06 [0,98; 1,16]
	8	0,0347	1,17 [0,87; 1,51]	21,9%	1,10 [1,01; 1,20]
SmolVLM2	2	0,0340	1,14 [0,95; 1,36]	21,9%	1,09 [1,02; 1,17]
	4	0,0338	1,14 [0,94; 1,35]	22,2%	1,11 [1,03; 1,19]
	6	0,0346	1,16 [0,95; 1,39]	22,3%	1,12 [1,04; 1,20]
	8	0,0354	1,19 [0,98; 1,42]	23,0%	1,15 [1,07; 1,23]

Kết luận giai đoạn 1

Backbone của VLA *có* chứa một chút tín hiệu về mục đích, nhưng quá yếu: cả lớp đọc được huấn luyện lẫn cách tự chấm điểm đều chỉ hơn đoán mò vài điểm, và lớp đọc về mức ngẫu nhiên trên tập test riêng. Nguyên nhân có thể là lớp đọc phải *tự học* mối liên hệ giữa ảnh và câu mục đích từ khoảng hai nghìn bước. Giai đoạn 2 thử một mô hình đã học sẵn mối liên hệ này từ hàng trăm triệu cặp ảnh–chú thích.

4.3 Giai đoạn 2: Bộ mã hóa ảnh–văn bản SigLIP, không huấn luyện

Câu hỏi. Một bộ mã hóa đã liên kết sẵn ảnh với chữ, dùng nguyên không huấn luyện, có chọn mục đích tốt hơn lớp đọc ở giai đoạn 1 không?

Cách làm. Dùng checkpoint `google/siglip-base-patch16-224` [17], gọi tắt là *SigLIP cơ bản*:

1. Mã hóa từng khung hình bằng phần ảnh của SigLIP (768 chiều), lấy trung bình k khung đầu.
2. Mã hóa từng câu WHY ứng viên bằng phần chữ của SigLIP.
3. Chọn câu có cosine cao nhất theo công thức (3.1).

Không có tham số nào được huấn luyện, nên không có nguy cơ học thuộc dữ liệu nhỏ. Các nhóm kiểm tra chéo chỉ dùng để chia tập ứng viên, giống hệt giai đoạn 1.

Vì sao SigLIP vẫn thuộc khung "dựa trên VLA"

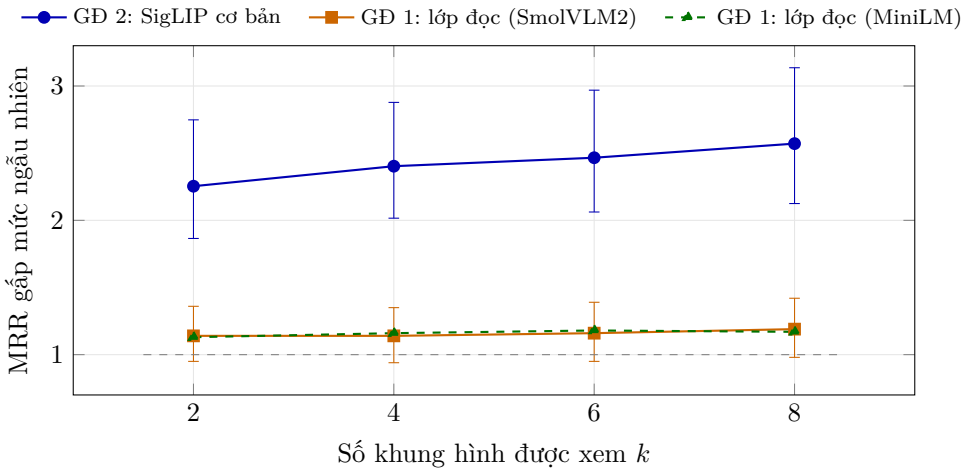
SigLIP chỉ thay *bộ mã hóa của mô-đun ý định*. Chính sách điều khiển robot vẫn là SmolVLA, và ý định vẫn đi vào SmolVLA qua token ý định (Hình 3.1). Backbone SmolVLM2 vốn dùng phần ảnh thuộc họ SigLIP; điểm khác là checkpoint SigLIP đầy đủ còn giữ phần chữ đã liên kết với ảnh, nên so được trực tiếp với câu mục đích.

Kết quả. Bảng 4.3 và Hình 4.2 cho thấy SigLIP cơ bản tốt hơn hẳn lớp đọc: MRR gấp 2,25–2,57 lần mức ngẫu nhiên (khoảng tin cậy hoàn toàn trên 1), gần gấp đôi lớp đọc ở mọi k; độ chính xác chọn 1 trong 5 là 27,5–28,9%.

Xem thêm khung hình có giúp không? Với SigLIP cơ bản, đi từ 2 lên 8 khung tăng MRR +0,0094 [+0,0053; +0,0141] và tăng chọn 1 trong 5 +1,1 điểm [+0,1; +2,1], cả hai đều rõ ràng. Với

Bảng 4.3. Giai đoạn 2: SigLIP cơ bản, không huấn luyện, cùng kiểm tra chéo và cùng tập ứng viên như giai đoạn 1.

k	MRR	Gấp mức ngẫu nhiên [CI 95%]	Chọn 1/5	Gấp mức ngẫu nhiên [CI 95%]	Chọn 1/10
2	0,0671	2,25 [1,87; 2,75]	27,7%	1,39 [1,23; 1,56]	15,7%
4	0,0715	2,40 [2,02; 2,88]	27,5%	1,38 [1,22; 1,55]	16,1%
6	0,0734	2,47 [2,06; 2,97]	28,1%	1,40 [1,24; 1,58]	16,7%
8	0,0765	2,57 [2,13; 3,14]	28,9%	1,44 [1,27; 1,62]	17,7%



Hình 4.2. MRR toàn tập (gấp mức ngẫu nhiên) theo số khung được xem. Thanh sai số: khoảng tin cậy 95%. Đường xám nét đứt: mức ngẫu nhiên.

lớp đọc ở giai đoạn 1, mức tăng MRR không rõ ràng (khoảng tin cậy chứa 0). Như vậy chỉ khi biểu diễn đã liên kết tốt với chữ, thêm hình ảnh mới giúp phân biệt mục đích tốt hơn.

Phân tích lỗi. Với bước ở Hình 3.2 (đáp án "positioning basin"), SigLIP cơ bản ở 8 khung xếp: "prepare to knead dough" (cosine 0,101), "developing dough consistency" (0,085), "forming cohesive dough" (0,072), "cleaning the table surface" (0,056), và câu đúng đứng cuối (0,020). Mô hình nhận ra đúng *hoạt động chung* là nhào bột, nhưng không phân biệt được *bước* cụ thể. Lý do là các khung hình của mọi bước đều chứa cùng cái bàn, cái chậu, đôi tay và bột; phần chung này chiếm phần lớn vector ảnh.

Kết luận giai đoạn 2

Dùng mô hình đã liên kết sẵn ảnh với chữ tốt hơn hẳn việc tự huấn luyện lớp đọc trên dữ liệu nhỏ, và kết quả tăng khi xem thêm khung. Tuy vậy, 27,5–28,9% vẫn dưới ngưỡng 30% đặt trước, và lỗi chủ yếu là nhầm giữa các bước cùng hoạt động. Giai đoạn 3 tìm cách bỏ bớt phần khung cảnh chung, và thử các bộ mã hóa lớn hơn, vẫn không huấn luyện.

4.4 Giai đoạn 3: Chọn cấu hình tốt nhất, không huấn luyện

Câu hỏi. Không huấn luyện thêm, có thể vượt 30% bằng cách chọn bộ mã hóa tốt hơn và xử lý vector ảnh khác đi không?

Cách làm. Đồ án thử 90 cấu hình, là tổ hợp của bốn lựa chọn:

- **Bộ mã hóa (5 loại)**: SigLIP cơ bản, `siglip-base-patch16-384`, `siglip2-base-patch16-224`, `siglip-so400m-patch14-384` (gọi tắt là *SigLIP lớn*) và `clip-vit-large-patch14`.
- **Cách gộp các khung (3 cách)**: lấy trung bình; lấy khung giống câu nhất; hoặc một cách trung hòa giữa hai cách trên.
- **Xử lý vector (3 cách)**: không xử lý; trừ vector trung bình chung của cả tập; hoặc **bỏ khung cảnh chung**, tức trừ đi trung bình ảnh của các bước *trước đó* trong cùng video.
- **Câu mẫu (2 cách)**: dùng nguyên câu WHY; hoặc bọc trong câu mẫu "`a first-person photo of a person doing: {why}`".

Trực giác của bước bỏ khung cảnh chung

Trong video nhào bột, khung nào cũng có cái bàn, cái chậu, đôi tay và bột, nên mọi câu "về nhào bột" đều khớp gần như ngang nhau. Trừ đi trung bình của các bước *đã xảy ra trước đó* giống như hỏi "khung hình bây giờ *khác gì* so với những gì đã thấy?". Phần còn lại là cái mới của bước hiện tại, thứ phân biệt các mục đích. Bước này chỉ dùng quá khứ nên robot làm được khi đang chạy thật. Với bước đầu tiên của video (khoảng 1% số bước), chưa có bước trước, nên dùng trung bình chung của cả tập thay thế.

Chọn cấu hình sao cho không tự lừa mình. Nếu thử cả 90 cấu hình rồi báo cáo cấu hình đẹp nhất trên cùng dữ liệu đánh giá, con số sẽ lạc quan giả tạo. Vì vậy trong mỗi lần kiểm tra chéo, 90 cấu hình chỉ được chấm trên 7 nhóm huấn luyện, cấu hình tốt nhất được chọn, rồi mới đem đánh giá trên nhóm giữ lại (*chọn lồng nhau*). Con số báo cáo vì vậy luôn đến từ dữ liệu không dùng để chọn.

Kết quả. Cả **8/8** lần đều chọn cùng một cấu hình: *SigLIP lớn, lấy trung bình, bỏ khung cảnh chung, dùng câu mẫu.* Đồ án gọi đây là **cấu hình đề xuất**. Bảng 4.4 so nó với SigLIP cơ bản trên cùng các bước.

Bảng 4.4. Giai đoạn 3: cấu hình đề xuất so với SigLIP cơ bản (giai đoạn 2), 2.503 bước, kiểm tra chéo. Hiệu ghép cặp trên cùng bước, khoảng tin cậy 95%.

	Chọn 1 trong 5			MRR toàn tập		
k	Cơ bản	Đề xuất	Hiệu [CI 95%]	Cơ bản	Đề xuất	Hiệu [CI 95%]
2	27,7%	**34,1%**	+6,4 [+3,9; +8,9]	0,0671	0,0747	+0,0076 [−0,0037; +0,0195]
4	27,5%	**34,9%**	+7,4 [+4,9; +10,0]	0,0715	0,0777	+0,0062 [−0,0059; +0,0183]
6	28,1%	**36,2%**	+8,2 [+5,1; +11,2]	0,0734	0,0825	+0,0091 [−0,0024; +0,0206]
8	28,9%	**38,7%**	+9,9 [+6,2; +13,4]	0,0765	0,0850	+0,0085 [−0,0026; +0,0195]

Ở phép chọn 1 trong 5, cấu hình đề xuất đạt 34,1–38,7%, vượt ngưỡng 30% ở cả 4 giá trị k và hơn SigLIP cơ bản 6,4–9,9 điểm, mọi khoảng tin cậy đều trên 0. Ở MRR toàn tập, cấu hình đề xuất cũng cao hơn nhưng mức tăng chưa rõ ràng (khoảng tin cậy chứa 0).

Kiểm tra tín hiệu có thật đến từ video không. Thay khung hình của mỗi bước bằng khung của một video ở khung cảnh khác (313 bước, $k = 8$), độ chính xác của cấu hình đề xuất rơi từ 39,6% xuống 18,8%, tức về mức đoán mò. Mô hình thật sự dùng nội dung hình ảnh, không đoán dựa vào câu chữ.

Thành phần nào đóng góp? Trong toàn bộ 90 cấu hình, 6 cấu hình đứng đầu đều dùng SigLIP lớn cùng bước bỏ khung cảnh chung. Bỏ bước này khỏi SigLIP lớn thì còn 31,1–33,0%; thêm

bước này cho SigLIP cơ bản thì được 29,1–32,1%. Cả bộ mã hóa lớn hơn lẫn bước bỏ khung cảnh chung đều có ích.

Kết luận giai đoạn 3

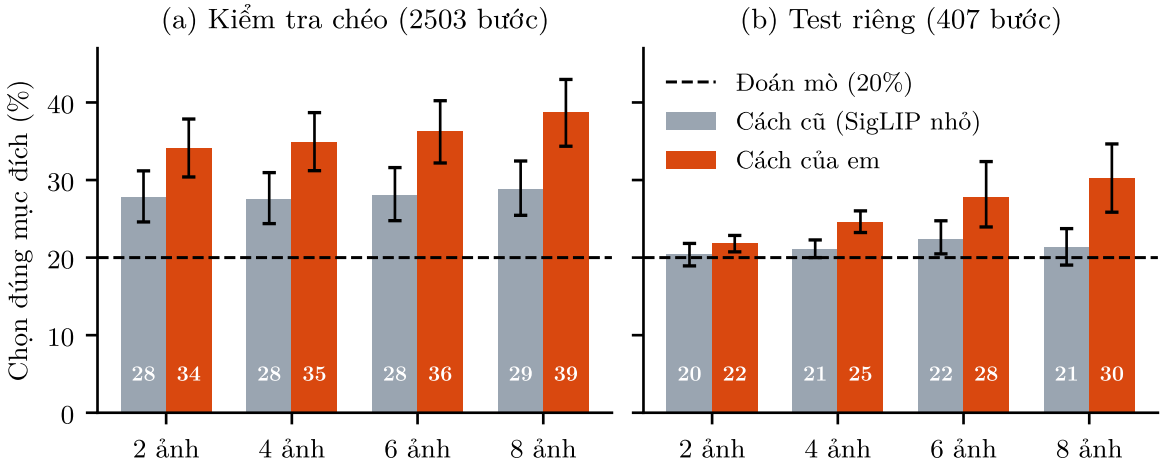
Không huấn luyện thêm, cấu hình đề xuất vượt ngưỡng 30% và được chọn ổn định 8/8 lần. Cấu hình được ghi lại cố định (tệp `FROZEN.json`, kèm mã băm) trước khi đọc tập test riêng. Câu hỏi còn lại: ưu thế này có giữ được trên video chưa từng dùng trong lúc phát triển không?

4.5 Giai đoạn 4: Kiểm tra một lần trên tập test riêng

Câu hỏi. Trên 407 bước của 4 video chưa từng dùng, cấu hình đề xuất có còn hơn đoán mò và hơn SigLIP cơ bản không?

Cách làm. Cấu hình đề xuất và tiêu chí đạt được ghi cố định trước. Mã đánh giá được thử trên dữ liệu giả, từ chối chạy nếu kết quả đã tồn tại, và chỉ chạy thật khi người làm đồ án xác nhận. Bước bỏ khung cảnh chung trên tập test chỉ dùng các bước trước của *chính video test*. Tập này được chạy đúng một lần, ngày 23/10/2026, và không dùng lại cho việc chọn mô hình.

Kết quả. Hình 4.3 và Bảng 4.5 so hai cấu hình trên tập test riêng, đặt cạnh kết quả kiểm tra chéo.



Hình 4.3. Tỉ lệ chọn đúng mục đích trong 5 câu. (a) Kiểm tra chéo trên 2.503 bước (giai đoạn 3); (b) tập test riêng 407 bước, chạy một lần (giai đoạn 4). Thanh đen: khoảng tin cậy 95%.

Bảng 4.5. Giai đoạn 4: tập test riêng (407 bước, 4 video), chạy một lần. Đoán mò: chọn 1 trong 5 là 20%, MRR 0,0318.

	Chọn 1 trong 5			MRR toàn tập	
k	Cơ bản	Đề xuất	Hiệu [CI 95%]	Cơ bản	Đề xuất
2	20,4%	21,9%	+1,5 [−1,0; +3,8]	0,0631	0,0459
4	21,1%	24,6%	+3,4 [+1,3; +4,8]	0,0594	0,0488
6	22,4%	27,8%	+5,4 [+1,0; +9,7]	0,0660	0,0557
8	21,4%	**30,2%**	+8,9 [+4,4; +14,8]	0,0653	0,0615

Cấu hình đề xuất rõ ràng hơn đoán mò ở cả 4 giá trị k, và rõ ràng hơn SigLIP cơ bản ở

$k = 4, 6, 8$; ở $k = 2$ chưa phân biệt được. Ở 8 khung, cấu hình đề xuất đạt 30,2% so với 21,4%. Khi đổi sang khung hình của video khác (51 bước, $k = 8$), độ chính xác rơi từ 31,4% xuống 21,6%, cùng chiều với kiểm tra chéo.

Có ba điểm cần đọc kèm:

- **Kết quả thấp hơn kiểm tra chéo** (21,9–30,2% so với 34,1–38,7%). SigLIP cơ bản cũng giảm (từ 27,5–28,9% xuống 20,4–22,4%), nên tập test có vẻ khó hơn; với 4 video thì chưa tách được nguyên nhân.
- **MRR toàn tập của cấu hình đề xuất thấp hơn SigLIP cơ bản** ở cả 4 giá trị k. Bước bỏ khung cảnh chung giúp phân biệt các bước *trong cùng video*, nhưng cũng làm mất thông tin "đang ở khung cảnh nào", vốn có ích khi xếp hạng giữa câu của nhiều video.
- **Chỉ có 4 video**, nên mọi khoảng tin cậy trên tập test chỉ dựa trên 4 cụm và cần đọc thận trọng.

Kết luận giai đoạn 4

Ưu thế của cấu hình đề xuất ở bài toán sát với robot (chọn đúng mục đích giữa các bước cùng video) giữ được trên video mới, với 30,2% so với 21,4% ở 8 khung. Mức độ thấp hơn kiểm tra chéo, nên một robot dùng mô-đun này vẫn sẽ sai nhiều. Giai đoạn 5 xem robot có biết khi nào mình đang không chắc hay không.

4.6 Giai đoạn 5: Biết khi nào nên hỏi lại

Câu hỏi. Điểm số của mô-đun ý định có cho biết lúc nào dự đoán đáng tin, để robot chỉ hành động khi chắc và hỏi lại người khi chưa chắc không?

Cách làm. Độ chắc chắn được đo bằng *độ chênh* giữa điểm của câu cao nhất và câu thứ hai trong 5 câu. Với một ngưỡng, mô-đun chỉ trả lời khi độ chênh vượt ngưỡng và hoãn trong các trường hợp còn lại; tỉ lệ được trả lời gọi là *độ phủ*. Ngưỡng của mỗi nhóm kiểm tra được tính từ các nhóm khác.

Kết quả. Trên cấu hình đề xuất (Bảng 4.6), chỉ trả lời 50% số trường hợp chắc nhất thì độ chính xác tăng 6,9–7,9 điểm; chỉ trả lời 20% thì đạt 53–61%. Dùng điểm tin cậy dạng xác suất thay cho độ chênh cho kết quả tương tự (47,4% ở 50% độ phủ, 8 khung). Với SigLIP cơ bản, mức tăng tương ứng chỉ 2,6–3,5 điểm, nên điểm tin cậy hữu ích hơn hẳn khi bộ mã hóa tốt hơn.

Bảng 4.6. Giai đoạn 5: độ chính xác chọn 1 trong 5 của cấu hình đề xuất theo độ phủ (kiểm tra chéo, 2.503 bước).

k	Trả lời 100%	Trả lời 50%	Trả lời 20%	Mức tăng ở 50% [CI 95%]
2	34,1%	41,0%	53,3%	+6,9 [+3,9; +9,6]
4	34,9%	41,8%	55,7%	+6,9 [+4,5; +9,5]
6	36,2%	44,1%	57,7%	+7,9 [+5,3; +10,6]
8	38,7%	45,7%	60,9%	+7,0 [+4,0; +9,7]

Những cách đã thử nhưng không giúp.

- **Dừng xem sớm khi đã chắc**: robot dừng ở khung đầu tiên có độ chênh vượt ngưỡng. So với

xem số khung cố định có cùng số khung trung bình, cách này chỉ hơn rõ ở 1/4 mức ngân sách, không đạt yêu cầu.

- **Tham khảo các bước giống nhất trong dữ liệu huấn luyện**: pha câu WHY của 20 bước huấn luyện giống nhất vào điểm số làm MRR giảm và không cải thiện chọn 1 trong 5, nên bị loại.
- **Tập trung vào vùng tay–vật**: kế hoạch là cắt vùng quanh bàn tay làm đầu vào, với điều kiện bàn tay được phát hiện trong ít nhất 60% số khung và 30% ở mọi khung cảnh. MediaPipe Hands [19] chỉ phát hiện được tay trong 58,2% số khung, và rất thấp ở hiên nhà (10,3%), phòng giặt (15,3%), sân (15,9%). Điều kiện không đạt nên hướng này chưa được đánh giá.

Kết luận giai đoạn 5

Độ chắc chắn của mô-đun ý định dùng được: robot có thể chỉ hành động ở các trường hợp chắc và hỏi lại người ở các trường hợp còn lại. Mô-đun ý định lúc này đã sẵn sàng để nối vào robot.

4.7 Giai đoạn 6: Nối mô-đun ý định vào SmolVLA

Câu hỏi. (i) Có thể đưa ý định vào SmolVLA một cách đúng đắn mà không phá vỡ mô hình gốc không? (ii) SmolVLA phụ thuộc vào thông tin mục tiêu đến mức nào?

4.7.1 Token ý định

Vector ý định $\mathbf{z}^{\text{int}} \in \mathbb{R}^d$ được đổi về kích thước 960 chiều của SmolVLA bằng một lớp tuyến tính (Intention Adapter):

$$\mathbf{e}^{\text{int}} = \mathbf{W}\mathbf{z}^{\text{int}} + \mathbf{b}, \qquad \mathbf{W} \in \mathbb{R}^{960\times d}, \tag{4.2}$$

rồi được chèn vào dãy đầu vào ngay sau câu lệnh, trước trạng thái robot:

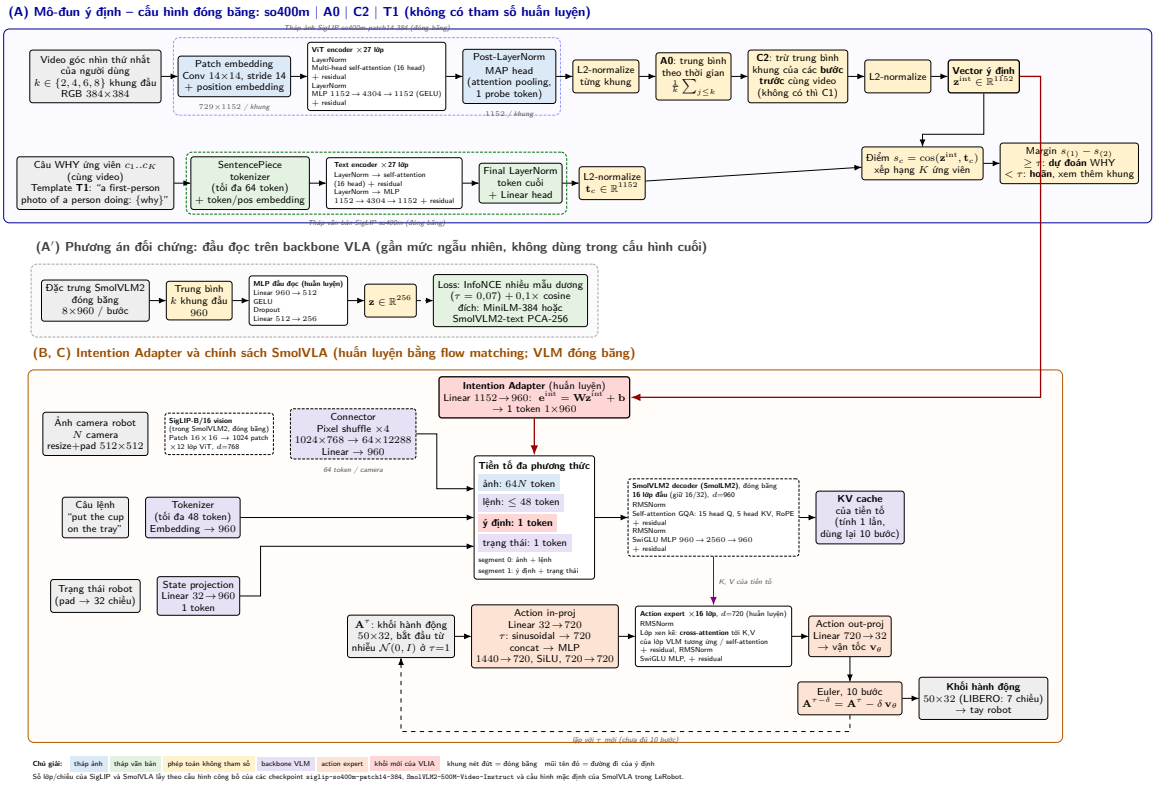
$$P_{\text{VLIA}} = \big[\, E_{\text{ảnh}};\ E_{\text{lệnh}};\ \mathbf{e}^{\text{int}};\ E_{\text{trạng thái}} \,\big]. \tag{4.3}$$

Dãy đầu vào dài thêm đúng một token. Vì phần này chỉ được tính một lần và lưu trong bộ nhớ đệm (KV cache) trước các bước sinh hành động, token ý định gần như không làm tăng chi phí. Khi tắt cờ ý định, mô hình quay về đúng SmolVLA gốc. Hình 4.4 vẽ chi tiết toàn hệ thống với cấu hình đề xuất ($d = 1152$).

Bảng 4.7 liệt kê các kiểm thử cài đặt. Tất cả được chạy với ba kích thước vector ý định $d \in \{256, 768, 1152\}$ trên một SmolVLA có cùng kiến trúc với checkpoint LIBERO, và đều đạt: đầu vào dài từ 77 lên 78 token, token ý định có trong bộ nhớ đệm và thay đổi khi đổi $\mathbf{z}^{\text{int}}$, sai khác khi tắt cờ và khi lưu/tải đều bằng 0. Đây là bằng chứng cài đặt đúng, chưa phải bằng chứng robot làm tốt hơn.

4.7.2 SmolVLA phụ thuộc vào câu lệnh đến mức nào

Đồ án huấn luyện lại SmolVLA (không có token ý định) trên LIBERO-10 [9] với hành động 7 chiều, 25.000 bước. Sau đó chạy 10 nhiệm vụ × 10 lượt trong ba điều kiện: **lệnh đúng**; **lệnh rỗng**; và **lệnh**



Hình 4.4. Sơ đồ chi tiết hệ thống VLIA với cấu hình đề xuất. Đường đi của thông tin ý định tô đỏ; khối viền nét đứt được đóng băng.

sai (câu lệnh của nhiệm vụ khác). Lượt thứ e của mỗi nhiệm vụ dùng cùng vị trí ban đầu và cùng hạt giống ở cả ba điều kiện; chỉ câu lệnh thay đổi.

Theo từng nhiệm vụ, số lượt thành công với lệnh đúng là 0, 1, 3, 7, 1, 3, 3, 0, 0, 1 trên 10. Mọi lượt với lệnh rỗng hoặc sai đều chạy hết giới hạn 520 bước mà không hoàn thành. Lệnh đúng hơn lệnh rỗng +19 điểm [+12; +27].

Kết luận giai đoạn 6

Token ý định đã được cài vào SmolVLA đúng cách và không làm hỏng mô hình gốc. SmolVLA phụ thuộc hoàn toàn vào câu lệnh: bỏ câu lệnh thì robot không làm xong việc nào. Chỗ của câu lệnh vì vậy là nơi cần đưa ý định vào khi người không nói ra; thí nghiệm này là hướng tiếp theo (Mục 5.3).

4.8 Tổng hợp

Bảng 4.9 tóm tắt các giai đoạn. Mạch chung: tự huấn luyện trên dữ liệu nhỏ không đủ (giai đoạn 0–1); dùng mô hình đã liên kết sẵn ảnh với chữ cho tín hiệu rõ (giai đoạn 2); bỏ phần khung cảnh chung và dùng bộ mã hóa lớn hơn vượt ngưỡng 30% (giai đoạn 3) và giữ được ưu thế trên video mới (giai đoạn 4); độ chắc chắn cho robot biết khi nào hỏi lại (giai đoạn 5); và chỗ cần đưa ý định vào robot là chỗ của câu lệnh (giai đoạn 6).

Bảng 4.7. Giai đoạn 6: kiểm thử cài đặt token ý định trong SmolVLA ($d \in \{256, 768, 1152\}$).

Thành phần	Nội dung kiểm tra	Kết quả
Intention Adapter	Gradient truyền ngược được qua adapter	Đạt
Độ dài đầu vào	Dãy đầu vào dài thêm đúng 1 token	Đạt
Vị trí token	Token ý định nằm ngay trước token trạng thái	Đạt
Bộ nhớ đệm	Token ý định có mặt trong KV cache khi suy luận	Đạt
Hàm mất mát	Mất mát flow matching hữu hạn	Đạt
Tắt ý định	Kết quả giống hệt SmolVLA gốc khi tắt cờ	Đạt
Lưu/tải	Lưu và tải lại checkpoint không mất trọng số	Đạt

Bảng 4.8. Giai đoạn 6: SmolVLA trên LIBERO-10 với ba loại câu lệnh (10 nhiệm vụ × 10 lượt mỗi điều kiện).

Câu lệnh	Thành công	Tỉ lệ	Khoảng Wilson 95%
Đúng	19/100	19%	[12,5%; 27,8%]
Rỗng	0/100	0%	[0,0%; 3,7%]
Sai (lệnh của nhiệm vụ khác)	0/100	0%	[0,0%; 3,7%]

Bảng 4.9. Tóm tắt các giai đoạn thực nghiệm. "Chọn 1/5": tỉ lệ chọn đúng mục đích trong 5 câu cùng video (đoán mò 20%).

GĐ	Cách làm	Kết quả chính	Quyết định
0	Mô hình WHAT→WHY, tập thử nhỏ	Không hơn mô hình trung bình đơn giản	Dùng toàn bộ dữ liệu, kiểm tra chéo
1	Lớp đọc trên SmolVLM2	MRR gấp 1,13–1,19 lần ngẫu nhiên; chọn 1/5: 21,9–23,0%	Thử mô hình đã liên kết ảnh–chữ
2	SigLIP cơ bản, không huấn luyện	Gấp 2,25–2,57 lần; chọn 1/5: 27,5–28,9%	Bỏ khung cảnh chung, thử bộ mã hóa lớn hơn
3	Chọn 1 trong 90 cấu hình	Chọn 1/5: 34,1–38,7%, cùng cấu hình 8/8 lần	Ghi cố định cấu hình
4	Tập test riêng, chạy một lần	30,2% so với 21,4% (8 khung)	Xét độ chắc chắn
5	Trả lời khi đủ chắc	+6,9–7,9 điểm ở 50% độ phủ	Nối vào robot
6	Token ý định trong SmolVLA; LIBERO	7/7 kiểm thử đạt; lệnh đúng 19/100, rỗng 0/100	Thay câu lệnh bằng ý định

CHƯƠNG 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Đồ án nghiên cứu cách tăng cường khả năng hiểu ý định người dùng cho robot cộng tác dựa trên mô hình VLA, theo hướng bổ sung cho SmolVLA một mô-đun ý định đọc video góc nhìn thứ nhất của người. Qua sáu giai đoạn thực nghiệm, đồ án đạt được:

1. Chỉ ra rằng đặc trưng của backbone VLA (SmolVLM2) không đủ để đọc ý định: lớp đọc huấn luyện trên nó chỉ gấp 1,13–1,19 lần mức ngẫu nhiên.
2. Xây dựng mô-đun ý định không cần huấn luyện, dùng SigLIP lớn và bỏ khung cảnh chung của các bước trước, đạt 34,1–38,7% chọn đúng trong 5 câu khi kiểm tra chéo và 30,2% trên tập test riêng (so với 21,4% của SigLIP cơ bản, 20% của đoán mò).
3. Cho robot cơ chế biết khi nào nên hỏi lại: trả lời một nửa số trường hợp chắc nhất tăng độ chính xác 6,9–7,9 điểm.
4. Đo được SmolVLA phụ thuộc hoàn toàn vào câu lệnh (19/100 so với 0/100), và cài đặt token ý định vào SmolVLA vượt qua 7/7 kiểm thử.

5.2 Hạn chế

- **Chưa đo tác động lên hành vi robot.** Token ý định chưa được huấn luyện cùng SmolVLA, nên chưa biết nó có thay được câu lệnh hay không.
- **Độ chính xác còn thấp.** 30% trên tập test riêng nghĩa là robot vẫn chọn sai phần lớn các trường hợp nếu trả lời mọi lúc.
- **Dữ liệu nhỏ.** 27 video, 13 khung cảnh để phát triển và 4 video để test, nên khoảng tin cậy trên tập test còn rộng.
- **Xếp hạng toàn tập chưa tốt hơn.** Bước bỏ khung cảnh chung giúp phân biệt các bước cùng video nhưng làm giảm MRR toàn tập trên tập test.
- **Câu đồng nghĩa bị tính là sai.** Các câu WHY viết tự do; 44,5% số bước có một câu khác trong cùng video gần như cùng nghĩa (cosine $\geq$ 0,9 theo MiniLM), nên điểm tuyệt đối bị chặn trên.
- **Thí nghiệm LIBERO nhỏ.** Một checkpoint, 10 lượt mỗi nhiệm vụ.

5.3 Hướng phát triển

Bước tiếp theo: đưa ý định vào thẳng chỗ của câu lệnh.

1. Tạo vector mục đích cho 10 nhiệm vụ LIBERO bằng phần chữ của SigLIP lớn (cùng bộ mã hóa với mô-đun ý định).
2. Huấn luyện lại SmolVLA 25.000 bước với cùng dữ liệu và cấu hình như bản gốc, nhưng luôn để trống câu lệnh, để robot chỉ biết nhiệm vụ qua token ý định.
3. Thử 100 lượt (10 nhiệm vụ $\times$ 10 lượt, cùng vị trí ban đầu như Mục 4.7.2) với token ý định đúng nhiệm vụ và token ý định của nhiệm vụ khác.

Nếu token ý định đúng cho tỉ lệ thành công cao hơn hẳn cả khi bỏ lệnh (0/100) lẫn khi dùng ý định sai, thì token ý định đã thay được câu lệnh. Mức 19/100 của câu lệnh thật dùng để so sánh. Sau đó, vector mục đích "đúng" được thay bằng mục đích robot tự chọn từ video người: video $\rightarrow$ mô-đun ý định $\rightarrow$ token ý định $\rightarrow$ hành động.

Song song, cải thiện mô-đun ý định (chỉ bằng kiểm tra chéo, không dùng lại tập test riêng):

- Chú trọng hơn vào các khung gần nhất, vì nhóm tác giả EgoIntent nhận thấy khung cuối thường mang nhiều thông tin hơn cả đoạn.
- Kết hợp điểm có và không bỏ khung cảnh chung, để giữ được thông tin "đang ở khung cảnh nào".
- Huấn luyện nhẹ một lớp hiệu chỉnh trên SigLIP với mẫu âm là các câu của cùng video.
- So sánh với một mô hình ngôn ngữ–thị giác lớn (Qwen2.5-VL) để biết mức trần.

Dữ liệu tự thu. Nhóm đã thiết kế một bộ dữ liệu nhỏ theo kịch bản "trà chiều cùng robot" (mời robot vào bàn, chọn cốc, chia bánh, sắp xếp bàn, đổi ý giữa chừng, dọn dẹp). Mỗi lần quay, người thực hiện bốc thăm một mục tiêu bí mật; các mục tiêu khác nhau mở đầu bằng cùng một động tác, và mục tiêu không được nói ra. Bộ dữ liệu này sẽ là tập test độc lập mới, và là bước đệm để đánh giá trên robot UR5. [CẦN ĐIỀN: Số người tham gia và số video đã quay, nếu có.]

TÀI LIỆU THAM KHẢO

[1] A. Brohan *et al.*, "RT-1: Robotics Transformer for real-world control at scale," *arXiv:2212.06817*, 2022.

[2] B. Zitkovich *et al.*, "RT-2: Vision-language-action models transfer web knowledge to robotic control," in *Proc. Conference on Robot Learning (CoRL)*, PMLR 229, 2023, pp. 2165–2183.

[3] Open X-Embodiment Collaboration, "Open X-Embodiment: Robotic learning datasets and RT-X models," in *Proc. IEEE Int. Conf. Robotics and Automation (ICRA)*, 2024, pp. 6892–6903.

[4] M. Shukor *et al.*, "SmolVLA: A vision-language-action model for affordable and efficient robotics," *arXiv:2506.01844*, 2025.

[5] R. Cadene *et al.*, "LeRobot: An open-source library for end-to-end robot learning," in *Proc. Int. Conf. Learning Representations (ICLR)*, 2026.

[6] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel, and M. Le, "Flow matching for generative modeling," in *Proc. ICLR*, 2023.

[7] A. Marafioti *et al.*, "SmolVLM: Redefining small and efficient multimodal models," *arXiv:2504.05299*, 2025.

[8] O. Zohar, M. Farre, A. Marafioti *et al.*, "SmolVLM2: Bringing video understanding to every device," Hugging Face technical blog, 2025.

[9] B. Liu, Y. Zhu, C. Gao, Y. Feng, Q. Liu, Y. Zhu, and P. Stone, "LIBERO: Benchmarking knowledge transfer for lifelong robot learning," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[10] K. Grauman *et al.*, "Ego4D: Around the world in 3,000 hours of egocentric video," in *Proc. IEEE/CVF CVPR*, 2022, pp. 18995–19012.

[11] K. Grauman *et al.*, "Ego-Exo4D: Understanding skilled human activity from first- and third-person perspectives," in *Proc. IEEE/CVF CVPR*, 2024, pp. 19383–19400.

[12] "EgoIntent: An open-ended benchmark for intent understanding at pre-outcome micro-steps in egocentric procedural activities," Hugging Face dataset card (`py2279105943/EgoIntent`), 2026.

[13] E. Valls Mascaro, H. Ahn, and D. Lee, "Intention-conditioned long-term human egocentric action anticipation," in *Proc. IEEE/CVF WACV*, 2023, pp. 6048–6057.

[14] Q. Zhao *et al.*, "AntGPT: Can large language models help long-term action anticipation from videos?" in *Proc. ICLR*, 2024.

[15] Q. Chu, H. Zhang, M. Liu, Y. Feng, H. Shi, and L. Nie, "Intention-guided cognitive reasoning for egocentric long-term action anticipation," in *Proc. AAAI Conf. Artificial Intelligence*, 2026.

[16] A. Radford *et al.*, "Learning transferable visual models from natural language supervision," in *Proc. Int. Conf. Machine Learning (ICML)*, PMLR 139, 2021, pp. 8748–8763.

[17] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer, "Sigmoid loss for language image pre-training," in *Proc. IEEE/CVF ICCV*, 2023, pp. 11975–11986.

[18] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence embeddings using Siamese BERT-networks," in *Proc. EMNLP-IJCNLP*, 2019, pp. 3982–3992.

[19] F. Zhang *et al.*, "MediaPipe Hands: On-device real-time hand tracking," *arXiv:2006.10214*, 2020.