ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

Vũ Thị Thu Trang

TĂNG CƯỜNG KHẢ NĂNG HIỂU Ý ĐỊNH NGƯỜI DÙNG CHO ROBOT CỘNG TÁC DỰA TRÊN MÔ HÌNH VLA

ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC HỆ CHÍNH QUY

Ngành: Kỹ thuật Robot

HÀ NỘI – 2026

ĐẠI HỌC QUỐC GIA HÀ NỘI

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

Vũ Thị Thu Trang

TĂNG CƯỜNG KHẢ NĂNG HIỂU Ý ĐỊNH NGƯỜI DÙNG CHO ROBOT CỘNG TÁC DỰA TRÊN MÔ HÌNH VLA

ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC HỆ CHÍNH QUY

Ngành: Kỹ thuật Robot

Cán bộ hướng dẫn: PGS.TS. Hoàng Văn Xiêm
(ký tên)

HÀ NỘI – 2026

TÓM TẮT

Tóm tắt: Robot cộng tác làm việc cạnh con người sẽ hữu ích hơn nếu tự đoán được người đó *định làm gì*, thay vì chờ một câu lệnh. Các mô hình Thị giác–Ngôn ngữ–Hành động (VLA) như SmolVLA chỉ biết mục tiêu qua câu lệnh: trên bộ mô phỏng LIBERO-10, SmolVLA thành công 19/100 lượt với câu lệnh đúng nhưng 0/100 lượt khi câu lệnh bị bỏ trống. Đồ án đề xuất kiến trúc VLIA (Vision–Language–Intention–Action), gồm một mô-đun ý định xem vài khung hình đầu của video góc nhìn thứ nhất, chọn ra mục đích của bước thao tác người đang làm, rồi đưa mục đích đó vào SmolVLA dưới dạng một token ý định.

Mô-đun ý định được xây dựng qua các giai đoạn thực nghiệm nối tiếp trên bộ dữ liệu EgoIntent. Thử nghiệm ban đầu trên tập nhỏ cho thấy các mô hình huấn luyện có cấu trúc phức tạp không vượt được cách lấy trung bình khung hình, và 81,5% lỗi là nhầm giữa các bước trong cùng một tác vụ. Trên 2.503 bước thao tác (27 video, 13 khung cảnh) với kiểm tra chéo theo khung cảnh, lớp đọc huấn luyện trên đặc trưng của chính backbone SmolVLM2 chỉ gần bằng đoán mò. Bộ mã hóa ảnh–văn bản SigLIP dùng nguyên, không huấn luyện, đạt 27,5–28,9% khi chọn đúng mục đích trong 5 câu của cùng video (đoán mò 20%). Dùng SigLIP cỡ lớn và trừ đi phần khung cảnh chung của các bước trước, độ chính xác đạt 34,1–38,7%, và cấu hình này được chọn giống nhau ở cả 8 lần kiểm tra chéo. Trên tập test riêng chỉ chạy một lần, cấu hình đề xuất đạt 30,2% so với 21,4% của SigLIP cơ bản khi xem 8 khung hình. Nếu chỉ trả lời một nửa số trường hợp chắc chắn nhất, độ chính xác tăng thêm 6,9–7,9 điểm, nên robot biết khi nào cần hỏi lại. Khi đoán hành động sắp tới chỉ từ 8 khung gần nhất, độ chính xác giảm từ 38,0% (đoán trước 0,6 giây) rồi đi ngang ở khoảng 25–27% từ khoảng 12 giây (đo theo giây thật); xem đoạn dài hơn 4 giây không giúp, còn số khung trong đoạn không ảnh hưởng (2 khung rải trong 4 giây đã đủ), nhưng độ chắc chắn của mô-đun gần như không đổi theo khoảng đoán trước. Các thử nghiệm cải thiện thêm cho thấy cấu hình đề xuất gần như đã là tốt nhất: huấn luyện thêm một lớp hiệu chỉnh làm kém đi 2–4 điểm, mô hình Qwen2.5-VL-3B không huấn luyện chỉ đạt ngang (39,8% so với 38,7% ở 8 khung), còn cộng thêm điểm không trừ khung cảnh làm MRR toàn tập tăng 10–21%. Phía robot, khi câu lệnh luôn để trống và nhiệm vụ chỉ được đưa vào qua token ý định, SmolVLA thành công 20/100 lượt, ngang với 19/100 khi nghe câu lệnh đúng, còn token ý định sai cho 0/100. Như vậy

token ý định thay được câu lệnh.

Từ khóa: *robot cộng tác, dự đoán ý định, mô hình VLA, video góc nhìn thứ nhất.*

LỜI CAM ĐOAN

Tôi xin cam đoan đồ án tốt nghiệp "*Tăng cường khả năng hiểu ý định người dùng cho robot cộng tác dựa trên mô hình VLA*" là công trình nghiên cứu của riêng tôi, được thực hiện dưới sự hướng dẫn của PGS.TS. Hoàng Văn Xiêm. Các nội dung nghiên cứu và kết quả trong đồ án là trung thực; mọi số liệu được tính trực tiếp từ các tệp kết quả thực nghiệm do tôi thực hiện. Tôi không sao chép tài liệu, công trình nghiên cứu của người khác mà không chỉ rõ trong tài liệu tham khảo. Nếu có bất kỳ sai phạm nào, tôi xin hoàn toàn chịu trách nhiệm.

Hà Nội, ngày … tháng … năm 2026

Sinh viên

(ký và ghi rõ họ tên)

Vũ Thị Thu Trang

MỤC LỤC

TÓM TẮT i

LỜI CAM ĐOAN iii

BẢNG CÁC KÝ HIỆU, CHỮ VIẾT TẮT viii

MỞ ĐẦU 1

1 Tổng quan 3

1.1 Đặt vấn đề . . . 3

1.1.1 Robot VLA cần biết mục tiêu . . . 3

1.1.2 Đoán ý định từ hình ảnh là bài toán nhập nhằng . . . 3

1.1.3 Câu hỏi nghiên cứu . . . 4

1.2 Các nghiên cứu liên quan . . . 4

1.2.1 Mô hình VLA cho robot thao tác . . . 4

1.2.2 Nhận biết ý định trong tương tác người–robot . . . 5

1.2.3 Video góc nhìn thứ nhất và dự đoán hành động . . . 5

1.2.4 Mô hình ảnh–văn bản . . . 6

1.2.5 Học từ nhiều góc nhìn . . . 6

1.2.6 Khoảng trống nghiên cứu . . . 6

1.3 Mục tiêu và phạm vi . . . 7

2 Cơ sở lý thuyết 9

2.1 Video góc nhìn thứ nhất và ý định mức bước . . . 9

2.2 Transformer và cơ chế chú ý . . . 10

2.3 Mô hình ngôn ngữ–thị giác SmolVLM2 . . . 10

2.4 Mô hình VLA SmolVLA . . . 11

2.5 Flow matching 12
2.6 Học tương phản ảnh–văn bản 12
2.6.1 Độ tương đồng cosine và bài toán chọn câu 12
2.6.2 Hàm mất mát InfoNCE 13
2.6.3 Hiện tượng sụp biểu diễn 13
2.6.4 CLIP, SigLIP và dùng không cần huấn luyện 13
2.6.5 Thành phần chung trong không gian biểu diễn 14
2.7 Thước đo và phương pháp thống kê 14
2.7.1 Độ chính xác chọn 1 trong N và MRR 14
2.7.2 Kiểm tra chéo theo nhóm và chọn lồng nhau 14
2.7.3 Khoảng tin cậy bootstrap theo cụm 15
2.7.4 Khoảng tin cậy Wilson cho tỉ lệ thành công 15
2.7.5 Dự đoán có quyền từ chối 15

3 Phương pháp đề xuất **16**
3.1 Phát biểu bài toán 16
3.2 Kiến trúc tổng thể VLIA 17
3.3 Mô-đun ý định 17
3.3.1 Mã hóa khung hình và câu 18
3.3.2 Gộp các khung 18
3.3.3 Trừ khung cảnh chung 18
3.3.4 Câu mẫu và cấu hình đề xuất 19
3.4 Trả lời có chọn lọc 19
3.5 Token ý định trong SmolVLA 20
3.5.1 Intention Adapter và vị trí chèn 20
3.5.2 Mặt nạ chú ý 20
3.5.3 Huấn luyện và suy luận 20
3.5.4 Tương thích với SmolVLA gốc 21
3.6 Ý định biết trước cho thí nghiệm robot 21

3.7 Cài đặt hệ thống 22
3.7.1 Môi trường và tổ chức mã nguồn 22
3.7.2 Đường dữ liệu và tính tái lập 23
3.7.3 Kiểm thử cài đặt 23

4 Thực nghiệm và đánh giá **25**
4.1 Dữ liệu và thiết lập thực nghiệm 25
4.1.1 Dữ liệu EgoIntent 25
4.1.2 Cách đánh giá 26
4.1.3 Thiết lập phía robot 27
4.2 Lộ trình thực nghiệm 27
4.3 Giai đoạn 0: Thử nghiệm ban đầu trên tập nhỏ 27
4.3.1 Thiết lập chung 27
4.3.2 Thí nghiệm 0A: Học biểu diễn như thế nào, từ đầu vào nào . . . 28
4.3.3 Thí nghiệm 0B: Có cần mô hình hóa thứ tự khung hình không . 29
4.3.4 Thí nghiệm 0C: Dùng hành động (WHAT) để đoán mục đích (WHY) 30
4.3.5 Thí nghiệm 0D: Học thêm từ video góc nhìn thứ ba 31
4.3.6 Phân tích lỗi: mô hình sai ở đâu 32
4.3.7 Chuẩn bị phía robot 32
4.3.8 Kết luận giai đoạn 0 33
4.4 Giai đoạn 1: Lớp đọc trên đặc trưng của backbone VLA 33
4.5 Giai đoạn 2: Bộ mã hóa ảnh–văn bản SigLIP, không huấn luyện 35
4.6 Giai đoạn 3: Chọn cấu hình tốt nhất, không huấn luyện 37
4.7 Giai đoạn 4: Kiểm tra một lần trên tập test riêng 38
4.8 Giai đoạn 5: Biết khi nào nên hỏi lại 40
4.8.1 Những hướng đã thử nhưng không giúp 40
4.9 Giai đoạn 6: Nối mô-đun ý định vào SmolVLA 42
4.9.1 Cài đặt token ý định 42
4.9.2 SmolVLA phụ thuộc vào câu lệnh đến mức nào 42

4.9.3 Token ý định thay cho câu lệnh 43
4.10 Giai đoạn 7: Robot đoán trước được bao xa 44
4.10.1 Đo lại theo giây thật: xem bao lâu và đoán xa bao nhiêu 47
4.11 Giai đoạn 8: Thử cải thiện cấu hình đã chốt 49
4.11.1 Chú trọng khung gần nhất và kết hợp hai cách tính điểm 49
4.11.2 Huấn luyện nhẹ một lớp hiệu chỉnh 50
4.11.3 Mô hình ngôn ngữ–thị giác lớn làm bài trắc nghiệm 51
4.11.4 Đoán bước tiếp theo 52
4.11.5 So với các cách làm cơ sở trong tài liệu 52
4.12 Giai đoạn 9: Số khung hình, độ dài đoạn nhìn và khâu nhận ra hành động 55
4.12.1 Tách số khung khỏi độ dài đoạn nhìn 55
4.12.2 Đo lại khâu nhận ra hành động hiện tại 56
4.12.3 Nhận ra hành động tốt hơn rồi mới đoán bước tiếp theo 57
4.12.4 Vì sao không dùng các mô hình video góc nhìn thứ nhất 58
4.13 Tổng hợp các giai đoạn 59
4.14 Thảo luận 59
4.14.1 Vì sao backbone của VLA không đọc được ý định 59
4.14.2 Vì sao trừ khung cảnh chung có ích, và cái giá của nó 60
4.14.3 Kết quả trên tập test riêng 60
4.14.4 Ý nghĩa cho robot cộng tác 61
4.14.5 Những yếu tố có thể ảnh hưởng tới kết luận 61

KẾT LUẬN **64**

PHỤ LỤC **68**

TÀI LIỆU THAM KHẢO **71**

BẢNG CÁC KÝ HIỆU, CHỮ VIẾT TẮT

Ký hiệu / Chữ viết tắt	Diễn giải
CI	Confidence interval: khoảng tin cậy (95%), ước lượng bằng bootstrap theo video
CLIP	Contrastive Language–Image Pre-training: mô hình ảnh–văn bản học tương phản
GĐ	Giai đoạn thực nghiệm (GĐ 0 đến GĐ 6)
k	Số khung hình đầu của bước mà mô-đun ý định được xem, $k \in \{2,4,6,8\}$
KV cache	Key–value cache: bộ nhớ đệm khóa–giá trị của Transformer khi suy luận
LIBERO-10	Bộ 10 nhiệm vụ thao tác dài trong môi trường mô phỏng LIBERO
MLP	Multi-layer perceptron: mạng nơ-ron truyền thẳng nhiều lớp
MRR	Mean reciprocal rank: trung bình nghịch đảo thứ hạng của câu đúng
NEXT	Nhãn bước tiếp theo trong EgoIntent
SigLIP	Sigmoid Language–Image Pre-training: mô hình ảnh–văn bản dùng mất mát sigmoid
SmolVLA	Mô hình VLA mã nguồn mở cỡ nhỏ của Hugging Face
SmolVLM2	Mô hình ngôn ngữ–thị giác cỡ nhỏ, là backbone của SmolVLA
τ	Hệ số nhiệt độ trong hàm mất mát tương phản
VLA	Vision–Language–Action: mô hình nhận ảnh và câu lệnh, sinh hành động robot
VLIA	Vision–Language–Intention–Action: kiến trúc đề xuất, VLA có thêm token ý định
VLM	Vision–Language Model: mô hình hiểu đồng thời ảnh và văn bản
WHAT	Nhãn hành động con quan sát được của một bước trong EgoIntent
WHY	Nhãn mục đích của một bước trong EgoIntent; trong đồ án gọi là ý định
$\mathbf{z}^{\text{int}}$	Vector ý định do mô-đun ý định tạo ra

MỞ ĐẦU

Tính cần thiết của đề tài

Robot công nghiệp truyền thống làm việc trong lồng an toàn và lặp lại các động tác đã lập trình sẵn. *Robot cộng tác* (cobot) thì làm việc chung không gian với con người: đưa dụng cụ cho thợ, giữ chi tiết khi người lắp ráp, dọn bàn cùng người dùng. Để phối hợp nhịp nhàng, robot không thể chỉ phản ứng sau khi người đã làm xong một việc; nó cần đoán trước người đó *đang định làm gì*. Các khảo sát về tương tác người–robot coi nhận biết ý định là điều kiện để robot hỗ trợ đúng lúc và đúng việc [30].

Trong vài năm gần đây, các mô hình *Thị giác–Ngôn ngữ–Hành động* (Vision–Language–Action, VLA) như RT-2 [58], OpenVLA [23], π_0 [3] và SmolVLA [43] đã trở thành hướng chính cho robot thao tác. Một mô hình VLA nhận ảnh camera, một câu lệnh (ví dụ "đặt cái bát vào ngăn kéo") và trạng thái robot, rồi sinh ra chuỗi lệnh điều khiển. Mục tiêu của nhiệm vụ đi vào mô hình *chỉ* qua câu lệnh. Đồ án đo trực tiếp mức phụ thuộc này trên bộ mô phỏng LIBERO-10: SmolVLA hoàn thành 19/100 lượt khi có câu lệnh đúng, nhưng 0/100 lượt khi câu lệnh bị bỏ trống (Mục 4.9). Trong khi đó, khi cộng tác thật, con người hiếm khi nói ra mọi ý định của mình. Vì vậy cần một thành phần giúp robot VLA tự suy ra mục tiêu từ những gì người đang làm, rồi đưa mục tiêu đó vào đúng chỗ câu lệnh còn thiếu. Đây là lý do đề tài được thực hiện.

Ý nghĩa khoa học và thực tiễn

Về khoa học, đồ án trả lời ba câu hỏi chưa có câu trả lời rõ trong tài liệu: (i) backbone ngôn ngữ–thị giác của một VLA có sẵn đủ thông tin để đọc ý định của người từ video hay không; (ii) có thể phân biệt các mục đích cạnh tranh *trong cùng một hoạt động* khi mới thấy phần đầu của bước thao tác đến mức nào, và yếu tố nào quyết định điều đó; (iii) độ chắc chắn của dự đoán có dùng được để robot biết khi nào nên hỏi lại hay không. Mọi kết luận đều dựa trên kiểm tra chéo theo khung cảnh, khoảng tin cậy theo video và một tập test chỉ chạy một lần.

Về thực tiễn, đồ án cung cấp một mô-đun ý định không cần huấn luyện, chạy được với bộ mã hóa công khai, cùng một cách nối mô-đun đó vào SmolVLA chỉ bằng một token thêm vào đầu vào. Thiết kế này cho phép thay mô-đun ý định mà không phải sửa

chính sách điều khiển, và giữ nguyên hành vi của SmolVLA gốc khi tắt token ý định.

Đối tượng và phương pháp nghiên cứu

Đối tượng nghiên cứu là ý định ở mức bước thao tác: mục đích (WHY) của một bước ngắn trong một hoạt động thao tác bằng tay, quan sát qua video góc nhìn thứ nhất. Dữ liệu chính là bộ EgoIntent [14], được xây dựng từ video Ego4D [18]. Chính sách robot được nghiên cứu là SmolVLA trên bộ mô phỏng LIBERO-10 [28].

Phương pháp nghiên cứu là thực nghiệm theo giai đoạn. Mỗi giai đoạn đặt một câu hỏi, thiết kế một thí nghiệm có mốc so sánh, đo kết quả với khoảng tin cậy, và dùng kết quả để quyết định giai đoạn sau. Tiêu chí đạt của mỗi giai đoạn được ghi vào kho mã trước khi chạy. Mô hình được chọn bằng kiểm tra chéo lồng nhau trên dữ liệu phát triển, rồi đánh giá một lần trên tập test riêng.

Nội dung nghiên cứu

1. Tổng quan về robot VLA, nhận biết ý định và dự đoán hành động từ video góc nhìn thứ nhất (Chương 1).
2. Cơ sở lý thuyết của SmolVLA, học tương phản ảnh–văn bản và các phương pháp thống kê dùng để đánh giá (Chương 2).
3. Đề xuất kiến trúc VLIA gồm mô-đun ý định và token ý định trong SmolVLA, cùng phần cài đặt (Chương 3).
4. Thực nghiệm theo giai đoạn trên EgoIntent và LIBERO-10, từ thử nghiệm ban đầu đến tập test riêng và thí nghiệm phía robot (Chương 4).

Chương 1. TỔNG QUAN

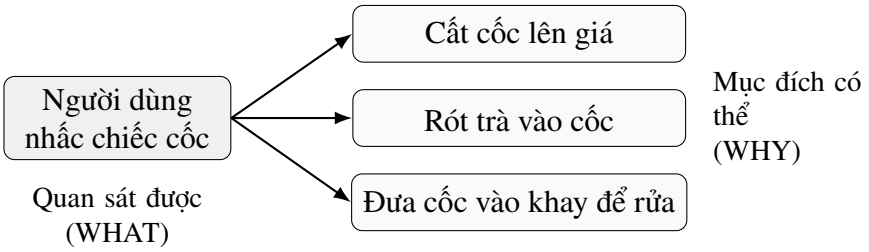
1.1. Đặt vấn đề

1.1.1. Robot VLA cần biết mục tiêu

Một mô hình VLA thường gồm hai phần: một *mô hình ngôn ngữ–thị giác* (Vision–Language Model, VLM) đọc ảnh và câu lệnh, và một *bộ sinh hành động* biến kết quả đọc thành lệnh điều khiển [3, 5, 32, 58]. Cách tổ chức này cho phép một mô hình làm nhiều nhiệm vụ: cùng một robot, cùng một bàn bếp, nhưng câu lệnh khác thì hành động khác. Mặt trái là mô hình không có nguồn nào khác để biết nên làm gì. Khi câu lệnh trống hoặc sai, chính sách vẫn sinh ra chuyển động, nhưng không hướng tới mục tiêu nào cụ thể. Thí nghiệm ở Mục 4.9 cho thấy điều này rõ ràng: với câu lệnh rỗng hoặc câu lệnh của nhiệm vụ khác, SmolVLA chạy hết giới hạn 520 bước ở cả 200 lượt mà không hoàn thành nhiệm vụ nào.

1.1.2. Đoán ý định từ hình ảnh là bài toán nhập nhằng

Cách tự nhiên để bù vào chỗ câu lệnh là cho robot nhìn người và tự đoán mục đích. Khó khăn là một động tác ban đầu thường phù hợp với nhiều mục đích khác nhau (Hình 1.1). Trong cùng một hoạt động, các bước lại diễn ra trong cùng khung cảnh, với cùng đồ vật và cùng đôi tay, nên phần lớn nội dung ảnh giống nhau giữa các bước. Thử nghiệm ban đầu của đồ án xác nhận điều này bằng số liệu: 81,5% lỗi của mô hình là nhầm sang mục đích của một bước khác *trong cùng tác vụ* (Mục 4.3.6).



Hình 1.1. Cùng một động tác quan sát được có thể dẫn tới nhiều mục đích khác nhau. Robot cần phân biệt các mục đích này khi mới thấy phần đầu của động tác.

1.1.3. Câu hỏi nghiên cứu

Từ hai vấn đề trên, đồ án đặt ra sáu câu hỏi, mỗi câu được trả lời bởi một hoặc nhiều giai đoạn thực nghiệm ở Chương 4:

Q1. Đặc trưng của backbone VLA (SmolVLM2) có đủ để đọc mục đích của người từ video góc nhìn thứ nhất không? (giai đoạn 0–1)

Q2. Khi mới thấy k khung hình đầu, có thể chọn đúng mục đích giữa các bước *cùng video* đến mức nào, và cấu hình nào làm được điều đó tốt nhất? (giai đoạn 2–4)

Q3. Độ chắc chắn của mô-đun ý định có cho biết lúc nào nên hỏi lại người không? (giai đoạn 5)

Q4. SmolVLA phụ thuộc vào thông tin mục tiêu đến mức nào, có thể đưa ý định vào SmolVLA mà không phá vỡ mô hình gốc không, và ý định có thay được câu lệnh không? (giai đoạn 6)

Q5. Chỉ từ đoạn video gần nhất, mô-đun ý định đoán trước được hành động sắp tới xa đến mức nào, và độ chắc chắn của nó thay đổi ra sao theo khoảng đoán trước? (giai đoạn 7)

Q6. Cấu hình đã chốt có cải thiện được thêm bằng cách gộp khung khác, huấn luyện nhẹ hay một mô hình ngôn ngữ–thị giác lớn không, và có đoán được bước tiếp theo không? (giai đoạn 8)

1.2. Các nghiên cứu liên quan

1.2.1. Mô hình VLA cho robot thao tác

RT-1 [5] cho thấy một Transformer đa nhiệm vụ huấn luyện trên dữ liệu robot thật có thể làm hàng trăm nhiệm vụ theo câu lệnh. RT-2 [58] đặt tên cho lớp mô hình VLA: lấy một VLM đã học trên dữ liệu Internet và tinh chỉnh để sinh hành động dưới dạng token, nhờ đó robot hiểu được các khái niệm chưa từng có trong dữ liệu robot. Open X-Embodiment [32] gom dữ liệu của nhiều loại robot để huấn luyện chung. OpenVLA [23] là một VLA mã nguồn mở 7 tỷ tham số. π_0 [3] thay việc sinh token hành động bằng một bộ sinh liên tục dựa trên flow matching [27]. SmolVLA [43] theo hướng của π_0 nhưng nhỏ hơn nhiều (khoảng 450 triệu tham số), chạy được trên một GPU thông thường, và được phát hành trong thư viện LeRobot [6]. Điểm chung của mọi mô hình trên là mục tiêu đến từ câu lệnh; không mô hình nào có thành phần ước lượng ý định của

người. Đồ án chọn SmolVLA làm nền vì nó có mã nguồn đầy đủ, kích thước vừa với tài nguyên tính toán, và có sẵn checkpoint cho LIBERO.

1.2.2. Nhận biết ý định trong tương tác người–robot

Trong điều khiển chia sẻ và tương tác vật lý người–robot, ý định thường được suy ra từ lực, quỹ đạo hoặc tín hiệu sinh học, rồi dùng để phân xử quyền điều khiển giữa người và robot [30]. Các phương pháp này giả định một tập mục tiêu nhỏ, định nghĩa trước (ví dụ vị trí đích trên bàn), và thường cần cảm biến tiếp xúc. Đồ án quan tâm tới trường hợp khác: robot quan sát người bằng camera khi người đang làm một hoạt động có nhiều bước, và mục tiêu là một câu mô tả mục đích viết tự do.

Một hướng gần khác là *dự đoán chuyển động của người* để robot phối hợp. ManiCast [21] học dự đoán quỹ đạo tay và cơ thể người trong khoảng ngắn phía trước, huấn luyện bộ dự đoán theo chi phí của bộ lập kế hoạch robot, rồi dùng dự đoán đó để lập kế hoạch trong các tác vụ như khuấy cùng nồi, trao đồ vật và cùng dọn bàn. Đầu ra của hướng này là *quỹ đạo liên tục* trong không gian, phù hợp để tránh va chạm và phối hợp chuyển động tức thời. Đồ án đi theo hướng bổ sung: đầu ra là *mục đích ngữ nghĩa* của bước thao tác dưới dạng một câu, đưa vào đúng chỗ của câu lệnh trong mô hình VLA. Hai loại dự đoán trả lời hai câu hỏi khác nhau, "tay người sẽ đi tới đâu" và "người làm việc này để làm gì", nên có thể dùng cùng nhau trong một hệ thống cộng tác.

1.2.3. Video góc nhìn thứ nhất và dự đoán hành động

Video góc nhìn thứ nhất (egocentric video) được quay từ camera gắn trên đầu hoặc ngực người thực hiện, nên thấy đúng bàn tay, vật đang cầm và vùng làm việc. EPIC-KITCHENS [12] và Ego4D [18] là hai bộ dữ liệu lớn đã thúc đẩy hướng nghiên cứu này, với các bài toán như nhận dạng hành động, dự đoán hành động sắp tới và dự đoán dài hạn.

Bài toán gần với đồ án nhất là *dự đoán hành động*. Ryoo [42] đặt bài toán nhận ra một hoạt động khi mới thấy phần đầu; khảo sát của Kong và Fu [24] tổng hợp các phương pháp dự đoán hành động từ video. Với video góc nhìn thứ nhất, Valls Mascaró và cộng sự [46] mô hình hóa ý định như một biến ẩn điều khiển chuỗi hành động tương lai; AntGPT [55] dùng mô hình ngôn ngữ lớn để suy ra mục tiêu rồi sinh chuỗi hành động; INSIGHT [11] kết hợp suy luận ý định với dự đoán dài hạn. Các công trình này cho thấy thông tin mục tiêu giúp thu hẹp không gian hành động tương lai, nhưng đầu ra

chính của chúng vẫn là *nhãn hành động kế tiếp*.

EgoIntent [14] là bộ dữ liệu gần nhất với mục tiêu của đồ án. Mỗi video được chia thành các bước ngắn, mỗi bước kết thúc *trước* khi kết cục xảy ra, và được gán ba nhãn: hành động nhìn thấy (WHAT), mục đích (WHY) và bước tiếp theo (NEXT). Nhóm tác giả EgoIntent nhận thấy khung hình cuối của bước thường mang nhiều thông tin hơn cả đoạn, và xem thêm lịch sử dài không giúp đoán mục đích. Đồ án dùng WHY của EgoIntent làm định nghĩa ý định.

1.2.4. Mô hình ảnh–văn bản

CLIP [35] và SigLIP [52] học hai bộ mã hóa, một cho ảnh và một cho văn bản, trên hàng trăm triệu cặp ảnh–chú thích, sao cho ảnh và chú thích đúng nằm gần nhau. Vì đã học rất nhiều khái niệm, chúng dùng được ngay mà không cần huấn luyện thêm (*zero-shot*): mã hóa ảnh và các câu ứng viên, rồi chọn câu gần nhất. Các phiên bản lớn hơn như SigLIP so400m [1] và SigLIP 2 [45] cải thiện thêm độ chính xác. Với video góc nhìn thứ nhất, EgoVLP [26] học trước trên cặp video–chú thích của Ego4D và cho thấy liên kết video với chữ giúp nhiều bài toán phía sau. Các nghiên cứu về "khoảng cách giữa hai miền" [25] chỉ ra rằng vector của các mô hình này chứa một thành phần chung lớn không mang thông tin phân biệt; đây là cơ sở cho bước trừ phần khung cảnh chung trong mô-đun ý định của đồ án (Mục 3.3).

1.2.5. Học từ nhiều góc nhìn

Robot nhìn người từ bên ngoài, không phải từ mắt người. Charades-Ego [44] là một trong những bộ dữ liệu đầu tiên ghép video góc nhìn thứ nhất với góc nhìn thứ ba của cùng hoạt động; HOMAGE [38] mở rộng với nhiều camera đồng bộ trong nhà; Ego-Exo4D [19] cung cấp dữ liệu hai góc nhìn quy mô lớn cho các hoạt động có kỹ năng. ENIGMA-360 [37], kế thừa ENIGMA-51 [36], cung cấp cặp video hai góc nhìn đồng bộ trong bối cảnh công nghiệp. Đồ án dùng ENIGMA-360 để kiểm tra xem học ghép hai góc nhìn có giúp đoán mục đích không (Mục 4.3).

1.2.6. Khoảng trống nghiên cứu

Từ các công trình trên có thể thấy ba khoảng trống. Thứ nhất, các mô hình VLA chưa có nguồn thông tin mục tiêu nào ngoài câu lệnh. Thứ hai, các nghiên cứu dự đoán hành động chủ yếu đoán nhãn hành động kế tiếp trong một tập nhãn cố định, ít khi đo

khả năng *phân biệt các mục đích cạnh tranh trong cùng hoạt động* khi mới thấy phần đầu của bước. Thứ ba, chưa có đánh giá nào cho biết backbone của chính VLA có đọc được ý định hay không, và nếu không thì nên lấy ý định từ đâu. Đồ án đặt mình vào giao của ba khoảng trống này.

1.3. Mục tiêu và phạm vi

Mục tiêu. Tên đề tài "Tăng cường khả năng hiểu ý định người dùng cho robot cộng tác dựa trên mô hình VLA" được cụ thể hóa thành hai việc:

1. **Xây dựng mô-đun ý định**: từ vài khung hình đầu của video góc nhìn thứ nhất, chọn ra câu mục đích của bước thao tác người đang làm. Chất lượng được đo bằng tỉ lệ chọn đúng mục đích trong 5 câu cùng video, với ngưỡng thực dụng 30%.
2. **Nối mô-đun ý định vào robot VLA**: đưa mục đích đã chọn vào SmolVLA dưới dạng một token ý định, đặt cạnh chỗ của câu lệnh.

Chữ "tăng cường" được hiểu là *bổ sung cho VLA một nguồn thông tin mục tiêu* khi người không nói ra, và *cải thiện dần chất lượng của nguồn đó* qua từng giai đoạn.

Đóng góp chính.

1. **Chỉ ra rằng backbone của VLA không tự đọc ra được ý định.** Một lớp đọc huấn luyện trên đặc trưng của SmolVLM2 chỉ gấp 1,13–1,19 lần mức ngẫu nhiên, và khoảng tin cậy đều chứa mức ngẫu nhiên.
2. **Đề xuất mô-đun ý định không cần huấn luyện**, dùng SigLIP cỡ lớn và trừ phần khung cảnh chung của các bước trước. Trên tập test riêng chạy một lần, mô-đun đạt **30,2%** chọn đúng trong 5 câu, so với 21,4% của SigLIP cơ bản và 20% của đoán mò; chỉ trả lời một nửa số trường hợp chắc nhất thì độ chính xác tăng thêm 6,9–7,9 điểm.
3. **Cho thấy token ý định thay được câu lệnh trong SmolVLA.** SmolVLA gốc đạt 19/100 với câu lệnh đúng và 0/100 khi bỏ câu lệnh; SmolVLA có token ý định, không cần câu lệnh, đạt **20/100**, còn token ý định sai cho 0/100.

Phạm vi. Đồ án giới hạn ở ý định mức bước, được biểu diễn bằng câu WHY của EgoIntent; giai đoạn 7 xét thêm ý định dưới dạng hành động tương lai (câu WHAT của bước sắp tới). Mô-đun ý định được đánh giá trên video của người; chính sách robot được đánh giá trên LIBERO-10 trong mô phỏng. Token ý định được chứng minh thay được

câu lệnh, nhưng vector ý định đưa cho robot vẫn được tạo từ mô tả đúng của nhiệm vụ, chưa phải ý định do mô-đun đoán từ video; đồ án cũng chưa triển khai trên robot thật.

Cấu trúc đồ án. Chương 2 trình bày cơ sở lý thuyết. Chương 3 phát biểu bài toán, mô tả kiến trúc VLIA và phần cài đặt. Chương 4 là phần chính: dữ liệu, cách đánh giá, và các giai đoạn thực nghiệm theo thứ tự đã thực hiện, mỗi giai đoạn gồm câu hỏi, cách làm, kết quả và kết luận dẫn tới giai đoạn sau. Phần Kết luận tổng kết kết quả, đánh giá, hạn chế và hướng phát triển.

Chương 2. CƠ SỞ LÝ THUYẾT

Chương này trình bày các khái niệm và công cụ mà các chương sau sử dụng: dữ liệu video góc nhìn thứ nhất và định nghĩa ý định (Mục 2.1), cơ chế chú ý của Transformer (Mục 2.2), mô hình SmolVLM2 và SmolVLA (Mục 2.3 and 2.4), flow matching (Mục 2.5), học tương phản ảnh–văn bản (Mục 2.6) và các phương pháp thống kê dùng để đánh giá (Mục 2.7).

2.1. Video góc nhìn thứ nhất và ý định mức bước

Một hoạt động thao tác (nhào bột, sửa xe đạp, hái quả) gồm nhiều *bước* ngắn nối tiếp nhau. Bộ dữ liệu EgoIntent [14] cắt mỗi video Ego4D [18] thành các bước như vậy và gán cho mỗi bước ba nhãn văn bản viết tự do:

- **WHAT**: hành động con nhìn thấy được, ví dụ "grasping basin" (cầm cái chậu).
- **WHY**: mục đích của bước, ví dụ "positioning basin" (đặt lại vị trí chậu).
- **NEXT**: bước tiếp theo trong quy trình.

Mỗi đoạn video của một bước kết thúc *trước* khi kết cục xảy ra, nên mô hình phải đoán mục đích từ phần chuẩn bị, không được nhìn thấy kết quả. WHAT thường nhìn thấy trực tiếp, còn WHY phải suy ra; hai bước có WHAT gần giống nhau vẫn có thể có WHY khác nhau.

Trong đồ án, **ý định** được định nghĩa là câu WHY của bước thao tác đang diễn ra. Định nghĩa này phân biệt ý định với các khái niệm gần nó:

- *Nhiệm vụ*: mục tiêu tổng thể của cả hoạt động ("làm bánh mì"), không đổi trong suốt video.
- *Hành động* (WHAT): điều đang quan sát được ở bước hiện tại.
- *Ý định* (WHY): lý do của bước hiện tại, thay đổi theo từng bước.
- *Lệnh điều khiển*: chuỗi chuyển động mức thấp mà robot thực thi.

Ý định vì vậy nằm giữa "robot hiểu người đang làm gì" và "robot nên làm gì": nó đủ cụ thể để robot hỗ trợ đúng bước, nhưng không phải là quỹ đạo chuyển động.

2.2. Transformer và cơ chế chú ý

Các mô hình dùng trong đồ án đều xây dựng trên Transformer [47]. Đầu vào là một dãy n vector (*token*) $\mathbf{X} \in \mathbb{R}^{n \times d}$. Mỗi lớp chú ý tính ba ma trận truy vấn, khóa và giá trị $\mathbf{Q} = \mathbf{X}\mathbf{W}_Q$, $\mathbf{K} = \mathbf{X}\mathbf{W}_K$, $\mathbf{V} = \mathbf{X}\mathbf{W}_V$, rồi

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\Big(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}} + \mathbf{M}\Big)\mathbf{V}, \tag{2.1}$$

trong đó $\mathbf{M}$ là *mặt nạ chú ý*: phần tử bằng $-\infty$ ở vị trí mà token i không được nhìn token j, bằng 0 ở các vị trí còn lại. Mỗi token vì vậy là tổng có trọng số của các token nó được phép nhìn, với trọng số do độ khớp giữa truy vấn và khóa quyết định.

Khi sinh đầu ra nhiều lần trên cùng một phần đầu vào cố định, khóa và giá trị của phần đó chỉ cần tính một lần rồi lưu lại, gọi là *bộ nhớ đệm khóa–giá trị* (KV cache) [34]. SmolVLA dùng cơ chế này: phần đầu vào gồm ảnh, câu lệnh và trạng thái được tính một lần, sau đó bộ sinh hành động đọc lại nhiều lần trong các bước tinh chỉnh (Mục 2.5). Điều này quan trọng cho token ý định: nếu token nằm trong phần đầu vào được lưu đệm, chi phí thêm gần như bằng 0.

2.3. Mô hình ngôn ngữ–thị giác SmolVLM2

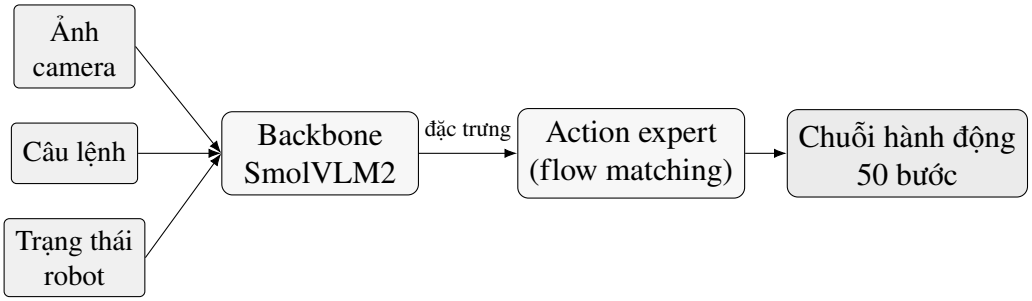
SmolVLM [31] và SmolVLM2 [59] là họ mô hình ngôn ngữ–thị giác cỡ nhỏ. Một bộ mã hóa ảnh thuộc họ SigLIP [52] biến ảnh thành một lưới đặc trưng; lưới này được nén lại (gộp các ô lân cận) và chiếu vào không gian của mô hình ngôn ngữ, tạo thành một số ít token ảnh. Các token ảnh được ghép với token văn bản, rồi đi qua một mô hình ngôn ngữ nhỏ. Phiên bản SmolVLM2-500M-Video-Instruct dùng trong đồ án có vector ẩn 960 chiều và được huấn luyện thêm trên video. Đây là backbone của SmolVLA, nên đặc trưng của nó là thứ chính sách robot "nhìn thấy".

Một điểm cần lưu ý: trong SmolVLM2, bộ mã hóa ảnh được nối vào mô hình ngôn ngữ, chứ không được huấn luyện để đặt ảnh và câu mô tả vào cùng một không gian so sánh được như CLIP hay SigLIP gốc. Vì vậy, muốn so đặc trưng ảnh của SmolVLM2 với câu mục đích, cần học thêm một lớp đọc (giai đoạn 1).

2.4. Mô hình VLA SmolVLA

SmolVLA [43] là một VLA mã nguồn mở khoảng 450 triệu tham số trong thư viện LeRobot [6]. SmolVLA xử lý một bước điều khiển như sau (Hình 2.1):

1. Ảnh của từng camera robot được mã hóa thành các token ảnh; câu lệnh được tách thành token văn bản; trạng thái khớp của robot được chiếu tuyến tính thành một token. Mọi token có cùng kích thước 960 chiều và được ghép thành một dãy, gọi là *tiền tố* (prefix):
$$P_{\text{base}} = \left[E_{\text{ảnh}};\ E_{\text{lệnh}};\ E_{\text{trạng thái}}\right]. \tag{2.2}$$
Độ dài tiền tố không cố định: nó phụ thuộc số camera và độ dài câu lệnh.
2. Tiền tố đi qua backbone SmolVLM2. Để nhẹ hơn, SmolVLA chỉ dùng một nửa số lớp đầu của mô hình ngôn ngữ.
3. Một *action expert*, một Transformer nhỏ hơn với vector ẩn 720 chiều, đọc kết quả của backbone qua cơ chế chú ý chéo và sinh ra một khối 50 bước hành động liên tiếp (*action chunk*) bằng flow matching. Hành động được đệm tới tối đa 32 chiều; với LIBERO, chỉ 7 chiều đầu có nghĩa.



Hình 2.1. Sơ đồ đơn giản của SmolVLA [43]. Mục tiêu của nhiệm vụ chỉ đi vào mô hình qua câu lệnh.

Mặt nạ chú ý (công thức (2.1)) của SmolVLA chia tiền tố thành các khối: token ảnh và câu lệnh nhìn nhau hai chiều; token trạng thái nằm ở khối riêng; token hành động nhìn toàn bộ tiền tố và nhìn nhau theo khối. Đồ án phân tích mã nguồn để đặt token ý định vào đúng khối (Mục 3.5).

Điều quan trọng nhất cho đồ án là SmolVLA **không có thành phần nào ước lượng ý định của người**. Mục tiêu chỉ đến từ câu lệnh. Kiểm tra mã nguồn xác nhận không có nhánh nào dự đoán mục tiêu, nhiệm vụ hay ý định.

2.5. Flow matching

Flow matching [27] là một cách học sinh mẫu liên tục: học một *trường vận tốc* đưa nhiễu ngẫu nhiên dần về dữ liệu thật. Trong SmolVLA, "dữ liệu thật" là khối hành động $\mathbf{A} \in \mathbb{R}^{50\times 32}$. Khi huấn luyện, lấy nhiễu $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ và một thời điểm $t \in [0,1]$, tạo điểm trung gian

$$\mathbf{x}_t = t\,\boldsymbol{\varepsilon} + (1-t)\,\mathbf{A}, \tag{2.3}$$

và vận tốc đích $\mathbf{u}_t = \boldsymbol{\varepsilon} - \mathbf{A}$. Action expert dự đoán vận tốc $\mathbf{v}_\theta(\mathbf{x}_t, t \mid P)$ khi biết tiền tố P, và được huấn luyện bằng

$$\mathscr{L}_{\text{action}} = \mathbb{E}_{t,\boldsymbol{\varepsilon}} \left\| \mathbf{u}_t - \mathbf{v}_\theta(\mathbf{x}_t, t \mid P) \right\|^2, \tag{2.4}$$

chỉ tính trên các bước hành động hợp lệ (không phải phần đệm). Khi suy luận, bắt đầu từ nhiễu $\mathbf{x}_1 = \boldsymbol{\varepsilon}$ và đi ngược 10 bước Euler, $\mathbf{x}_{t-\Delta} = \mathbf{x}_t - \Delta\,\mathbf{v}_\theta(\mathbf{x}_t, t \mid P)$ với $\Delta = 0{,}1$, thu được khối hành động. Vì tiền tố P không đổi trong 10 bước này, khóa và giá trị của nó được lưu đệm một lần (Mục 2.2).

Hai hệ quả cho đồ án: (i) thêm thông tin vào tiền tố P không đổi hàm mất mát công thức (2.4), nên token ý định có thể được huấn luyện cùng chính sách mà không cần mục tiêu học mới; (ii) gradient của công thức (2.4) chảy ngược qua P, nên lớp chiếu token ý định nhận được tín hiệu học từ chính nhiệm vụ điều khiển.

2.6. Học tương phản ảnh–văn bản

2.6.1. Độ tương đồng cosine và bài toán chọn câu

Để so một đoạn video với một câu mô tả mục đích, cả hai được đưa về cùng một không gian vector, sao cho video và câu *đúng* nằm gần nhau. Độ gần được đo bằng độ tương đồng cosine

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\|\,\|\mathbf{v}\|} \in [-1, 1]. \tag{2.5}$$

Khi đó, chọn mục đích là chọn câu ứng viên có cosine cao nhất với vector của video.

2.6.2. Hàm mất mát InfoNCE

Học tương phản kéo cặp đúng lại gần và đẩy các cặp sai ra xa. Hàm mất mát InfoNCE [33] cho một vector video $\mathbf{z}$, câu đúng $\mathbf{t}^+$ và các câu sai $\mathbf{t}_j^-$ là

$$\mathscr{L}_{\text{NCE}} = -\log \frac{\exp(\cos(\mathbf{z}, \mathbf{t}^+)/\tau)}{\exp(\cos(\mathbf{z}, \mathbf{t}^+)/\tau) + \sum_j \exp(\cos(\mathbf{z}, \mathbf{t}_j^-)/\tau)}, \tag{2.6}$$

với τ là hệ số nhiệt độ: τ nhỏ làm mô hình chú ý nhiều hơn tới các câu sai gần nhất. Khi một mẫu có nhiều câu đúng (nhiều bước cùng một câu WHY), các câu đúng không được coi là câu sai của nhau; tử số được lấy trung bình trên các câu đúng [22]. *Mẫu âm khó*, tức các câu sai rất giống câu đúng, làm việc học hiệu quả hơn nếu được nhấn mạnh có kiểm soát [41].

2.6.3. Hiện tượng sụp biểu diễn

Nếu chỉ kéo dự đoán về gần câu đúng (mất mát cosine $1 - \cos(\mathbf{z}, \mathbf{t}^+)$) mà không đẩy các câu sai ra xa, mô hình có thể tìm được một lời giải tầm thường: trả về cùng một vector "trung bình" cho mọi đầu vào. Wang và Isola [50] phân tích học tương phản thành hai yêu cầu: *gần nhau* (cặp đúng gần) và *trải đều* (các vector phân tán trên mặt cầu). Mất mát cosine chỉ đáp ứng yêu cầu thứ nhất. Thí nghiệm 0A (Mục 4.3) gặp đúng hiện tượng này.

2.6.4. CLIP, SigLIP và dùng không cần huấn luyện

CLIP [35] huấn luyện bộ mã hóa ảnh f và bộ mã hóa văn bản g bằng InfoNCE hai chiều trên 400 triệu cặp ảnh–chú thích. SigLIP [52] thay softmax bằng một mất mát sigmoid độc lập cho từng cặp:

$$\mathscr{L}_{\text{SigLIP}} = -\frac{1}{|\mathscr{B}|} \sum_{i,j \in \mathscr{B}} \log \sigma\big(y_{ij}\,(a\,\mathbf{f}_i^\top \mathbf{g}_j + b)\big), \tag{2.7}$$

với $y_{ij} = 1$ nếu ảnh i và chú thích j là một cặp, -1 nếu không; a, b là hai tham số học được; $\mathbf{f}_i, \mathbf{g}_j$ đã chuẩn hóa. Cách này không cần chuẩn hóa trên cả lô nên huấn luyện được với lô rất lớn. Sau huấn luyện, có thể chọn câu cho một ảnh mới mà không cần huấn luyện thêm: mã hóa ảnh và mọi câu ứng viên, chọn câu có điểm cao nhất. Bọc câu ứng viên trong một câu mẫu (ví dụ "a photo of a {nhãn}") thường làm kết quả tốt hơn vì gần

với dạng chú thích lúc huấn luyện [35].

2.6.5. Thành phần chung trong không gian biểu diễn

Liang và cộng sự [25] chỉ ra rằng vector ảnh và vector văn bản của các mô hình học tương phản nằm trong hai "nón" hẹp, tách rời nhau; mọi vector ảnh chia sẻ một thành phần chung lớn. Trong bài toán của đồ án, thành phần chung còn lớn hơn: mọi khung hình của một video có cùng khung cảnh, đồ vật và ánh sáng. Một cách xử lý là trừ đi phần chung rồi mới so sánh, tương tự ý tưởng hiệu chỉnh theo "đầu vào rỗng" của Zhao và cộng sự [57]: biết trước mô hình thiên về các lựa chọn nào khi không có thông tin, rồi bù lại. Mô-đun ý định của đồ án dùng một biến thể chỉ nhìn quá khứ của ý tưởng này (Mục 3.3).

2.7. Thước đo và phương pháp thống kê

2.7.1. Độ chính xác chọn 1 trong N và MRR

Với mỗi bước i có tập ứng viên $\mathscr{C}_i$ gồm câu đúng và $N-1$ câu sai, độ chính xác chọn 1 trong N là tỉ lệ bước mà câu đúng có điểm cao nhất; đoán mò đạt $1/N$. Khi xếp câu đúng giữa *mọi* câu của tập kiểm tra, thứ hạng của nó là r_i và

$$\mathrm{MRR} = \frac{1}{n}\sum_{i=1}^{n}\frac{1}{r_i} \tag{2.8}$$

[48]: đứng đầu được 1 điểm, thứ hai được 0,5, thứ mười được 0,1. MRR tuyệt đối phụ thuộc số câu trong tập, nên đồ án báo cáo thêm tỉ số với MRR của xếp hạng ngẫu nhiên (bằng trung bình của $\frac{1}{|\mathscr{C}|}\sum_r 1/r$ trên tập ứng viên).

2.7.2. Kiểm tra chéo theo nhóm và chọn lồng nhau

Các bước trong cùng một video, cùng một khung cảnh rất giống nhau. Nếu chia ngẫu nhiên theo bước, các bước gần như trùng nhau rơi vào cả tập huấn luyện và tập kiểm tra, làm kết quả lạc quan giả tạo; Roberts và cộng sự [40] khuyến nghị chia theo nhóm có cấu trúc. Đồ án chia theo *khung cảnh*: mỗi lần giữ lại một nhóm khung cảnh để kiểm tra.

Khi thử nhiều cấu hình rồi báo cáo cấu hình tốt nhất trên cùng dữ liệu đánh giá, con số báo cáo bị lệch lên do chính việc chọn [8]. Cách tránh là *chọn lồng nhau*: trong

mỗi lần kiểm tra chéo, mọi việc chọn chỉ dùng các nhóm huấn luyện; nhóm giữ lại chỉ được dùng một lần để đo cấu hình đã chọn.

2.7.3. Khoảng tin cậy bootstrap theo cụm

Bootstrap [13] ước lượng độ bất định của một đại lượng bằng cách lấy mẫu lại dữ liệu có hoàn lại rồi tính lại đại lượng nhiều lần; khoảng giữa phân vị 2,5% và 97,5% là khoảng tin cậy 95%. Khi dữ liệu có cụm (các bước trong cùng video không độc lập), phải lấy mẫu lại *cả cụm*, nếu không khoảng tin cậy sẽ hẹp giả tạo [15]. Khi so hai phương pháp trên cùng các bước, đồ án tính hiệu trên từng bước rồi mới lấy mẫu lại theo video (hiệu ghép cặp). Một kết quả được coi là rõ ràng khi cả khoảng tin cậy nằm về một phía của mốc so sánh.

2.7.4. Khoảng tin cậy Wilson cho tỉ lệ thành công

Với s lượt thành công trên n lượt, khoảng Wilson [51] là

$$\frac{\hat{p} + \frac{z^2}{2n} \pm z\sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}, \qquad \hat{p} = \frac{s}{n},\ z = 1{,}96. \tag{2.9}$$

Khác với khoảng chuẩn $\hat{p} \pm z\sqrt{\hat{p}(1-\hat{p})/n}$, khoảng Wilson vẫn có nghĩa khi $s = 0$ (ví dụ 0/100 cho khoảng $[0;\, 3{,}7\%]$), trường hợp gặp ở thí nghiệm LIBERO.

2.7.5. Dự đoán có quyền từ chối

Trong *dự đoán có quyền từ chối* [10, 17], mô hình được phép không trả lời khi không chắc. Với một điểm tin cậy c_i và ngưỡng θ, mô hình chỉ trả lời các mẫu có $c_i \geq \theta$. Tỉ lệ mẫu được trả lời gọi là *độ phủ*; độ chính xác trên các mẫu được trả lời gọi là *độ chính xác có chọn lọc*. Một điểm tin cậy tốt làm độ chính xác có chọn lọc tăng khi độ phủ giảm. Với robot cộng tác, "không trả lời" tương ứng với chờ thêm hoặc hỏi lại người.

Chương 3. PHƯƠNG PHÁP ĐỀ XUẤT

Chương này mô tả phương pháp ở dạng cuối cùng: bài toán (Mục 3.1), kiến trúc tổng thể VLIA (Mục 3.2), mô-đun ý định (Mục 3.3), cơ chế trả lời có chọn lọc (Mục 3.4), token ý định trong SmolVLA (Mục 3.5), ý định biết trước dùng cho thí nghiệm robot (Mục 3.6) và phần cài đặt (Mục 3.7). Quá trình thực nghiệm dẫn tới từng lựa chọn thiết kế được trình bày ở Chương 4.

3.1. Phát biểu bài toán

Mỗi video gồm nhiều bước thao tác. Từ đoạn video của bước i lấy đều 8 khung hình $(x_{i,1}, \ldots, x_{i,8})$. Với $k \in \{2,4,6,8\}$, mô-đun ý định chỉ được xem k khung đầu $x_{i,1:k}$; k nhỏ nghĩa là robot phải đoán sớm hơn. Mô-đun có một hàm mã hóa video f và một hàm mã hóa câu g, và cho mỗi câu ứng viên c một điểm

$$s(i,c) = \cos\big(f(x_{i,1:k}),\, g(c)\big). \tag{3.1}$$

Câu có điểm cao nhất trong tập ứng viên $\mathscr{C}_i$ là ý định được chọn:

$$\hat{c}_i = \arg\max_{c \in \mathscr{C}_i} s(i,c). \tag{3.2}$$

Tập ứng viên chính gồm câu WHY đúng và 4 câu WHY khác *của cùng video*, nên các ứng viên có cùng khung cảnh và đồ vật, đúng tình huống robot gặp khi đứng cạnh một người đang làm một việc.

Ví dụ cụ thể

Video nhào bột, bước "positioning basin". Mô-đun xem 8 khung đầu (Hình 4.1) và phải chọn đúng câu này trong 5 câu: *positioning basin*, *add salt to flour*, *prepare to pour water into flour*, *clean the table surface*, *forming dough*. Cả 5 câu đều thuộc cùng video nhào bột, nên đồ vật và khung cảnh trong ảnh không đủ để phân biệt.

Phía robot, chính sách VLA nhận thêm vector ý định $\mathbf{z}^{\text{int}} = g(\hat{c}_i)$:

$$\hat{\mathbf{A}}_t = \pi_\theta\big(I_t,\, L,\, S_t,\, \mathbf{z}^{\text{int}}\big), \tag{3.3}$$

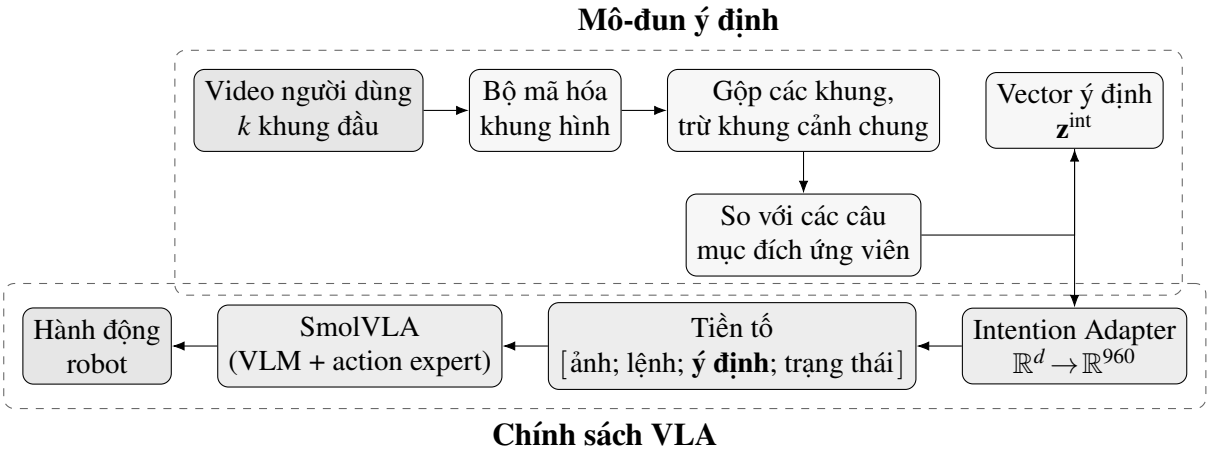
với I_t là ảnh camera robot, L là câu lệnh (có thể rỗng), S_t là trạng thái và $\hat{\mathbf{A}}_t$ là khối hành động sắp tới.

3.2. Kiến trúc tổng thể VLIA

Kiến trúc VLIA (Hình 3.1) gồm hai khối nối tiếp:

1. **Mô-đun ý định** đọc k khung đầu của video người và chọn câu mục đích; vector của câu được chọn là $\mathbf{z}^{\text{int}}$.
2. **SmolVLA** nhận $\mathbf{z}^{\text{int}}$ qua một lớp tuyến tính (Intention Adapter) dưới dạng một token, cùng với ảnh camera robot, câu lệnh và trạng thái, rồi sinh hành động.

Hai khối chỉ giao tiếp qua vector $\mathbf{z}^{\text{int}}$. Nhờ vậy có thể thay mô-đun ý định qua từng giai đoạn thực nghiệm mà không phải sửa SmolVLA, và có thể kiểm tra SmolVLA với ý định "biết trước" trước khi nối mô-đun ý định thật.



Hình 3.1. Kiến trúc VLIA. Mô-đun ý định (trên) chọn mục đích từ phần đầu video góc nhìn thứ nhất; vector của mục đích được đổi thành một token và chèn vào tiền tố của SmolVLA (dưới).

3.3. Mô-đun ý định

Mô-đun ý định ở dạng cuối cùng *không có tham số nào được huấn luyện*. Nó gồm bốn bước: mã hóa từng khung hình, gộp các khung, trừ khung cảnh chung, và so với các câu ứng viên viết theo câu mẫu. Mỗi bước có một vài lựa chọn; tổ hợp các lựa chọn tạo thành 90 cấu hình, và cấu hình cuối cùng được chọn bằng kiểm tra chéo lồng nhau (Mục 4.6).

3.3.1. Mã hóa khung hình và câu

Mỗi khung hình $x_{i,j}$ đi qua phần ảnh của một mô hình ảnh–văn bản, cho vector đã chuẩn hóa $\mathbf{v}_{i,j} = f_{\text{img}}(x_{i,j})/\|f_{\text{img}}(x_{i,j})\|$. Mỗi câu ứng viên c đi qua phần chữ của cùng mô hình, cho $\mathbf{t}_c$. Năm bộ mã hóa được xét: `siglip-base-patch16-224` [52] (gọi là *SigLIP cơ bản*, 768 chiều), `siglip-base-patch16-384`, `siglip2-base-patch16-224` [45], `siglip-so400m-patch14-384` [1] (gọi là *SigLIP lớn*, 1152 chiều) và `clip-vit-large-patch14` [35]. Mọi bộ mã hóa đều là bản công khai và được giữ nguyên.

3.3.2. Gộp các khung

Ba cách gộp k khung thành một điểm cho mỗi câu c được xét:

$$\text{Trung bình:} \quad s_{\text{mean}}(i,c) = \cos\left(\tfrac{1}{k}\textstyle\sum_{j=1}^{k}\mathbf{v}_{i,j},\ \mathbf{t}_c\right), \tag{3.4}$$

$$\text{Khung giống nhất:} \quad s_{\text{max}}(i,c) = \max_{j\le k}\ \cos(\mathbf{v}_{i,j},\mathbf{t}_c), \tag{3.5}$$

$$\text{Trung hòa:} \quad s_{\text{lse}}(i,c) = \beta\log\textstyle\sum_{j=1}^{k}\exp\left(\cos(\mathbf{v}_{i,j},\mathbf{t}_c)/\beta\right), \quad \beta = 0{,}02. \tag{3.6}$$

Lấy trung bình là mốc chuẩn trong nhận dạng hành động từ video [49]; khung giống nhất phù hợp khi chỉ một khoảnh khắc mang thông tin; cách trung hòa nằm giữa hai cách trên.

3.3.3. Trừ khung cảnh chung

Mọi bước của một video có cùng khung cảnh, đồ vật và đôi tay, nên phần lớn vector ảnh giống nhau giữa các bước (Mục 2.6). Ba cách xử lý vector ảnh trước khi so sánh được xét:

- **Không xử lý.**
- **Trừ trung bình chung**: trừ vector ảnh trung bình và vector chữ trung bình, tính trên các nhóm huấn luyện, rồi chuẩn hóa lại. Đây là cách bù "khoảng cách giữa hai miền" [25].
- **Trừ khung cảnh của các bước trước**: với bước i thuộc video V, lấy trung bình mọi

khung hình của các bước *trước i* trong cùng video,

$$\bar{\mathbf{v}}_{<i} = \frac{1}{|\mathscr{P}_i|} \sum_{(i',j)\in\mathscr{P}_i} \mathbf{v}_{i',j}, \qquad \mathscr{P}_i = \{(i',j) : i' \in V,\ i' < i\}, \tag{3.7}$$

rồi thay mỗi $\mathbf{v}_{i,j}$ bằng $(\mathbf{v}_{i,j} - \bar{\mathbf{v}}_{<i})/\|\mathbf{v}_{i,j} - \bar{\mathbf{v}}_{<i}\|$. Với bước đầu tiên của video (khoảng 1% số bước), chưa có bước trước, nên dùng cách trừ trung bình chung thay thế.

Trực giác của bước trừ khung cảnh chung

Trong video nhào bột, khung nào cũng có cái bàn, cái chậu, đôi tay và bột, nên mọi câu "về nhào bột" đều khớp gần như ngang nhau. Trừ đi trung bình của các bước *đã xảy ra trước đó* giống như hỏi "khung hình bây giờ *khác gì* so với những gì đã thấy?". Phần còn lại là cái mới của bước hiện tại, thứ phân biệt các mục đích. Cách này giống ý tưởng hiệu chỉnh theo "đầu vào rỗng" [57], nhưng chỉ dùng quá khứ, nên robot làm được khi đang chạy thật.

3.3.4. Câu mẫu và cấu hình đề xuất

Câu WHY được dùng theo hai cách: nguyên câu, hoặc bọc trong câu mẫu "`a first-person photo of a person doing: {why}`", theo cách CLIP dùng câu mẫu cho phân loại không huấn luyện [35].

Tổ hợp 5 bộ mã hóa $\times$ 3 cách gộp $\times$ 3 cách xử lý $\times$ 2 cách viết câu cho 90 cấu hình. Qua chọn lồng nhau (Mục 4.6), cấu hình được chọn ở cả 8/8 lần kiểm tra chéo là: **SigLIP lớn, lấy trung bình, trừ khung cảnh của các bước trước, dùng câu mẫu**. Đồ án gọi đây là **cấu hình đề xuất**, và gọi cấu hình *SigLIP cơ bản, lấy trung bình, không xử lý, nguyên câu* là **cấu hình cơ bản**. Với cấu hình đề xuất, $\mathbf{z}^{\text{int}} \in \mathbb{R}^{1152}$.

3.4. Trả lời có chọn lọc

Robot không nhất thiết phải hành động ngay. Mô-đun ý định tính độ chắc chắn bằng *độ chênh* giữa điểm của câu cao nhất và câu thứ hai trong tập ứng viên:

$$m_i = s(i, c_{(1)}) - s(i, c_{(2)}), \tag{3.8}$$

với $c_{(1)}, c_{(2)}$ là hai câu có điểm cao nhất. Với một ngưỡng θ, mô-đun chỉ trả lời khi $m_i \geq \theta$; khi $m_i < \theta$, robot chờ thêm khung hình hoặc hỏi lại người [10, 17]. Ngưỡng cho

mỗi nhóm kiểm tra được tính từ các nhóm khác, nên độ phủ đạt được trên nhóm kiểm tra là một ước lượng trung thực. Một điểm tin cậy dạng xác suất (softmax của điểm trên 5 ứng viên) cũng được so sánh.

3.5. Token ý định trong SmolVLA

3.5.1. Intention Adapter và vị trí chèn

Vector ý định $\mathbf{z}^{\text{int}} \in \mathbb{R}^d$ được đổi về kích thước 960 chiều của SmolVLA bằng một lớp tuyến tính:

$$\mathbf{e}^{\text{int}} = \mathbf{W}\mathbf{z}^{\text{int}} + \mathbf{b}, \qquad \mathbf{W} \in \mathbb{R}^{960\times d},\ \mathbf{b} \in \mathbb{R}^{960}, \tag{3.9}$$

rồi được chèn vào tiền tố công thức (2.2) ngay sau câu lệnh, trước trạng thái robot:

$$P_{\text{VLIA}} = \left[E_{\text{ảnh}};\ E_{\text{lệnh}};\ \mathbf{e}^{\text{int}};\ E_{\text{trạng thái}}\right]. \tag{3.10}$$

Nếu tiền tố gốc dài L token thì tiền tố mới dài đúng $L+1$. Vị trí chèn được tính từ cuối tiền tố (trước token trạng thái), nên không phụ thuộc số camera hay độ dài câu lệnh. Với cấu hình đề xuất ($d = 1152$), adapter có $1152 \times 960 + 960 = 1.106.880$ tham số.

3.5.2. Mặt nạ chú ý

Token ý định được đánh dấu là token hợp lệ (không phải phần đệm) và được đặt vào cùng loại khối chú ý với token trạng thái: nó nhìn được ảnh và câu lệnh, và các token hành động nhìn được nó. Như vậy action expert đọc ý định cùng với các thông tin điều kiện khác của bước điều khiển.

3.5.3. Huấn luyện và suy luận

Khi huấn luyện, hàm mất mát flow matching công thức (2.4) giữ nguyên; chỉ tiền tố đổi từ P_{base} sang P_{VLIA}. Gradient đi từ mất mát qua token ý định tới adapter:

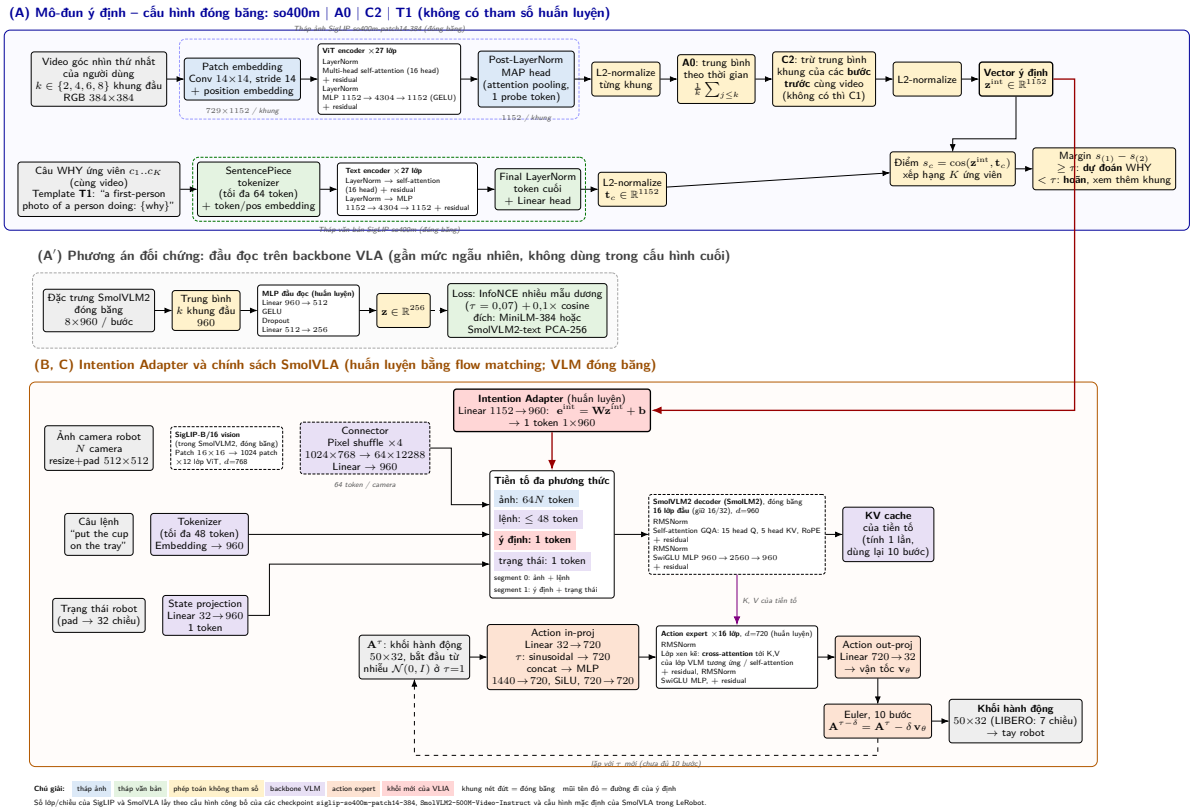
$$\mathscr{L}_{\text{action}} \to \mathbf{e}^{\text{int}} \to (\mathbf{W}, \mathbf{b}), \tag{3.11}$$

nên adapter học từ chính nhiệm vụ điều khiển. Khi suy luận, token ý định được thêm vào tiền tố *trước* khi tiền tố đi qua backbone và trước khi bộ nhớ đệm khóa–giá trị được tạo (Mục 2.2). Mười bước tinh chỉnh của action expert vì vậy đều đọc được ý định mà

không phải tính lại tiền tố; chi phí thêm chỉ là một token trong một lần tính tiền tố.

3.5.4. Tương thích với SmolVLA gốc

Một cờ cấu hình bật hoặc tắt token ý định. Khi tắt cờ, hoặc khi lô dữ liệu không có ý định, tiền tố quay về đúng dạng công thức (2.2) và kết quả trùng khớp hoàn toàn với SmolVLA gốc. Nhờ vậy chính sách gốc và chính sách có ý định dùng chung một đường mã, nên mọi khác biệt trong thí nghiệm chỉ đến từ token ý định. Hình 3.2 vẽ chi tiết toàn hệ thống với cấu hình đề xuất.



Hình 3.2. Sơ đồ chi tiết hệ thống VLIA với cấu hình đề xuất ($d = 1152$)**. Đường đi của thông tin ý định tô đỏ; khối viền nét đứt được đóng băng.**

3.6. Ý định biết trước cho thí nghiệm robot

LIBERO [28] không có video của người và không có nhãn ý định. Để kiểm tra riêng câu hỏi "chính sách có dùng được ý định hay không", tách khỏi lỗi của mô-đun ý định, đồ án xây dựng một tín hiệu ý định *biết trước* (oracle) theo từng giai đoạn của mỗi lượt minh họa:

1. **Chia giai đoạn.** Trong dữ liệu minh họa LIBERO-10, các lần đóng/mở tay kẹp được dùng làm ranh giới giai đoạn (ví dụ "tiếp cận", "gắp", "mang tới đích", "thả"). Sau khi lọc nhiễu, chỉ giữ các lượt có số lần chuyển trạng thái khớp với mẫu chuẩn của nhiệm vụ: còn **335/379 lượt**, tương ứng **88.302 khung hình** huấn luyện.
2. **Gán câu mục đích.** Mỗi giai đoạn của mỗi nhiệm vụ được gán một câu mục đích viết theo mẫu, tổng cộng **38 câu** khác nhau. Mỗi câu được mã hóa một lần bằng phần chữ của SmolVLM2, cho bảng 38×960; mỗi khung hình ánh xạ tới đúng một câu.
3. **Đệm hành động theo giai đoạn.** SmolVLA học khối 50 bước hành động. Kiểm tra cho thấy **58,25%** điểm bắt đầu có khối hành động đi qua ranh giới giai đoạn, tức ý định hiện tại phải "giải thích" cả hành động của giai đoạn sau. Đồ án đệm các bước sau ranh giới bằng hành động hợp lệ cuối cùng của giai đoạn hiện tại và đánh dấu chúng là phần đệm, giống cách LeRobot đệm ở cuối lượt; mất mát chỉ tính trên các bước hợp lệ.

Hai nhánh, SmolVLA gốc và SmolVLA có ý định biết trước, dùng cùng 88.302 khung hình, cùng phép đệm, cùng tiền xử lý, bộ tối ưu, lịch học, hạt giống và khởi tạo; khác biệt duy nhất là token ý định. Ý định biết trước là một phép chẩn đoán có đặc quyền, không phải ý định thật của người.

3.7. Cài đặt hệ thống

3.7.1. Môi trường và tổ chức mã nguồn

Hệ thống được cài đặt bằng Python 3.12 và PyTorch, trên thư viện LeRobot [6] và Hugging Face Transformers. Mã nguồn chia thành ba phần:

- `policies/intention/`: lớp `IntentionAdapter` và các bộ mã hóa ý định có huấn luyện dùng ở giai đoạn 0–1.
- `policies/smolvla/`: bản mở rộng của SmolVLA. Cấu hình thêm hai trường `use_intention_token` và `intention_dim`; mô hình flow matching thêm ba đường xử lý có ý định (tạo tiền tố, huấn luyện, sinh hành động); lớp chính sách đọc ý định từ lô dữ liệu theo khóa `intention` và chuyển xuống mô hình. Phần mở rộng được tách khỏi mã gốc của LeRobot để không sửa trực tiếp mã gốc.
- `scripts/`: các kịch bản trích đặc trưng, chạy từng giai đoạn thực nghiệm, đánh giá

và vẽ bảng.

Chính sách có ý định được khởi tạo trực tiếp với mô hình flow matching đã mở rộng, thay vì tạo SmolVLA gốc rồi thay thế, nên backbone chỉ được nạp một lần.

3.7.2. Đường dữ liệu và tính tái lập

Mỗi bước EgoIntent được giải mã một lần, lấy đều 8 khung RGB và lưu đặc trưng của mọi bộ mã hóa trên cùng các khung này. Mã băm SHA1 của khung hình được kiểm tra ở mỗi lần chạy sau để bảo đảm mọi cấu hình dùng đúng cùng đầu vào. Với mỗi giai đoạn, tiêu chí đạt/không đạt được ghi vào một tệp trong kho mã trước khi chạy. Cấu hình đề xuất được ghi cố định vào tệp `FROZEN.json` kèm mã băm trước khi đọc tập test riêng; kịch bản đánh giá tập test từ chối chạy nếu kết quả đã tồn tại.

3.7.3. Kiểm thử cài đặt

Các kiểm thử được chạy với ba kích thước ý định $d \in \{256, 768, 1152\}$ trên một SmolVLA có cùng kiến trúc với checkpoint LIBERO 7 chiều, khởi tạo ngẫu nhiên (Bảng 3.1). Tất cả đều đạt: tiền tố dài từ 77 lên 78 token; bộ nhớ đệm chứa 78 vị trí khi có ý định và 77 khi không; gradient tại adapter khác 0 (chuẩn 0,077; 0,130; 0,165 cho ba kích thước); sai khác lớn nhất khi tắt cờ và khi lưu/tải lại đều bằng 0. Đây là bằng chứng cài đặt đúng, chưa phải bằng chứng robot làm tốt hơn.

Bảng 3.1. Kiểm thử cài đặt token ý định trong SmolVLA ($d \in \{256, 768, 1152\}$).

Thành phần	Nội dung kiểm tra	Kết quả
Intention Adapter	Gradient truyền ngược được qua adapter	Đạt
Độ dài tiền tố	Tiền tố dài thêm đúng 1 token ($77 \rightarrow 78$)	Đạt
Vị trí token	Token ý định nằm ngay trước token trạng thái	Đạt
Bộ nhớ đệm	Token ý định có mặt trong KV cache khi suy luận	Đạt
Hàm mất mát	Mất mát flow matching hữu hạn	Đạt
Tắt ý định	Kết quả giống hệt SmolVLA gốc khi tắt cờ	Đạt
Lưu/tải	Lưu và tải lại checkpoint không sai khác	Đạt

Ngoài ra, đường huấn luyện ý định biết trước (Mục 3.6) được kiểm tra riêng (Bảng 3.2): 500 tensor dùng chung giữa SmolVLA gốc và SmolVLA có ý định giống hệt nhau sau khởi tạo; phiên bản có ý định chỉ thêm 922.560 tham số của adapter ($960 \times 960 + 960$); cả hai nhánh huấn luyện xuôi–ngược được trên cùng một lô và lưu

checkpoint thành công.

Bảng 3.2. Kiểm tra đường huấn luyện với ý định biết trước trên LIBERO-10.

Hạng mục	Kết quả
Số lượt minh họa giữ lại	335/379
Số khung hình huấn luyện	88.302
Số câu mục đích khác nhau	38
Tensor dùng chung khớp sau khởi tạo	500/500
Tham số thêm của adapter	922.560
Đệm hành động theo giai đoạn	Đạt
Tiền xử lý giống nhau giữa hai nhánh	Đạt
Huấn luyện xuôi–ngược trên cùng lô	Đạt
Gradient tại adapter	> 0
Lưu checkpoint	Đạt

Chương 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ

Chương này trình bày dữ liệu và cách đánh giá dùng chung (Mục 4.1), lộ trình thực nghiệm (Mục 4.2), rồi lần lượt bảy giai đoạn theo thứ tự đã thực hiện (Mục 4.3–Mục 4.9). Mỗi giai đoạn bắt đầu bằng một câu hỏi, sau đó là cách làm, kết quả, và kết luận dẫn tới giai đoạn sau. Chương kết thúc bằng phần tổng hợp và thảo luận.

4.1. Dữ liệu và thiết lập thực nghiệm

4.1.1. Dữ liệu EgoIntent

EgoIntent [14] được xây dựng từ video Ego4D [18]. Mỗi video là một hoạt động (nhào bột, sửa xe đạp, hái quả…) được chia thành các bước ngắn; mỗi bước kết thúc *trước* khi kết cục xảy ra (Hình 4.1).



Hình 4.1. Tám khung hình của một bước trong EgoIntent (bếp, nhào bột). WHAT: "grasping basin"; WHY: "positioning basin". Các khung màu là khung phát hiện bàn tay do công cụ hiển thị của đồ án vẽ lên; mô-đun ý định không dùng chúng.

Đồ án dùng phần huấn luyện và kiểm định của bản đầy đủ, gồm 2.503 bước (Bảng 4.1), cho mọi giai đoạn phát triển. Phần test của bộ dữ liệu được giữ riêng (Mục 4.1.2).

Các khung cảnh gồm xưởng mộc, bếp, gara, trang trại, phòng khách, phòng ngủ, xưởng vẽ, tủ quần áo, hiên nhà, hành lang, phòng giặt, sân và ngoài trời. Gần như mọi câu WHY là duy nhất, nên mô hình không thể học thuộc một danh sách nhãn mà phải so ý nghĩa giữa video và câu.

Bảng 4.1. Dữ liệu dùng để phát triển mô-đun ý định (phần train + val của EgoIntent).

Thuộc tính	Giá trị
Số bước thao tác	2.503
Số video	27
Số khung cảnh	13
Số câu WHY khác nhau	2.032
Số bước mỗi video	19 – 125
Số khung lấy đều mỗi bước	8

4.1.2. Cách đánh giá

Phép đo chính: chọn 1 trong 5. Với mỗi bước, tập ứng viên gồm câu đúng và 4 câu WHY *khác của cùng video*. Đoán mò đúng 20%. Bộ câu nhiễu được cố định theo mã của bước, nên giống hệt nhau giữa mọi giai đoạn. Đây là phép đo sát với robot cộng tác nhất, vì các ứng viên có cùng khung cảnh và đồ vật.

Phép đo phụ: MRR toàn tập. Câu đúng được xếp hạng giữa *mọi* câu WHY trong nhóm kiểm tra (vài trăm câu). MRR [48] là trung bình của $1/\text{thứ hạng}$: đứng đầu được 1 điểm, thứ hai được 0,5, thứ mười được 0,1. Vì MRR tuyệt đối phụ thuộc số câu, đồ án báo cáo thêm *số lần gấp mức ngẫu nhiên*: 1 nghĩa là ngang đoán mò.

Kiểm tra chéo theo khung cảnh. Robot phải dùng được ở nơi chưa từng thấy. Vì vậy 13 khung cảnh được chia thành 8 nhóm có số bước gần bằng nhau. Mỗi lần, một nhóm được giữ lại để kiểm tra và 7 nhóm còn lại dùng để huấn luyện hoặc để chọn cấu hình; lặp lại 8 lần. Mỗi bước được đánh giá đúng một lần, trên khung cảnh mà mô hình chưa thấy. Chia theo nhóm như vậy tránh việc các bước giống nhau của cùng một nơi rơi vào cả hai phía, vốn làm kết quả lạc quan giả tạo [40].

Tập test riêng. Phần test của EgoIntent, sau khi bỏ một video từng dùng trong thử nghiệm ban đầu, còn 407 bước từ 4 video. Tập này không dùng trong lúc phát triển và chỉ chạy *một lần* cho cấu hình cuối cùng (Mục 4.7).

Khoảng tin cậy. Các bước trong cùng video có chung người, khung cảnh và ánh sáng, nên không độc lập. Khoảng tin cậy 95% được tính bằng *bootstrap theo video* [13, 15]: lấy mẫu lại cả video, tính lại kết quả 10.000 lần. Khi so hai cách trên cùng các bước, đồ án tính hiệu trên từng bước rồi mới bootstrap (hiệu ghép cặp). Một kết quả được coi là "rõ ràng" khi cả khoảng tin cậy nằm về một phía (trên mức ngẫu nhiên, hoặc trên

0 với hiệu).

Ngưỡng đạt đặt trước. Trước mỗi giai đoạn, tiêu chí đạt/không đạt được ghi vào kho mã, để kết luận không bị ảnh hưởng bởi số liệu vừa thấy. Ngưỡng thực dụng cho mô-đun ý định là **30%** chọn đúng trong 5 câu.

4.1.3. Thiết lập phía robot

Thí nghiệm phía robot dùng LIBERO-10 [28], bộ 10 nhiệm vụ thao tác dài trong mô phỏng, mỗi nhiệm vụ có một câu lệnh tiếng Anh (Bảng PL.3). SmolVLA được huấn luyện 25.000 bước với hành động 7 chiều, kích thước lô 32, tốc độ học 10^{-4}, khởi động 1.000 bước rồi giảm theo hàm cosine. Mỗi lượt đánh giá chạy tối đa 520 bước điều khiển; một lượt thành công khi môi trường báo hoàn thành nhiệm vụ. Tỉ lệ thành công được báo cáo kèm khoảng Wilson 95% (Mục 2.7).

4.2. Lộ trình thực nghiệm

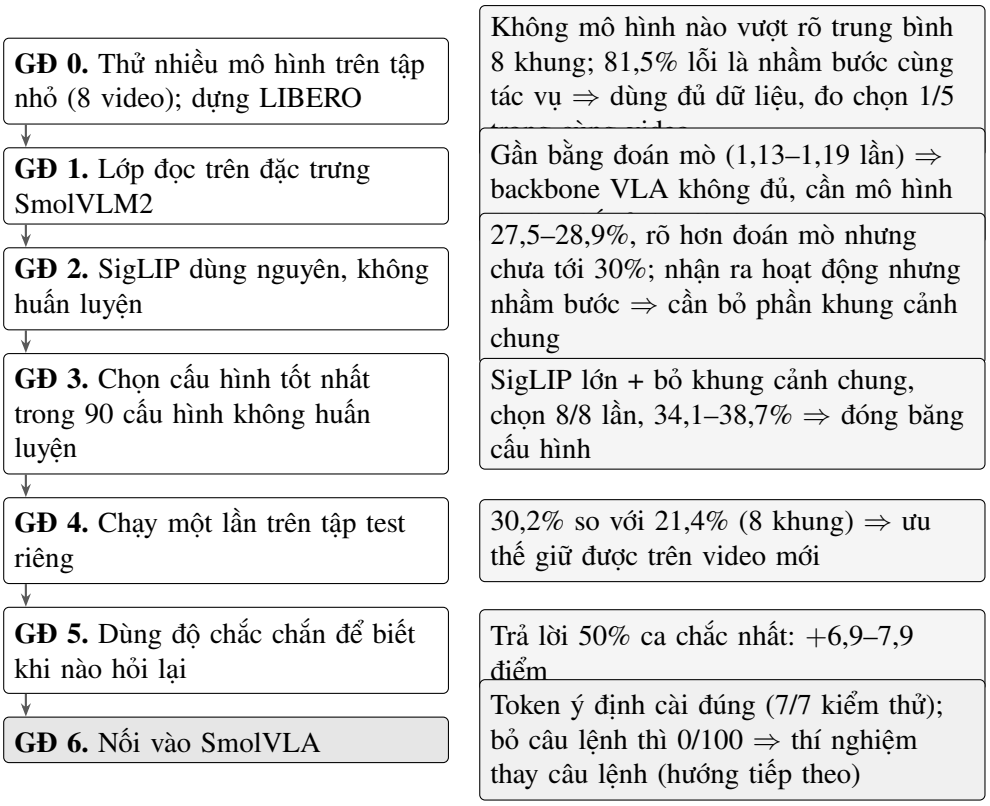
Hình 4.2 tóm tắt toàn bộ quá trình. Giai đoạn 0 là thử nghiệm ban đầu trên tập nhỏ, trước khi đồ án tập trung hẳn vào bài toán đoán ý định; giai đoạn 1–5 xây dựng và đánh giá mô-đun ý định trên toàn bộ dữ liệu; giai đoạn 6 nối mô-đun vào SmolVLA.

4.3. Giai đoạn 0: Thử nghiệm ban đầu trên tập nhỏ

Trước khi tập trung hẳn vào bài toán đoán ý định, đồ án đi theo kế hoạch ban đầu: vừa xây bộ dự đoán ý định có huấn luyện, vừa chuẩn bị thí nghiệm trên robot mô phỏng (LIBERO). Giai đoạn này gồm bốn thí nghiệm trên cùng một tập nhỏ, một phân tích lỗi, và phần chuẩn bị phía robot. Mỗi thí nghiệm kiểm tra một ý tưởng lấy từ tài liệu; kết quả của nó quyết định thí nghiệm tiếp theo. Kết luận chung (Mục 4.3.8) giải thích vì sao các giai đoạn sau được thiết kế như vậy.

4.3.1. Thiết lập chung

Tập thử gồm 8 video EgoIntent [14]: 6 video trong nhà (556 bước) để huấn luyện và 2 video ngoài trời (215 bước) để kiểm định; không video nào nằm ở cả hai phía. Mỗi khung hình được mã hóa bằng phần ảnh của SmolVLM2 [31] thành vector 960 chiều. Mô hình được huấn luyện để vector của đoạn video nằm gần vector của câu WHY đúng. Câu WHY đúng được xếp hạng giữa mọi câu WHY của tập kiểm định, và kết quả được



Hình 4.2. Các giai đoạn thực nghiệm của đồ án. Mỗi hàng: việc đã làm (trái) và kết quả cùng quyết định cho giai đoạn sau (phải).

tóm bằng MRR (trung bình của $1/$thứ hạng, 48). Xếp hạng ngẫu nhiên cho MRR 0,0420. Mọi số trong mục này đều đo trên cùng 215 bước kiểm định đó, và là trung bình $\pm$ độ lệch chuẩn qua 3–4 lần chạy với hạt giống ngẫu nhiên khác nhau, trừ khi ghi khác.

4.3.2. Thí nghiệm 0A: Học biểu diễn như thế nào, từ đầu vào nào

Câu hỏi. Hàm mất mát nào đưa được video về gần câu mục đích đúng, và mô hình nên nhận những đầu vào nào?

Cách làm. Cách đơn giản nhất là ép vector dự đoán gần câu đúng bằng mất mát cosine. Tài liệu về học biểu diễn cảnh báo rằng nếu chỉ kéo cặp đúng lại gần mà không đẩy cặp sai ra xa, mô hình có thể trả về cùng một vector cho mọi đầu vào [50]. Cách thay thế là học tương phản InfoNCE [33] (công thức (2.6)), ở dạng nhiều câu đúng cho một mẫu [22], vì nhiều bước có cùng câu WHY. Đồ án so hai hàm mất mát, rồi với InfoNCE so các tổ hợp đầu vào: ảnh, tên tác vụ, và lịch sử các bước trước (lấy từ nhãn).

Kết quả. Với mất mát cosine, độ tương đồng giữa dự đoán và câu đúng đạt 0,795, tưởng là tốt; nhưng MRR chỉ 0,0282, *thấp hơn xếp hạng ngẫu nhiên* (Bảng 4.2). Độ

Bảng 4.2. Thí nghiệm 0A: hàm mất mát và đầu vào (215 bước kiểm định).

Hàm mất mát	Đầu vào	MRR
—	Xếp hạng ngẫu nhiên	0,0420
Cosine (1 hạt giống)	Ảnh + tác vụ + lịch sử	0,0282
InfoNCE	Lịch sử	$0{,}0524 \pm 0{,}0032$
InfoNCE	Ảnh	$0{,}0540 \pm 0{,}0017$
InfoNCE	Ảnh + lịch sử	$0{,}0591 \pm 0{,}0031$
InfoNCE	Ảnh + tác vụ + lịch sử	$0{,}0607 \pm 0{,}0020$

tương đồng trung bình giữa các câu WHY với nhau đã là 0,68, nên một vector "trung bình" cũng gần mọi câu; mô hình học đúng vector đó và không phân biệt được gì. Với InfoNCE, mọi cấu hình đều vượt mức ngẫu nhiên. Thêm lịch sử bước cho MRR cao nhất (0,0607), nhưng lịch sử lấy từ nhãn do người ghi, robot thật không có.

Kết luận. Hiện tượng sụp đúng như tài liệu cảnh báo, nên mọi thí nghiệm sau dùng học tương phản. Đầu vào được giữ là **chỉ ảnh** (MRR 0,0540), vì đó là thứ duy nhất robot có khi chạy thật.

4.3.3. Thí nghiệm 0B: Có cần mô hình hóa thứ tự khung hình không

Câu hỏi. Lấy trung bình các khung bỏ qua thứ tự thời gian. Một mô hình đọc khung theo thứ tự có đoán mục đích tốt hơn không?

Cách làm. Lấy trung bình đặc trưng các khung là mốc so sánh chuẩn trong nhận dạng hành động từ video [49]. Đồ án so nó với bốn mô hình có thứ tự: một lớp chú ý theo thời gian (350 nghìn tham số), một Transformer [47] (2,2 triệu tham số), mạng hồi quy GRU [9], và trung bình kèm độ thay đổi giữa các khung liên tiếp.

Kết quả. Lấy trung bình cao nhất trong cả hai nhóm so sánh (Bảng 4.3). Transformer, mô hình lớn nhất, thấp nhất (0,0408, gần mức ngẫu nhiên): với 556 mẫu huấn luyện, nó học thuộc tập huấn luyện thay vì học điều tổng quát.

Kết luận. Với lượng dữ liệu này, thêm tham số để đọc thứ tự khung làm kết quả kém đi. Điều này phù hợp với quan sát của chính EgoIntent rằng xem thêm lịch sử dài không giúp đoán mục đích [14]. Đồ án giữ **lấy trung bình các khung** cho mọi giai đoạn sau.

Bảng 4.3. Thí nghiệm 0B: gộp khung hình (đầu vào chỉ ảnh, 215 bước kiểm định).

Cách gộp các khung	MRR
Cùng một hạt giống, vector 256 chiều	
Lấy trung bình	0,0542
Chú ý theo thời gian	0,0516
Transformer	0,0408
3 hạt giống, 8 khung	
Lấy trung bình	$\mathbf{0{,}0589 \pm 0{,}0016}$
GRU	$0{,}0525 \pm 0{,}0066$
Trung bình + độ thay đổi giữa khung	$0{,}0480 \pm 0{,}0019$

4.3.4. Thí nghiệm 0C: Dùng hành động (WHAT) để đoán mục đích (WHY)

Câu hỏi. EgoIntent gán ba tầng nhãn: hành động nhìn thấy (WHAT), mục đích (WHY) và bước tiếp theo (NEXT) [14]. Nếu mô hình biết người đang làm gì, có đoán mục đích tốt hơn không?

Cách làm. Đồ án thử hai cách dùng WHAT. Cách thứ nhất là *học phụ*: thêm nhánh đoán WHAT và NEXT bên cạnh nhánh đoán WHY, với hy vọng nhánh phụ giúp biểu diễn chung tốt hơn [7]. Cách thứ hai là *dẫn đường*: đưa dự đoán WHAT vào thẳng đường tính WHY. Trên cách thứ hai, đồ án thêm lần lượt hai cải tiến: *mẫu âm khó*, tức câu sai thuộc cùng tác vụ, vốn được chứng minh giúp học tương phản [41]; và một bộ xếp hạng lại nhỏ, huấn luyện sau khi đóng băng mô hình chính. Cuối cùng, để biết giới hạn trên của hướng này, đồ án cho mô hình dùng WHAT *đúng* lấy từ nhãn. Đây chỉ là phép chẩn đoán, vì robot không có nhãn.

Kết quả. Học phụ không giúp: ở hạt giống 0, MRR tăng lên 0,0571, nhưng trung bình 3 hạt giống (0,0551) ngang với chỉ học WHY (0,0556) (Bảng 4.4); giảm trọng số nhánh phụ cũng cho 0,0551. Dẫn đường cho mức tăng lặp lại được: từ 0,0475 lên 0,0551 sau hai cải tiến, cao hơn đoán thẳng khoảng 16%. Hơn mười biến thể khác (nhánh WHAT lớn hơn, học theo mô hình dùng WHAT đúng, cổng theo độ tin cậy, huấn luyện chung hai đầu ra) đều không tốt hơn. Khi biết WHAT đúng, MRR tăng gấp đôi (0,1055).

Kết luận. Thông tin về hành động *có* giúp đoán mục đích, như phép chẩn đoán cho thấy; nhưng dự đoán WHAT từ dữ liệu nhỏ quá kém để khai thác được phần lớn lợi ích đó. Quan trọng hơn, cấu hình tốt nhất (0,0551) vẫn *không vượt* cách lấy trung bình 8 khung ở thí nghiệm 0B (0,0589). Ví dụ ở hạt giống 0 cũng cho thấy chênh lệch giữa các

Bảng 4.4. Thí nghiệm 0C: dùng WHAT để đoán WHY (3 hạt giống, 215 bước kiểm định).

Cấu hình	MRR
Học phụ	
Chỉ học WHY	$0{,}0556 \pm 0{,}0051$
WHY + WHAT + NEXT (hạt giống 0 riêng: 0,0571)	$0{,}0551 \pm 0{,}0044$
Dẫn đường	
Đoán thẳng WHY	$0{,}0475 \pm 0{,}0061$
WHAT dẫn đường cho WHY	$0{,}0518 \pm 0{,}0015$
+ mẫu âm khó cùng tác vụ	$0{,}0540 \pm 0{,}0023$
+ bộ xếp hạng lại	$0{,}0551 \pm 0{,}0009$
WHAT đúng từ nhãn (chỉ để chẩn đoán)	$0{,}1055 \pm 0{,}0067$

cấu hình nhỏ hơn dao động giữa các lần chạy; chọn cấu hình theo một lần chạy dễ dẫn tới kết luận sai [4].

4.3.5. Thí nghiệm 0D: Học thêm từ video góc nhìn thứ ba

Câu hỏi. Robot nhìn người từ bên ngoài, không phải từ mắt người. Học cách ghép video góc nhìn thứ nhất với góc nhìn thứ ba của cùng thao tác, như hướng nghiên cứu của Ego-Exo4D [19], có giúp đoán mục đích không?

Cách làm. Trên ENIGMA-360 [37], bộ dữ liệu có cặp video hai góc nhìn quay cùng lúc, đồ án dùng 433 cặp đoạn video từ 5 video. Mô hình được huấn luyện để ghép đúng đoạn nhìn thứ nhất với đoạn nhìn thứ ba tương ứng, rồi dùng làm điểm khởi đầu để huấn luyện đoán WHY trên EgoIntent. Mốc so sánh là cùng kiến trúc nhưng khởi tạo ngẫu nhiên.

Kết quả. Mô hình học ghép cặp được trên video chưa thấy (MRR ghép cặp $0{,}118 \pm 0{,}006$ theo chiều thứ nhất sang thứ ba và $0{,}100 \pm 0{,}010$ theo chiều ngược lại). Nhưng khi dùng làm điểm khởi đầu, MRR đoán WHY chỉ đạt $0{,}0345 \pm 0{,}0004$, thấp hơn khởi tạo ngẫu nhiên ($0{,}0476 \pm 0{,}0045$). Huấn luyện chung hai mục tiêu cũng không cải thiện.

Kết luận. Thứ mô hình học được khi ghép hai góc nhìn (cùng đồ vật, cùng thời điểm) không phải thứ cần để phân biệt mục đích, và còn làm hại. Hướng này dừng ở mức chẩn đoán.

4.3.6. Phân tích lỗi: mô hình sai ở đâu

Sau bốn thí nghiệm, câu hỏi tự nhiên là: mô hình tốt nhất đang sai theo kiểu nào? Với mô hình lấy trung bình 8 khung, 510 trên 626 lần đoán sai câu đứng đầu (**81,5%**) là chọn nhầm sang mục đích của *một bước khác trong cùng tác vụ*. Mô hình nhận ra người đang làm hoạt động gì (nhào bột, rửa bát), nhưng không phân biệt được người đang ở bước nào và định làm gì tiếp. Đây chính là phần khó của bài toán, và cũng là phần robot cộng tác cần nhất: biết người đang nhào bột chưa đủ, robot cần biết người sắp đổ nước hay sắp rắc muối.

4.3.7. Chuẩn bị phía robot

Song song, đồ án dựng thí nghiệm trên LIBERO-10 [28], huấn luyện SmolVLA [43] trong cùng điều kiện có và không có ý định biết trước (Mục 3.6). Khi kiểm tra lại checkpoint, đồ án phát hiện hai lần huấn luyện 25.000 bước đầu tiên đã lưu hành động 6 chiều và thiếu một camera rỗng, trong khi LIBERO dùng hành động 7 chiều. Cả hai lần chạy bị loại. Sau khi sửa và thêm kiểm tra bắt buộc về kích thước, SmolVLA huấn luyện lại đạt **24/100** lượt thành công trong lần đánh giá chuẩn đầu tiên. Với đường huấn luyện ý định biết trước (Mục 3.6), đồ án chạy thử 500 bước cho cả hai nhánh với cùng hạt giống (Bảng 4.5). Nhánh có ý định có mất mát trung bình 100 bước cuối thấp hơn khoảng 3,2%, và adapter vẫn nhận gradient ở bước 500. Đây chỉ cho thấy mô hình dùng được tín hiệu thêm vào, chưa phải bằng chứng robot làm tốt hơn.

Bảng 4.5. Chạy thử 500 bước trên LIBERO-10, hạt giống 0: SmolVLA gốc và SmolVLA có ý định biết trước.

Nhánh	Mất mát cuối	Mất mát TB 100 bước cuối	Thời gian (s)	Gradient adapter
SmolVLA gốc	0,5329	0,5839	632,8	–
Có ý định biết trước	0,5162	0,5653	635,7	1,076

Checkpoint 24/100 là checkpoint được dùng ở giai đoạn 6.

4.3.8. Kết luận giai đoạn 0

Kết luận giai đoạn 0

Bằng chứng. (i) Không mô hình huấn luyện nào vượt rõ cách lấy trung bình 8 khung (0,0589), và tất cả chỉ cao hơn xếp hạng ngẫu nhiên 1,3–1,4 lần (thí nghiệm 0A–0D). (ii) Chênh lệch giữa các cấu hình nhỏ hơn dao động giữa các lần chạy (thí nghiệm 0C). (iii) 81,5% lỗi là nhầm bước trong cùng tác vụ (Mục 4.3.6).

Kết luận. Trên tập này, không thể nói cấu hình nào thật sự tốt hơn: tập kiểm định chỉ có 2 video, mọi lựa chọn đều làm trên chính tập đó, và phép đo xếp hạng giữa mọi câu không đo đúng phần khó.

Quyết định. Theo góp ý của giảng viên hướng dẫn, đồ án tập trung hẳn vào bài toán đoán ý định và đổi cách làm: (i) dùng toàn bộ 2.503 bước với kiểm tra chéo theo khung cảnh và một tập test riêng (Mục 4.1.2); (ii) thêm phép đo chọn 1 trong 5 mục đích *của cùng video*, nhắm thẳng vào lỗi nhầm bước; (iii) giữ mô hình đơn giản nhất (lấy trung bình các khung) làm điểm xuất phát cho giai đoạn 1.

4.4. Giai đoạn 1: Lớp đọc trên đặc trưng của backbone VLA

Câu hỏi. SmolVLA đã "nhìn" ảnh qua backbone SmolVLM2. Đặc trưng của backbone này có chứa đủ thông tin để đoán mục đích của người không?

Cách làm. Mỗi khung hình đi qua SmolVLM2-500M-Video-Instruct [59] (đóng băng, không cập nhật trọng số), cho một vector 960 chiều. Lấy trung bình k khung đầu, rồi đưa qua một lớp đọc hai lớp (lớp ẩn 512 chiều):

$$\mathbf{z}_i = \mathrm{MLP}\left(\tfrac{1}{k}\textstyle\sum_{j=1}^{k} \mathbf{X}_{i,j}\right). \tag{4.1}$$

Câu WHY được biểu diễn theo hai cách: bằng bộ mã hóa câu all-MiniLM-L6-v2 [39], hoặc bằng đặc trưng văn bản của chính SmolVLM2 (giảm còn 256 chiều bằng PCA). Lớp đọc được huấn luyện bằng InfoNCE (công thức (2.6), $\tau = 0{,}07$) cộng $0{,}1\times$ mất mát cosine, AdamW [29], tốc độ học 10^{-3}, tối đa 100 epoch, 3 seed. Số epoch được chọn trên một phần khung cảnh tách ra từ dữ liệu huấn luyện, không bao giờ nhìn nhóm kiểm tra.

Kết quả trên cách chia gốc. Trước tiên, lớp đọc được đánh giá theo cách chia gốc của bộ dữ liệu (Bảng 4.6). Trên tập kiểm định, MRR gấp khoảng 1,7–1,9 lần mức ngẫu

nhiên; nhưng trên tập test riêng, MRR cao nhất (0,0314) gần như bằng mức ngẫu nhiên (0,0318).

Bảng 4.6. Giai đoạn 1: lớp đọc trên cách chia gốc (MRR toàn tập, trung bình ± độ lệch chuẩn qua 3 seed).

	Kiểm định (412 bước, 4 video)		Test riêng (407 bước, 4 video)	
k	MRR	Top-1	MRR	Top-1
2	0,0440 ± 0,0064	0,0162	0,0290 ± 0,0028	0,0057
4	0,0448 ± 0,0072	0,0162	0,0288 ± 0,0033	0,0082
6	0,0474 ± 0,0010	0,0218	0,0294 ± 0,0045	0,0090
8	0,0429 ± 0,0053	0,0146	0,0314 ± 0,0035	0,0098
Mức ngẫu nhiên	0,0249	0,0047	0,0318	0,0071

Kết quả với kiểm tra chéo. Kiểm tra chéo dùng cả 27 video để đánh giá (Bảng 4.7). Lớp đọc chỉ gấp 1,13–1,19 lần mức ngẫu nhiên về MRR, và khoảng tin cậy đều chứa 1. Ở phép chọn 1 trong 5, cách biểu diễn bằng SmolVLM2 đạt 21,9–23,0%, chỉ hơn đoán mò 2–3 điểm. Hai cách biểu diễn câu không khác nhau rõ ràng.

Bảng 4.7. Giai đoạn 1: lớp đọc trên đặc trưng SmolVLM2, kiểm tra chéo 8 nhóm theo khung cảnh, 2.503 bước. Mức ngẫu nhiên: MRR 0,0298; chọn 1 trong 5 là 20%.

Biểu diễn câu	k	MRR	Gấp ngẫu nhiên [CI 95%]	Chọn 1/5	Gấp ngẫu nhiên [CI 95%]
MiniLM	2	0,0335	1,13 [0,86; 1,43]	21,6%	1,08 [1,00; 1,16]
	4	0,0345	1,16 [0,88; 1,48]	21,5%	1,07 [1,00; 1,16]
	6	0,0353	1,18 [0,90; 1,52]	21,2%	1,06 [0,98; 1,16]
	8	0,0347	1,17 [0,87; 1,51]	21,9%	1,10 [1,01; 1,20]
SmolVLM2	2	0,0340	1,14 [0,95; 1,36]	21,9%	1,09 [1,02; 1,17]
	4	0,0338	1,14 [0,94; 1,35]	22,2%	1,11 [1,03; 1,19]
	6	0,0346	1,16 [0,95; 1,39]	22,3%	1,12 [1,04; 1,20]
	8	0,0354	1,19 [0,98; 1,42]	23,0%	1,15 [1,07; 1,23]

Kiểm tra thêm: để SmolVLM2 tự chấm điểm. Một cách khác không cần huấn luyện là để chính SmolVLM2 đọc khung hình rồi chấm xác suất của từng câu ứng viên, có chuẩn hóa theo xác suất của câu khi không có ảnh để câu ngắn hay câu phổ biến không được lợi [20]. Cách này đạt 23,5% ($k = 2$) và 24,6% ($k = 8$) ở phép chọn 1 trong 5, rõ hơn đoán mò nhưng vẫn thấp.

Kết luận giai đoạn 1

Backbone của VLA *có* chứa một chút tín hiệu về mục đích, nhưng quá yếu: cả lớp đọc được huấn luyện lẫn cách tự chấm điểm đều chỉ hơn đoán mò vài điểm, và lớp đọc về mức ngẫu nhiên trên tập test riêng. Nguyên nhân có thể là lớp đọc phải *tự học* mối liên hệ giữa ảnh và câu mục đích từ khoảng hai nghìn bước. Giai đoạn 2 thử một mô hình đã học sẵn mối liên hệ này từ hàng trăm triệu cặp ảnh–chú thích.

4.5. Giai đoạn 2: Bộ mã hóa ảnh–văn bản SigLIP, không huấn luyện

Câu hỏi. Một bộ mã hóa đã liên kết sẵn ảnh với chữ, dùng nguyên không huấn luyện, có chọn mục đích tốt hơn lớp đọc ở giai đoạn 1 không?

Cách làm. Dùng checkpoint `google/siglip-base-patch16-224` [52], gọi tắt là *SigLIP cơ bản*:

1. Mã hóa từng khung hình bằng phần ảnh của SigLIP (768 chiều), lấy trung bình k khung đầu.
2. Mã hóa từng câu WHY ứng viên bằng phần chữ của SigLIP.
3. Chọn câu có cosine cao nhất theo công thức (3.1).

Không có tham số nào được huấn luyện, nên không có nguy cơ học thuộc dữ liệu nhỏ. Các nhóm kiểm tra chéo chỉ dùng để chia tập ứng viên, giống hệt giai đoạn 1.

Vì sao SigLIP vẫn thuộc khung "dựa trên VLA"

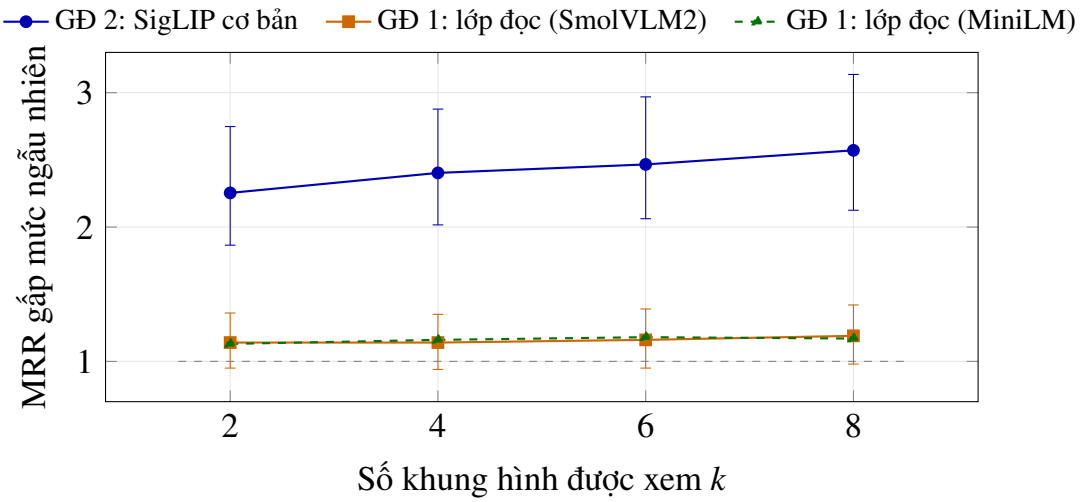
SigLIP chỉ thay *bộ mã hóa của mô-đun ý định*. Chính sách điều khiển robot vẫn là SmolVLA, và ý định vẫn đi vào SmolVLA qua token ý định (Hình 3.1). Backbone SmolVLM2 vốn dùng phần ảnh thuộc họ SigLIP; điểm khác là checkpoint SigLIP đầy đủ còn giữ phần chữ đã liên kết với ảnh, nên so được trực tiếp với câu mục đích.

Kết quả. Bảng 4.8 và Hình 4.3 cho thấy SigLIP cơ bản tốt hơn hẳn lớp đọc: MRR gấp 2,25–2,57 lần mức ngẫu nhiên (khoảng tin cậy hoàn toàn trên 1), gần gấp đôi lớp đọc ở mọi k; độ chính xác chọn 1 trong 5 là 27,5–28,9%.

Xem thêm khung hình có giúp không? Với SigLIP cơ bản, đi từ 2 lên 8 khung tăng MRR $+0{,}0094$ [$+0{,}0053$; $+0{,}0141$] và tăng chọn 1 trong 5 $+1{,}1$ điểm [$+0{,}1$; $+2{,}1$], cả hai đều rõ ràng. Với lớp đọc ở giai đoạn 1, mức tăng MRR không rõ ràng (khoảng tin cậy chứa 0). Như vậy chỉ khi biểu diễn đã liên kết tốt với chữ, thêm hình ảnh

Bảng 4.8. Giai đoạn 2: SigLIP cơ bản, không huấn luyện, cùng kiểm tra chéo và cùng tập ứng viên như giai đoạn 1.

k	MRR	Gấp mức ngẫu nhiên [CI 95%]	Chọn 1/5	Gấp mức ngẫu nhiên [CI 95%]	Chọn 1/10
2	0,0671	2,25 [1,87; 2,75]	27,7%	1,39 [1,23; 1,56]	15,7%
4	0,0715	2,40 [2,02; 2,88]	27,5%	1,38 [1,22; 1,55]	16,1%
6	0,0734	2,47 [2,06; 2,97]	28,1%	1,40 [1,24; 1,58]	16,7%
8	0,0765	2,57 [2,13; 3,14]	28,9%	1,44 [1,27; 1,62]	17,7%



Hình 4.3. MRR toàn tập (gấp mức ngẫu nhiên) theo số khung được xem. Thanh sai số: khoảng tin cậy 95%. Đường xám nét đứt: mức ngẫu nhiên.

mới giúp phân biệt mục đích tốt hơn.

Phân tích lỗi. Với bước ở Hình 4.1 (đáp án "positioning basin"), SigLIP cơ bản ở 8 khung xếp: "prepare to knead dough" (cosine 0,101), "developing dough consistency" (0,085), "forming cohesive dough" (0,072), "cleaning the table surface" (0,056), và câu đúng đứng cuối (0,020). Mô hình nhận ra đúng *hoạt động chung* là nhào bột, nhưng không phân biệt được *bước* cụ thể. Lý do là các khung hình của mọi bước đều chứa cùng cái bàn, cái chậu, đôi tay và bột; phần chung này chiếm phần lớn vector ảnh.

Kết luận giai đoạn 2

Dùng mô hình đã liên kết sẵn ảnh với chữ tốt hơn hẳn việc tự huấn luyện lớp đọc trên dữ liệu nhỏ, và kết quả tăng khi xem thêm khung. Tuy vậy, 27,5–28,9% vẫn dưới ngưỡng 30% đặt trước, và lỗi chủ yếu là nhầm giữa các bước cùng hoạt động. Giai đoạn 3 tìm cách bỏ bớt phần khung cảnh chung, và thử các bộ mã hóa lớn hơn, vẫn không huấn luyện.

4.6. Giai đoạn 3: Chọn cấu hình tốt nhất, không huấn luyện

Câu hỏi. Không huấn luyện thêm, có thể vượt 30% bằng cách chọn bộ mã hóa tốt hơn và xử lý vector ảnh khác đi không?

Cách làm. Kết quả phân tích lỗi ở giai đoạn 2 gợi ý hai hướng: dùng bộ mã hóa mạnh hơn, và bỏ phần khung cảnh chung giữa các bước. Đồ án thử 90 cấu hình không huấn luyện, là tổ hợp của 5 bộ mã hóa, 3 cách gộp khung, 3 cách xử lý vector ảnh (trong đó có trừ khung cảnh của các bước trước, công thức (3.7)) và 2 cách viết câu ứng viên. Các lựa chọn và cơ sở của từng lựa chọn được mô tả ở Mục 3.3.

Chọn cấu hình sao cho không tự lừa mình. Nếu thử cả 90 cấu hình rồi báo cáo cấu hình đẹp nhất trên cùng dữ liệu đánh giá, con số sẽ lạc quan giả tạo. Vì vậy trong mỗi lần kiểm tra chéo, 90 cấu hình chỉ được chấm trên 7 nhóm huấn luyện, cấu hình tốt nhất được chọn, rồi mới đem đánh giá trên nhóm giữ lại (*chọn lồng nhau*, 8). Con số báo cáo vì vậy luôn đến từ dữ liệu không dùng để chọn.

Kết quả. Cả **8/8** lần đều chọn cùng một cấu hình: *SigLIP lớn, lấy trung bình, trừ khung cảnh của các bước trước, dùng câu mẫu*, tức **cấu hình đề xuất** ở Mục 3.3. Bảng 4.9 so nó với SigLIP cơ bản trên cùng các bước.

Bảng 4.9. Giai đoạn 3: cấu hình đề xuất so với SigLIP cơ bản (giai đoạn 2), 2.503 bước, kiểm tra chéo. Hiệu ghép cặp trên cùng bước, khoảng tin cậy 95%.

	Chọn 1 trong 5			MRR toàn tập		
k	Cơ bản	Đề xuất	Hiệu [CI 95%]	Cơ bản	Đề xuất	Hiệu [CI 95%]
2	27,7%	**34,1%**	+6,4 [+3,9; +8,9]	0,0671	0,0747	+0,0076 [−0,0037; +0,0195]
4	27,5%	**34,9%**	+7,4 [+4,9; +10,0]	0,0715	0,0777	+0,0062 [−0,0059; +0,0183]
6	28,1%	**36,2%**	+8,2 [+5,1; +11,2]	0,0734	0,0825	+0,0091 [−0,0024; +0,0206]
8	28,9%	**38,7%**	+9,9 [+6,2; +13,4]	0,0765	0,0850	+0,0085 [−0,0026; +0,0195]

Ở phép chọn 1 trong 5, cấu hình đề xuất đạt 34,1–38,7%, vượt ngưỡng 30% ở cả 4 giá trị k và hơn SigLIP cơ bản 6,4–9,9 điểm, mọi khoảng tin cậy đều trên 0. Ở MRR toàn tập, cấu hình đề xuất cũng cao hơn nhưng mức tăng chưa rõ ràng (khoảng tin cậy chứa 0).

Kiểm tra tín hiệu có thật đến từ video không. Thay khung hình của mỗi bước bằng khung của một video ở khung cảnh khác (313 bước, $k = 8$), độ chính xác của cấu hình đề xuất rơi từ 39,6% xuống 18,8%, tức về mức đoán mò. Mô hình thật sự dùng nội

dung hình ảnh, không đoán dựa vào câu chữ.

Thành phần nào đóng góp? Trong toàn bộ 90 cấu hình, 6 cấu hình đứng đầu đều dùng SigLIP lớn cùng bước bỏ khung cảnh chung. Bỏ bước này khỏi SigLIP lớn thì còn 31,1–33,0%; thêm bước này cho SigLIP cơ bản thì được 29,1–32,1%. Cả bộ mã hóa lớn hơn lẫn bước bỏ khung cảnh chung đều có ích.

Kết luận giai đoạn 3

Không huấn luyện thêm, cấu hình đề xuất vượt ngưỡng 30% và được chọn ổn định 8/8 lần. Cấu hình được ghi lại cố định (tệp `FROZEN.json`, kèm mã băm) trước khi đọc tập test riêng. Câu hỏi còn lại: ưu thế này có giữ được trên video chưa từng dùng trong lúc phát triển không?

4.7. Giai đoạn 4: Kiểm tra một lần trên tập test riêng

Câu hỏi. Trên 407 bước của 4 video chưa từng dùng, cấu hình đề xuất có còn hơn đoán mò và hơn SigLIP cơ bản không?

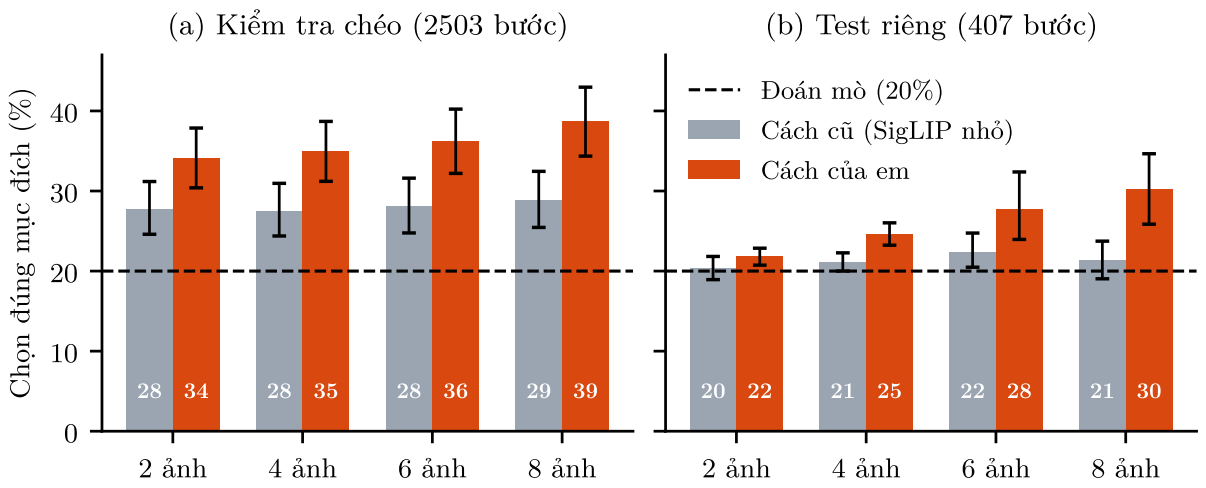
Cách làm. Cấu hình đề xuất và tiêu chí đạt được ghi cố định trước. Mã đánh giá được thử trên dữ liệu giả, từ chối chạy nếu kết quả đã tồn tại, và chỉ chạy thật khi người làm đồ án xác nhận. Bước bỏ khung cảnh chung trên tập test chỉ dùng các bước trước của *chính video test*. Tập này được chạy đúng một lần, ngày 23/10/2026, và không dùng lại cho việc chọn mô hình.

Kết quả. Hình 4.4 và Bảng 4.10 so hai cấu hình trên tập test riêng, đặt cạnh kết quả kiểm tra chéo.

Bảng 4.10. Giai đoạn 4: tập test riêng (407 bước, 4 video), chạy một lần. Đoán mò: chọn 1 trong 5 là 20%, MRR 0,0318.

	Chọn 1 trong 5			MRR toàn tập	
k	Cơ bản	Đề xuất	Hiệu [CI 95%]	Cơ bản	Đề xuất
2	20,4%	21,9%	+1,5 [−1,0; +3,8]	0,0631	0,0459
4	21,1%	24,6%	+3,4 [+1,3; +4,8]	0,0594	0,0488
6	22,4%	27,8%	+5,4 [+1,0; +9,7]	0,0660	0,0557
8	21,4%	**30,2%**	+8,9 [+4,4; +14,8]	0,0653	0,0615

Cấu hình đề xuất rõ ràng hơn đoán mò ở cả 4 giá trị k, và rõ ràng hơn SigLIP cơ bản ở $k = 4, 6, 8$; ở $k = 2$ chưa phân biệt được. Ở 8 khung, cấu hình đề xuất đạt 30,2% so



Hình 4.4. Tỉ lệ chọn đúng mục đích trong 5 câu. (a) Kiểm tra chéo trên 2.503 bước (giai đoạn 3); (b) tập test riêng 407 bước, chạy một lần (giai đoạn 4). Thanh đen: khoảng tin cậy 95%.

với 21,4%. Khi đổi sang khung hình của video khác (51 bước, $k = 8$), độ chính xác rơi từ 31,4% xuống 21,6%, cùng chiều với kiểm tra chéo.

Kết quả cùng chiều khi tăng độ khó lên chọn 1 trong 10 câu cùng video (đoán mò 10%): cấu hình đề xuất đạt 16,0%, 15,2%, 17,0% và 19,2% ở $k = 2, 4, 6, 8$, so với 12,5%, 10,3%, 11,6% và 10,8% của cấu hình cơ bản. Hiệu ghép cặp có khoảng tin cậy trên 0 ở cả 4 giá trị k (từ $+3{,}4$ [$+1{,}3$; $+5{,}4$] ở $k = 2$ đến $+8{,}4$ [$+5{,}7$; $+10{,}9$] ở $k = 8$). Ở phép đo này, cấu hình cơ bản gần như về mức đoán mò trên tập test, còn cấu hình đề xuất vẫn gần gấp đôi.

Có ba điểm cần đọc kèm:

- **Kết quả thấp hơn kiểm tra chéo** (21,9–30,2% so với 34,1–38,7%). SigLIP cơ bản cũng giảm (từ 27,5–28,9% xuống 20,4–22,4%), nên tập test có vẻ khó hơn; với 4 video thì chưa tách được nguyên nhân.
- **MRR toàn tập của cấu hình đề xuất thấp hơn SigLIP cơ bản** ở cả 4 giá trị k. Bước bỏ khung cảnh chung giúp phân biệt các bước *trong cùng video*, nhưng cũng làm mất thông tin "đang ở khung cảnh nào", vốn có ích khi xếp hạng giữa câu của nhiều video.
- **Chỉ có 4 video**, nên mọi khoảng tin cậy trên tập test chỉ dựa trên 4 cụm và cần đọc thận trọng.

Kết luận giai đoạn 4

Ưu thế của cấu hình đề xuất ở bài toán sát với robot (chọn đúng mục đích giữa các bước cùng video) giữ được trên video mới, với 30,2% so với 21,4% ở 8 khung. Mức độ thấp hơn kiểm tra chéo, nên một robot dùng mô-đun này vẫn sẽ sai nhiều. Giai đoạn 5 xem robot có biết khi nào mình đang không chắc hay không.

4.8. Giai đoạn 5: Biết khi nào nên hỏi lại

Câu hỏi. Điểm số của mô-đun ý định có cho biết lúc nào dự đoán đáng tin, để robot chỉ hành động khi chắc và hỏi lại người khi chưa chắc không?

Cách làm. Đây là bài toán *dự đoán có quyền từ chối* (Mục 2.7). Mô-đun dùng độ chênh giữa câu cao nhất và câu thứ hai trong 5 câu (công thức (3.8)) làm độ chắc chắn, và chỉ trả lời khi độ chênh vượt ngưỡng; tỉ lệ được trả lời là *độ phủ*. Ngưỡng của mỗi nhóm kiểm tra được tính từ các nhóm khác (Mục 3.4). Cách tính được áp dụng cho cả cấu hình đề xuất và cấu hình cơ bản để so sánh.

Kết quả. Trên cấu hình đề xuất (Bảng 4.11), chỉ trả lời 50% số trường hợp chắc nhất thì độ chính xác tăng 6,9–7,9 điểm; chỉ trả lời 20% thì đạt 53–61%. Dùng xác suất cao nhất của softmax (nhiệt độ 0,07) thay cho độ chênh cho kết quả tương tự (47,4% ở 50% độ phủ, 8 khung). Với SigLIP cơ bản, mức tăng tương ứng chỉ 2,6–3,5 điểm, nên điểm tin cậy hữu ích hơn hẳn khi bộ mã hóa tốt hơn.

Bảng 4.11. Giai đoạn 5: độ chính xác chọn 1 trong 5 của cấu hình đề xuất theo độ phủ (kiểm tra chéo, 2.503 bước).

k	Trả lời 100%	Trả lời 50%	Trả lời 20%	Mức tăng ở 50% [CI 95%]
2	34,1%	41,0%	53,3%	+6,9 [+3,9; +9,6]
4	34,9%	41,8%	55,7%	+6,9 [+4,5; +9,5]
6	36,2%	44,1%	57,7%	+7,9 [+5,3; +10,6]
8	38,7%	45,7%	60,9%	+7,0 [+4,0; +9,7]

4.8.1. Những hướng đã thử nhưng không giúp

Ba hướng khác đã được thử ở giai đoạn này. Cả ba chạy trên cấu hình cơ bản (SigLIP cơ bản), cùng kiểm tra chéo và cùng tập ứng viên, với tiêu chí đạt ghi trước.

Dừng xem sớm khi đã chắc. Ý tưởng lấy từ bài toán nhận ra hoạt động sớm

[42]: thay vì luôn xem k khung cố định, robot dừng ở khung đầu tiên có độ chênh công thức (3.8) vượt ngưỡng, và trả lời ngay. Ngưỡng được chọn sao cho số khung trung bình bằng một "ngân sách" cho trước (3, 4, 5 hoặc 6 khung). Mốc so sánh là xem đúng số khung đó cho mọi bước. Tiêu chí đạt là dừng sớm hơn rõ ràng ở đa số ngân sách. Bảng 4.12 cho thấy chỉ ở ngân sách 5 khung, hiệu mới có khoảng tin cậy trên 0 ($+1{,}4$ điểm); ở ba ngân sách còn lại, hiệu nằm trong khoảng $-0{,}2$ đến $+0{,}6$ điểm. Lý do thấy được ngay ở cột cuối: với cấu hình cơ bản, độ chính xác gần như không đổi từ 1 đến 8 khung (27,5% đến 28,9%), nên dừng sớm hay muộn không khác nhau mấy.

Bảng 4.12. Dừng xem sớm khi đã chắc (cấu hình cơ bản, chọn 1 trong 5, 2.503 bước). "Cố định": xem cùng số khung trung bình cho mọi bước.

Ngân sách (khung)	Số khung TB	Dừng sớm [CI 95%]	Cố định	Hiệu [CI 95%]
3	3,01	27,9% [24,9; 31,3]	28,2%	$-0{,}2$ [$-0{,}9$; $+0{,}5$]
4	4,00	28,2% [24,8; 31,7]	27,5%	$+0{,}6$ [$-0{,}0$; $+1{,}3$]
5	5,01	28,9% [25,3; 32,6]	27,5%	$+1{,}4$ [$+0{,}2$; $+2{,}6$]
6	6,00	28,7% [25,2; 32,3]	28,1%	$+0{,}6$ [$-0{,}3$; $+1{,}4$]

Tham khảo các bước giống nhất trong dữ liệu huấn luyện. Theo kiểu bộ nhớ đệm không huấn luyện của Tip-Adapter [54], với mỗi bước cần đoán, lấy 20 bước giống nhất trong các khung cảnh huấn luyện, pha trộn vector câu WHY của chúng theo độ giống (softmax nhiệt độ 0,05), rồi cộng điểm khớp với vector pha trộn này vào điểm gốc với trọng số β. Trọng số $\beta \in \{0;\ 0{,}25;\ 0{,}5;\ 1;\ 2\}$ được chọn trong các khung cảnh huấn luyện. Kết quả: β được chọn là 0 hoặc 0,25 ở mọi lần; MRR *giảm* rõ ở 3/4 giá trị k (ví dụ $-0{,}0071$ [$-0{,}0135$; $-0{,}0015$] ở $k = 8$), và chọn 1 trong 5 giảm nhẹ 0,4–0,6 điểm. Vì câu WHY gần như không lặp lại giữa các video (2.032 câu trên 2.503 bước), "hàng xóm" ở khung cảnh khác hầu như không mang mục đích đúng.

Tập trung vào vùng tay–vật. Kế hoạch là cắt vùng quanh bàn tay làm đầu vào, vì tay và vật đang cầm mang nhiều thông tin về bước hiện tại. Điều kiện để thử là bàn tay được phát hiện trong ít nhất 60% số khung và ít nhất 30% ở mọi khung cảnh. MediaPipe Hands [53] chỉ phát hiện được tay trong 58,2% số khung (11.652/20.024), và rất thấp ở một số khung cảnh (Bảng 4.13). Điều kiện không đạt, nên hướng này chưa được đánh giá; nếu vẫn cắt theo tay, gần như toàn bộ khung hình ở hiên nhà, phòng giặt và sân sẽ không có vùng cắt.

Bảng 4.13. Tỉ lệ khung hình phát hiện được bàn tay bằng MediaPipe Hands theo khung cảnh (2.503 bước × 8 khung).

Khung cảnh	Khung	Tỉ lệ	Khung cảnh	Khung	Tỉ lệ
Tủ quần áo	832	88,8%	Phòng khách	1.584	61,9%
Hành lang	808	84,5%	Xưởng vẽ	720	61,8%
Xưởng mộc	3.672	76,2%	Trang trại	1.712	32,2%
Bếp	3.168	71,6%	Ngoài trời	904	24,8%
Phòng ngủ	1.528	67,2%	Sân	832	15,9%
Gara	2.568	61,8%	Phòng giặt	848	15,3%
			Hiên nhà	848	10,3%
Tổng: 11.652/20.024 khung (58,2%); điều kiện: $\geq 60\%$ tổng và $\geq 30\%$ mỗi khung cảnh					

Kết luận giai đoạn 5

Độ chắc chắn của mô-đun ý định dùng được: robot có thể chỉ hành động ở các trường hợp chắc và hỏi lại người ở các trường hợp còn lại. Mô-đun ý định lúc này đã sẵn sàng để nối vào robot.

4.9. Giai đoạn 6: Nối mô-đun ý định vào SmolVLA

Câu hỏi. (i) Có thể đưa ý định vào SmolVLA một cách đúng đắn mà không phá vỡ mô hình gốc không? (ii) SmolVLA phụ thuộc vào thông tin mục tiêu đến mức nào?

4.9.1. Cài đặt token ý định

Token ý định được cài vào SmolVLA như mô tả ở Mục 3.5. Bảy kiểm thử ở Bảng 3.1 được chạy với ba kích thước $d \in \{256, 768, 1152\}$ và đều đạt: tiền tố dài thêm đúng một token, token nằm trước trạng thái và có trong bộ nhớ đệm, gradient tới được adapter, và khi tắt cờ thì kết quả trùng khớp hoàn toàn với SmolVLA gốc. Câu hỏi (i) vì vậy được trả lời ở mức cài đặt.

4.9.2. SmolVLA phụ thuộc vào câu lệnh đến mức nào

Đồ án huấn luyện lại SmolVLA (không có token ý định) trên LIBERO-10 [28] với hành động 7 chiều, 25.000 bước. Đây là checkpoint đạt 24/100 trong lần đánh giá chuẩn ở giai đoạn 0 (Mục 4.3). Sau đó chạy 10 nhiệm vụ × 10 lượt trong ba điều kiện: **lệnh đúng**; **lệnh rỗng**; và **lệnh sai** (câu lệnh của nhiệm vụ khác). Lượt thứ e của mỗi nhiệm

vụ dùng cùng vị trí ban đầu và cùng hạt giống ở cả ba điều kiện; chỉ câu lệnh thay đổi.

Bảng 4.14. Giai đoạn 6: SmolVLA trên LIBERO-10 với ba loại câu lệnh (10 nhiệm vụ $\times$ 10 lượt mỗi điều kiện).

Câu lệnh	Thành công	Tỉ lệ	Khoảng Wilson 95% [51]
Đúng	19/100	19%	[12,5%; 27,8%]
Rỗng	0/100	0%	[0,0%; 3,7%]
Sai (lệnh của nhiệm vụ khác)	0/100	0%	[0,0%; 3,7%]

Theo từng nhiệm vụ, số lượt thành công với lệnh đúng là 0, 1, 3, 7, 1, 3, 3, 0, 0, 1 trên 10. Mọi lượt với lệnh rỗng hoặc sai đều chạy hết giới hạn 520 bước mà không hoàn thành. Lệnh đúng hơn lệnh rỗng $+19$ điểm $[+12; +27]$. Với lệnh đúng, 19/100 thấp hơn 24/100 của lần đánh giá đầu vì lần này cố định vị trí ban đầu và hạt giống cho từng lượt; 24% vẫn nằm trong khoảng Wilson [12,5%; 27,8%].

4.9.3. Token ý định thay cho câu lệnh

Câu hỏi. Kết quả trên cho thấy bỏ câu lệnh thì SmolVLA không làm được gì. Nếu robot không được nghe câu lệnh mà chỉ được biết *ý định* qua token ý định, nó có làm được việc không?

Cách làm. Đồ án huấn luyện lại SmolVLA với đúng dữ liệu và cấu hình như bản có câu lệnh (25.000 bước, cùng tốc độ học và kích thước lô), chỉ khác một điểm: câu lệnh *luôn để trống*. Nhiệm vụ được đưa vào qua token ý định: vector mục đích là phần chữ của SigLIP lớn (cùng bộ mã hóa và mẫu câu với mô-đun ý định) cho mô tả nhiệm vụ, đi qua lớp chuyển $1152 \to 960$ chiều rồi đặt trước token trạng thái (Mục 3.5). Trong quá trình huấn luyện, máy bị mất điện một lần và bị dừng một lần; cả hai lần đều được chạy tiếp từ checkpoint gần nhất (bước 8.000 và 12.000) với trạng thái bộ tối ưu được giữ nguyên. Khi thử, câu lệnh luôn để trống và mỗi lượt dùng cùng vị trí ban đầu, cùng hạt giống như Bảng 4.14. Có hai điều kiện: **ý định đúng** (vector của chính nhiệm vụ đó) và **ý định sai** (vector của nhiệm vụ khác, nhiệm vụ $t+5$).

Kết quả. Chỉ với token ý định, robot thành công 20/100 lượt, ngang với 19/100 của SmolVLA gốc khi nghe câu lệnh đúng (hiệu $+1$ điểm, khoảng tin cậy $[-7; +9]$). So với lệnh rỗng, token ý định đúng tăng 20 điểm $[+12; +28]$; so với ý định sai cũng tăng 20 điểm $[+12; +28]$, và ý định sai không cho lượt thành công nào. Như vậy robot thật sự *dựa vào* token ý định để biết phải làm gì, chứ không tự làm được nhờ hình ảnh. Theo

Bảng 4.15. Giai đoạn 6: robot chỉ biết nhiệm vụ qua token ý định, câu lệnh luôn để trống (10 nhiệm vụ × 10 lượt, cùng vị trí ban đầu với Bảng 4.14).

Mô hình	Robot được biết gì	Thành công	Khoảng Wilson 95%
SmolVLA gốc	Câu lệnh đúng	19/100	[12,5%; 27,8%]
SmolVLA gốc	Không có gì (lệnh rỗng)	0/100	[0,0%; 3,7%]
VLIA (token ý định)	Ý định đúng, không câu lệnh	**20/100**	[13,3%; 28,9%]
VLIA (token ý định)	Ý định sai, không câu lệnh	0/100	[0,0%; 3,7%]

từng nhiệm vụ, số lượt thành công là 0, 0, 3, 7, 0, 8, 1, 0, 0, 1 trên 10; các nhiệm vụ mà bản có câu lệnh làm được cũng là các nhiệm vụ bản token ý định làm được.

Kết luận giai đoạn 6

Token ý định đã được cài vào SmolVLA đúng cách và không làm hỏng mô hình gốc. SmolVLA gốc phụ thuộc hoàn toàn vào câu lệnh: bỏ câu lệnh thì robot không làm xong việc nào. Khi được huấn luyện để nhận nhiệm vụ qua token ý định thay cho câu lệnh, robot làm được 20/100 lượt mà không cần câu lệnh nào, ngang với 19/100 khi nghe câu lệnh đúng; đưa ý định sai thì 0/100. Token ý định vì vậy thay được câu lệnh. Vector ý định ở đây vẫn được tạo từ mô tả đúng của nhiệm vụ; bước tiếp theo là thay nó bằng ý định robot tự đoán từ video người.

4.10. Giai đoạn 7: Robot đoán trước được bao xa

Câu hỏi. Các giai đoạn 2–5 đoán mục đích của bước *đang* diễn ra. Với robot cộng tác, ý định có ích nhất ở dạng *hành động tương lai*: robot cần biết trước người sẽ làm gì để chuẩn bị. Câu hỏi của giai đoạn này là: nếu chỉ xem đoạn video gần nhất, mô-đun ý định đoán đúng hành động sắp xảy ra xa đến mức nào, và độ chắc chắn của nó thay đổi ra sao khi phải đoán xa hơn?

Cách làm. Bài toán được đặt theo kiểu *dự đoán hành động sắp tới* (action anticipation) của EPIC-KITCHENS [12] và Ego4D [18], trong đó mô hình chỉ thấy video *trước* một mốc thời gian rồi đoán hành động *sau* mốc đó [16]. Khác với các bộ dữ liệu này, vốn cố định khoảng đoán trước (ví dụ 1 giây ở EPIC-KITCHENS), đồ án thay đổi khoảng đoán trước để đo xem dự đoán còn có ích đến đâu.

- **Dòng thời gian.** Các bước của mỗi video được nối theo thứ tự, mỗi bước 8 khung như trong bộ nhớ đệm của giai đoạn 3. Đo bằng độ dài thật của các đoạn video, mỗi

bước dài trung bình khoảng 2,6 giây.

- **Đầu vào và nhãn.** Tại khung t, mô-đun chỉ xem 8 khung gần nhất ($t-7$ đến t) và phải chọn *hành động* (WHAT) của bước chứa khung $t+H$ trong 5 câu WHAT của cùng video (đoán mò 20%). Cùng phép đo được lặp với nhãn WHY để so sánh.
- **Khoảng đoán trước.** $H \in \{2,4,6,8,12,16,24,32,48,64\}$ khung, tức từ 0,6 đến 20,5 giây. Mọi H dùng *chung* 18.107 thời điểm t trên 27 video phát triển, nên các mức H so được trực tiếp với nhau. Bốn video của tập test riêng không được dùng.
- **Cách chấm điểm.** Giữ nguyên cấu hình đã chốt ở giai đoạn 3: SigLIP lớn, lấy trung bình khung, mẫu câu T1, và trừ trung bình các khung đứng *trước* đoạn quan sát (C2). Không có tham số nào được huấn luyện hay chọn lại.
- **Mức trần.** Cùng các thời điểm, mô-đun được xem chính 8 khung của bước đích. Con số này cho biết bài toán nhận ra hành động khó đến đâu khi đã nhìn thấy nó.
- **Điểm hội tụ.** Với mỗi cặp H liền nhau, đồ án tính hiệu độ chính xác *ghép cặp* trên cùng các thời điểm, với khoảng tin cậy bootstrap theo video (Mục 2.7). Cặp nào có khoảng tin cậy chứa 0 thì hai mức H không phân biệt được: đường cong đã đi ngang.

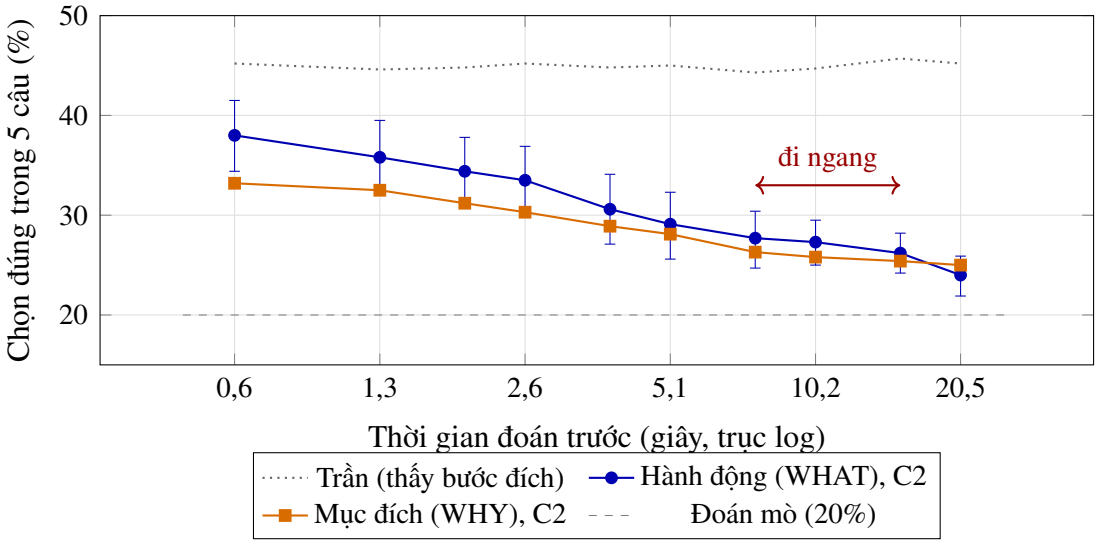
Kết quả. Bảng 4.16 và Hình 4.5 cho thấy ba điều.

Bảng 4.16. Giai đoạn 7: chọn đúng hành động sắp tới trong 5 câu cùng video theo khoảng đoán trước H (27 video, 18.107 thời điểm cho mỗi H, đoán mò 20%).

			Hành động (WHAT)			Mục đích (WHY)	WHAT, C2	
H (khung)	Đoán trước (s)	Cùng bước (%)	C2 [CI 95%]	C0	Trần	C2	Trả lời 20%	Độ chênh TB
2	0,6	74,8	**38,0** [34,4; 41,5]	33,5	45,2	33,2	59,2	0,0375
4	1,3	49,9	**35,8** [32,0; 39,5]	31,7	44,6	32,5	54,8	0,0369
6	1,9	24,9	**34,4** [30,9; 37,8]	30,5	44,8	31,2	51,9	0,0370
8	2,6	0	**33,5** [29,9; 36,9]	29,9	45,2	30,3	49,1	0,0368
12	3,8	0	**30,6** [27,1; 34,1]	28,3	44,8	28,9	42,8	0,0362
16	5,1	0	**29,1** [25,6; 32,3]	26,8	45,0	28,1	39,9	0,0363
24	7,7	0	**27,7** [24,7; 30,4]	26,1	44,3	26,3	37,3	0,0361
32	10,2	0	**27,3** [25,0; 29,5]	25,3	44,7	25,8	34,6	0,0354
48	15,4	0	**26,2** [24,2; 28,2]	24,2	45,7	25,4	31,9	0,0353
64	20,5	0	**24,0** [21,9; 25,9]	22,8	45,2	25,0	30,1	0,0351

C2: trừ trung bình các khung trước đoạn quan sát; C0: không trừ. Trần: mô-đun được xem chính bước đích. Cùng bước: tỉ lệ thời điểm mà khung $t+H$ vẫn thuộc bước đang làm. Trả lời 20%: độ chính xác khi chỉ trả lời 20% trường hợp có độ chênh (công thức (3.8)) lớn nhất. Độ chênh TB: độ chênh trung bình giữa câu cao nhất và câu thứ hai.

Thứ nhất, độ chính xác giảm nhanh trong vài giây đầu rồi đi ngang từ khoảng 7–8 giây. Với hành động, độ chính xác giảm từ 38,0% (0,6 s) xuống 29,1% (5,1 s). Phép so



Hình 4.5. Giai đoạn 7: độ chính xác dự đoán hành động sắp tới theo thời gian đoán trước. Thanh dọc: khoảng tin cậy 95% (bootstrap theo video). Mũi tên: đoạn mà các mức H liền nhau không phân biệt được (Bảng 4.17).

sánh ghép cặp (Bảng 4.17) cho thấy mọi bước tăng H từ 2 đến 24 đều làm giảm rõ, với khoảng tin cậy của hiệu nằm hẳn trên 0. Hai cặp $24 \to 32$ và $32 \to 48$ (7,7 đến 15,4 s) thì không phân biệt được, nên điểm hội tụ ở khoảng $H = 24$, tức khoảng 3 bước thao tác. Từ 48 lên 64 khung, độ chính xác lại giảm thêm 2,2 điểm; ở 20,5 s nó vẫn hơn đoán mò (24,0%, khoảng tin cậy từ 21,9%). Với mục đích, đường cong đi ngang hẳn từ $H = 24$: cả ba cặp sau đều không phân biệt được, ở mức 25–26%. Cần lưu ý rằng "không phân biệt được" không có nghĩa là bằng nhau; các hiệu ở đoạn này đều dưới khoảng 1–2 điểm.

Thứ hai, mức còn lại trên đoán mò khi đoán xa nhiều khả năng đến từ việc biết người đang làm hoạt động gì, chứ không phải biết chính xác hành động cụ thể sắp tới. Mức trần gần như không đổi theo H (44,3–45,7%), nên độ khó của bản thân các nhãn đích không đổi; phần giảm là do đoạn quan sát xa dần bước đích. Nhãn WHY, vốn mô tả mục đích chung hơn, giữ được lâu hơn WHAT. Điều này phù hợp với quan sát của AntGPT rằng biết mục tiêu của cả hoạt động giúp dự đoán dài hạn [55].

Thứ ba, độ chắc chắn của mô-đun gần như không đổi khi phải đoán xa hơn. Độ chênh trung bình chỉ giảm từ 0,0375 xuống 0,0351, trong khi độ chính xác giảm 14 điểm. Vì vậy cách trả lời có chọn lọc của giai đoạn 5 kém dần theo H: ở 20% độ phủ, độ chính xác giảm từ 59,2% (0,6 s) xuống 30,1% (20,5 s). Mô-đun không tự biết khi nào nó đang đoán quá xa.

Ngoài ra, ở mọi H, nhãn WHAT dễ đoán hơn WHY (38,0% so với 33,2% ở 0,6

s), và bước trừ khung cảnh chung (C2) tốt hơn không trừ (C0). Ở mức trần, WHY đạt khoảng 38%, khớp với kết quả 38,7% của giai đoạn 3 khi xem đủ 8 khung. Đây là một kiểm tra chéo cho thấy dòng thời gian được dựng đúng.

Bảng 4.17. Giai đoạn 7: hiệu độ chính xác ghép cặp giữa các mức H liền nhau (cấu hình C2, điểm phần trăm). "Ngang": khoảng tin cậy 95% chứa 0.

	Hành động (WHAT)		Mục đích (WHY)	
Cặp H (giây)	Hiệu [CI 95%]		Hiệu [CI 95%]	
2 → 4 (0,6→1,3)	+2,2 [+1,3; +3,1]		+0,7 [+0,1; +1,4]	
4 → 6 (1,3→1,9)	+1,4 [+0,4; +2,4]		+1,3 [+0,4; +2,1]	
6 → 8 (1,9→2,6)	+0,9 [+0,3; +1,6]		+1,0 [+0,2; +1,7]	
8 → 12 (2,6→3,8)	+2,9 [+2,1; +3,7]		+1,4 [+0,4; +2,4]	
12 → 16 (3,8→5,1)	+1,5 [+0,6; +2,5]		+0,8 [+0,0; +1,5]	
16 → 24 (5,1→7,7)	+1,4 [+0,2; +2,6]		+1,8 [+0,9; +2,7]	
24 → 32 (7,7→10,2)	+0,4 [−0,7; +1,5]	Ngang	+0,5 [−0,5; +1,5]	Ngang
32 → 48 (10,2→15,4)	+1,1 [−0,3; +2,4]	Ngang	+0,4 [−1,1; +1,8]	Ngang
48 → 64 (15,4→20,5)	+2,2 [+1,0; +3,5]		+0,4 [−0,4; +1,3]	Ngang

4.10.1. Đo lại theo giây thật: xem bao lâu và đoán xa bao nhiêu

Câu hỏi. Ở trên, mỗi bước có 8 khung lấy cách đều, nên "H khung" dài hay ngắn tùy độ dài của bước, và mô-đun luôn xem đúng 8 khung. Cách lấy 8 khung này theo nguyên lý lấy mẫu thưa, cách đều của TSN [49], nhưng con số 8 chưa được chọn dựa trên kết quả; ảnh hưởng của riêng số khung được kiểm tra ở giai đoạn 9 (Mục 4.12.1). Phần này trả lời hai câu hỏi: tính theo giây thật thì mô-đun đoán trước được bao xa, và cho mô-đun xem đoạn video dài hơn có giúp không?

Cách làm. Video gốc quay ở 30 khung/giây. Mỗi đoạn video được lấy lại đều *4 khung mỗi giây*, không phụ thuộc độ dài bước, rồi mã hóa bằng SigLIP lớn. Các bước của một video được nối theo thứ tự thành một dòng thời gian. Cứ mỗi giây lấy một thời điểm t, và mọi cấu hình dùng chung các thời điểm này (5.710 thời điểm trên 26 video; một video bị bỏ vì ngắn hơn 36 giây). Tại t, mô-đun xem C giây gần nhất ($C \in \{1, 2, 4, 8, 16\}$, tức 4 đến 64 khung), lấy trung bình và trừ khung cảnh của phần trước đó như C2. Nó phải chọn hành động của bước chứa thời điểm $t + H$ (H từ 0,5 đến 20 giây) trong 5 câu cùng video. Năm câu ứng viên giống nhau với mọi C, nên các độ dài quan sát so được trực tiếp với nhau.

Bảng 4.18. Giai đoạn 7, đo theo giây thật: chọn đúng hành động sắp tới trong 5 câu cùng video (%, 4 khung/giây, 5.710 thời điểm, 26 video, đoán mò 20%). Hàng: độ dài đoạn mô-đun được xem; cột: đoán trước bao xa.

	Đoán trước (giây)					
Xem (giây)	0,5	2	4	8	12	20
1	**36,3**	34,3	32,1	29,2	26,2	25,2
2	35,9	**34,4**	**32,2**	**30,1**	26,7	25,4
4	35,7	34,2	31,9	29,5	26,9	25,6
8	34,3	33,2	30,7	28,8	27,0	25,6
16	32,7	31,9	31,1	28,8	**27,2**	**26,1**
Bước hiện tại = bước đích (%)	82	41	17	1	0	0

Kết quả. Bảng 4.18 cho thấy hai điều.

Thứ nhất, xem dài hơn không giúp, và với dự đoán gần còn làm kém đi. So sánh ghép cặp cho thấy xem 1, 2 hay 4 giây gần như không phân biệt được: trong 32 cặp (1 với 2 giây, 2 với 4 giây, ở 8 khoảng đoán trước và hai loại nhãn), chỉ 2 cặp khác nhau rõ, và đều dưới 1,5 điểm. Với dự đoán gần (0,5–2 giây), tăng từ 4 lên 8 giây làm giảm rõ khoảng 1–1,5 điểm ở mọi trường hợp, và tăng tiếp lên 16 giây thường giảm thêm. Ví dụ, đoán trước 0,5 giây: xem 2 giây đạt 35,9%, xem 16 giây chỉ còn 32,7%. Với dự đoán xa (từ 8 giây), mọi độ dài quan sát cho kết quả như nhau. Như vậy đoạn quan sát tốt nhất là khoảng 1–4 giây, tức một đến hai bước. Cách cũ (8 khung trên một bước dài trung bình 2,6 giây) đã nằm trong vùng này. Lý do có thể là mô-đun lấy trung bình các khung: đoạn quá dài trộn hành động hiện tại với các hành động đã qua. Một mô hình có thứ tự thời gian có thể dùng đoạn dài tốt hơn; điều này chưa được thử.

Thứ hai, tính theo giây thật, độ chính xác đi ngang từ khoảng 12 giây. Với đoạn quan sát 2 giây, độ chính xác giảm rõ từ 2 đến 4, từ 4 đến 8 và từ 8 đến 12 giây (mỗi bước giảm 2–3 điểm, khoảng tin cậy dưới 0), rồi không phân biệt được từ 12 đến 16 và 16 đến 20 giây, ở mức 25–27%. Mốc này xa hơn mốc "khoảng 7–8 giây" ở trên, vì cách đo cũ suy ra thời gian từ độ dài bước. Mô-đun vẫn chỉ ngang với cách "nhận ra rồi chép" (Mục 4.11.5) ở mọi độ dài quan sát: hiệu nằm trong khoảng ± 2 điểm và hầu hết khoảng tin cậy chứa 0.

Kết luận giai đoạn 7

Chỉ từ 8 khung gần nhất, mô-đun ý định đoán được hành động sắp tới tốt hơn đoán mò đến tận 20 giây, mức xa nhất đã thử. Đo theo giây thật, độ chính xác giảm rõ đến khoảng 12 giây rồi đi ngang ở khoảng 25–27%. Xem đoạn video dài hơn 4 giây không giúp, và với dự đoán gần còn làm kém đi, nên 8 khung trên một bước (khoảng 2,6 giây) đã nằm trong vùng tốt nhất. Độ chắc chắn của mô-đun không giảm theo khoảng đoán trước, nên khi dùng cho robot, ngưỡng hành động cần tính cả khoảng đoán trước, không chỉ dựa vào độ chênh điểm (Mục 4.14.5).

4.11. Giai đoạn 8: Thử cải thiện cấu hình đã chốt

Câu hỏi. Giai đoạn 3 chốt một cấu hình, gọi tắt là F: SigLIP lớn, lấy trung bình các khung, trừ khung cảnh của các bước trước (C2) và mẫu câu T1. Giai đoạn này kiểm tra xem F đã là cách tốt nhất trong tầm dữ liệu hiện có chưa, bằng bốn hướng cải thiện mà các giai đoạn trước gợi ra: (a) chú trọng các khung gần nhất và kết hợp điểm có với không trừ khung cảnh; (b) huấn luyện nhẹ một lớp hiệu chỉnh với mẫu âm là các câu của cùng video; (c) dùng một mô hình ngôn ngữ–thị giác lớn làm bài trắc nghiệm; và (d) đoán thẳng bước tiếp theo (nhãn NEXT).

Quy tắc chung. Tiêu chí đạt hay không được viết ra *trước* khi có con số. Mọi thí nghiệm chỉ dùng 27 video phát triển với cùng 8 lần kiểm tra chéo theo khung cảnh như giai đoạn 3; tập test riêng không được dùng lại. Trước khi chạy, F được tính lại và phải cho *đúng* 853, 874, 907 và 969 lần chọn đúng (trên 2.503 bước) ở $k = 2,4,6,8$, trùng với giai đoạn 3; nếu lệch thì dừng. Một cách làm được coi là *tốt hơn F* khi hiệu chọn 1/5 so với F có khoảng tin cậy nằm hẳn trên 0 ở ít nhất 2 trong 4 giá trị k, và MRR toàn tập không kém rõ F ở cả 4 giá trị k. Mọi hiệu đều tính ghép cặp trên cùng các bước, với khoảng tin cậy bootstrap theo video (Mục 2.7).

4.11.1. Chú trọng khung gần nhất và kết hợp hai cách tính điểm

Cách làm. Đồ án thử ba cách gộp k khung: lấy trung bình như F; chỉ lấy khung cuối; và trung bình có trọng số, trong đó khung càng gần khung cuối càng nặng, trọng số giảm e lần sau mỗi h khung ($h = 1,2,4$). Điểm của mỗi câu ứng viên là $s = \cos_{C0} + \lambda \cos_{C2}$, tức điểm không trừ khung cảnh cộng với λ lần điểm có trừ khung cảnh, với $\lambda \in \{0; 0{,}25; 0{,}5; 1; 2; \infty\}$ ($\lambda = \infty$ là chỉ dùng C2 như F). Tổng cộng 30 tổ

hợp. Ở mỗi lần kiểm tra chéo, tổ hợp được chọn chỉ trên các khung cảnh huấn luyện, rồi mới chấm trên khung cảnh để riêng.

Kết quả. Bảng 4.19 cho thấy chọn 1/5 gần như không đổi: hiệu so với F nằm trong khoảng $-0{,}4$ đến $+0{,}7$ điểm, và mọi khoảng tin cậy đều chứa 0. Ngược lại, MRR toàn tập tăng rõ ở cả 4 giá trị k, từ 10% ($k = 2$) đến 21% ($k = 8$) so với F, với mọi khoảng tin cậy nằm trên 0; ở $k = 8$, chọn 1/10 cũng tăng 1,5 điểm [0,2; 3,0]. Tổ hợp được chọn khá ổn định: trọng số nghiêng về khung gần nhất với $h = 2$ và $\lambda = 2$ ở 5/8 lần, các lần còn lại là tổ hợp lân cận. Nghĩa là cách tốt nhất vẫn dựa chủ yếu vào điểm có trừ khung cảnh, nhưng cộng thêm một nửa điểm không trừ khung cảnh. Phần cộng thêm này trả lại thông tin "đang ở khung cảnh nào" mà bước trừ khung cảnh đã bỏ đi, đúng với nhận định ở Mục 4.14. Thí nghiệm này được chạy lại bằng một đoạn mã viết độc lập và cho đúng các con số trên.

Bảng 4.19. Giai đoạn 8a: cấu hình F so với tổ hợp gộp khung và kết hợp điểm được chọn trong mỗi lần kiểm tra chéo (2.503 bước, 27 video). Hiệu tính bằng điểm phần trăm (chọn 1/5) hoặc đơn vị MRR.

	Chọn 1/5 (%)			MRR toàn tập		
k	F	Chọn lại	Hiệu [CI 95%]	F	Chọn lại	Hiệu [CI 95%]
2	34,1	34,1	$+0{,}0$ [$-0{,}9$; $+0{,}9$]	0,0747	0,0825	$+0{,}0078$ [$+0{,}0032$; $+0{,}0123$]
4	34,9	35,6	$+0{,}7$ [$-0{,}4$; $+1{,}8$]	0,0777	0,0898	$+0{,}0121$ [$+0{,}0068$; $+0{,}0178$]
6	36,2	36,8	$+0{,}5$ [$-1{,}0$; $+2{,}0$]	0,0825	0,0941	$+0{,}0116$ [$+0{,}0065$; $+0{,}0165$]
8	38,7	38,3	$-0{,}4$ [$-2{,}1$; $+1{,}0$]	0,0850	0,1032	$+0{,}0182$ [$+0{,}0122$; $+0{,}0242$]

4.11.2. Huấn luyện nhẹ một lớp hiệu chỉnh

Cách làm. Trên vector truy vấn của F, đồ án thêm một lớp hiệu chỉnh $z' = \mathrm{norm}(z + Wz)$, với W khởi tạo bằng 0, nên lúc đầu lớp này không làm thay đổi gì. Phần chữ giữ nguyên. Lớp được huấn luyện bằng học tương phản: câu WHY đúng là mẫu dương; mẫu âm là mọi câu WHY khác của *cùng video* (mẫu âm khó [41]) cộng 64 câu ngẫu nhiên của video khác. Mức điều chuẩn (weight decay 10^{-2}, 10^{-1}, 1) và số vòng huấn luyện (5 hoặc 20) được chọn trên một phần khung cảnh huấn luyện để riêng; kết quả lấy trung bình 3 hạt giống. Để kiểm tra vai trò của mẫu âm khó, đồ án huấn luyện thêm một bản chỉ dùng mẫu âm ngẫu nhiên.

Kết quả. Lớp hiệu chỉnh làm *kém đi* ở mọi k: chọn 1/5 đạt 31,9%, 33,0%, 33,8% và 34,7% ở $k = 2, 4, 6, 8$, thấp hơn F từ 2,0 đến 4,0 điểm, với mọi khoảng tin cậy nằm

hẳn dưới 0 (ví dụ $k = 8$: $-4{,}0$ $[-6{,}3;\ -1{,}7]$). MRR toàn tập cũng giảm 0,016–0,018. Bản chỉ dùng mẫu âm ngẫu nhiên kém tương tự ($-2{,}5$ đến $-3{,}7$ điểm). Đáng chú ý, ở cả 8/8 lần, cách chọn tham số đều chọn mức điều chuẩn mạnh nhất và số vòng ít nhất, tức là lớp hiệu chỉnh càng ít thay đổi SigLIP thì càng tốt. Đây là cùng bài học với giai đoạn 0: với khoảng hai nghìn bước và gần như mỗi bước một câu WHY riêng, huấn luyện thêm chỉ làm mô hình học thuộc dữ liệu huấn luyện.

4.11.3. Mô hình ngôn ngữ–thị giác lớn làm bài trắc nghiệm

Cách làm. Đồ án cho Qwen2.5-VL-3B-Instruct [2] xem k khung đầu của bước (cạnh dài 448 điểm ảnh) cùng 5 câu ứng viên, và hỏi câu nào là mục đích của người. Mô hình được dùng nguyên, không huấn luyện, với một câu hỏi cố định, không thử nhiều cách hỏi. Mỗi câu hỏi được hỏi hai lần với thứ tự ứng viên đảo ngược rồi lấy trung bình, để tránh mô hình thiên về một vị trí. Bản 7B không được dùng vì cần 16,58 GB, lớn hơn bộ nhớ 16 GB của GPU. Vì mỗi câu hỏi mất khoảng 3 giây, đồ án chỉ chạy $k = 2$ và $k = 8$. Để chắc mô hình thật sự nhìn ảnh, đồ án chạy thêm một phép đối chứng: giữ nguyên 5 câu nhưng đưa khung hình của một khung cảnh khác. Cuối cùng, đồ án thử kết hợp điểm của F và của Qwen sau khi chuẩn hoá, $s = z(F) + \gamma z(\text{Qwen})$, với γ chọn trong từng lần kiểm tra chéo.

Kết quả. Bảng 4.20 cho thấy Qwen2.5-VL-3B tốt hơn rõ đoán mò ở cả hai k (gấp 1,54 và 1,99 lần, khoảng tin cậy trên 1). Khi đưa khung hình của khung cảnh khác, độ chính xác tụt từ 39,8% xuống 11,7%, nên mô hình thật sự dùng ảnh. Tuy vậy, so với F trên cùng các bước, Qwen kém hơn khi mới thấy 2 khung ($-3{,}3$ điểm, khoảng tin cậy dưới 0) và chỉ ngang F khi thấy đủ 8 khung. Kết hợp hai điểm ($\gamma = 0{,}5$ ở 7/8 lần) tăng 2,2 điểm ở $k = 8$, nhưng không tăng ở $k = 2$, nên không đạt tiêu chí đã đặt trước (cần tăng ở cả hai k).

Bảng 4.20. Giai đoạn 8c: Qwen2.5-VL-3B làm bài trắc nghiệm 5 câu cùng video, so với F trên cùng 2.503 bước (đoán mò 20%).

	$k = 2$		$k = 8$	
Cách làm	Chọn 1/5 (%)	Hiệu so với F	Chọn 1/5 (%)	Hiệu so với F
F (giai đoạn 3)	34,1	—	38,7	—
Qwen2.5-VL-3B	30,8	$-3{,}3$ $[-6{,}0;\ -0{,}3]$	39,8	$+1{,}1$ $[-2{,}6;\ +5{,}1]$
F + Qwen	34,2	$+0{,}1$ $[-1{,}8;\ +2{,}2]$	**40,9**	$+2{,}2$ $[+0{,}1;\ +4{,}4]$
Qwen, khung cảnh khác (đối chứng)	—	—	11,7	—

Kết quả này có ý nghĩa thực tế cho robot. Một mô hình tổng quát 3 tỉ tham số chưa từng thấy EgoIntent chỉ đạt ngang F, trong khi F chỉ cần mã hoá ảnh một lần bằng SigLIP và so với các câu đã mã hoá sẵn. Ưu thế của F rõ nhất khi mới thấy ít khung, đúng là lúc robot cần đoán sớm. Qwen có ích nhất như một nguồn kiểm tra thêm khi đã xem hết bước, nhưng 3 giây cho mỗi lần hỏi là quá chậm để cập nhật liên tục.

4.11.4. Đoán bước tiếp theo

Cách làm. Nhãn là câu NEXT (*observed_next_step*) của bước đang xem, tức bước người sẽ làm tiếp. Ứng viên là 5 câu NEXT khác nhau của cùng video, dùng đúng F, không có tham số nào được chọn lại. Mức trần là khi mô-đun được xem 8 khung của chính bước tiếp theo. Một kiểm tra phụ cho thấy câu NEXT của một bước chỉ trùng nguyên văn câu WHAT của bước kế sau ở 1,9% số bước, nên đây là một nhãn riêng chứ không phải chép lại WHAT.

Kết quả. Chỉ từ k khung đầu của bước hiện tại, F chọn đúng bước tiếp theo 27,8%, 28,9%, 30,0% và 32,1% ở $k = 2, 4, 6, 8$, đều hơn đoán mò rõ (cận dưới của khoảng tin cậy gấp 1,22–1,45 lần đoán mò), và tăng đều theo số khung đã xem. Không trừ khung cảnh (C0) chỉ đạt 26,7–28,0%, nên bước trừ khung cảnh vẫn có ích ở nhãn này. Mức trần là 38,4%, nên ở $k = 8$ mô-đun đã đi được khoảng 2/3 quãng từ đoán mò đến mức trần. Con số này cùng mức với kết quả đoán hành động sau khoảng một bước ở giai đoạn 7 (33,5% ở 2,6 giây), dù hai phép đo dùng nhãn khác nhau.

4.11.5. So với các cách làm cơ sở trong tài liệu

Câu hỏi. Kết quả đoán trước ở giai đoạn 7 và phần NEXT ở trên đều hơn đoán mò. Nhưng các bài về dự đoán hành động sắp tới luôn so với các cách làm cơ sở đơn giản [12, 16], vì một mô hình có thể "đoán trước" tốt chỉ nhờ nhận ra việc đang làm, khi bước sau thường giống bước hiện tại. Phần này kiểm tra xem mô-đun có làm được hơn thế không.

Cách làm. Dùng đúng các thời điểm, các nhãn đích và 5 câu ứng viên của giai đoạn 7 và phần NEXT. Đồ án so mô-đun ý định (F) với ba cách làm cơ sở. Không cách nào được huấn luyện hay chọn tham số.

- **Không xem video:** chọn câu ứng viên gần nhất với "câu trung bình" của các video khác. Cách này đo xem bản thân các câu có thiên lệch nào giúp đoán đúng mà không

cần nhìn hay không.

- **Nhận ra rồi chép:** dùng chính F để nhận ra bước *hiện tại* (câu gần nhất với đoạn đang xem trong các câu của video), rồi chọn câu ứng viên có nghĩa gần nhất với câu đó. Đây là giả định "người sẽ tiếp tục làm việc đang làm".
- **Chép nhãn đúng:** như trên nhưng dùng câu *đúng* của bước hiện tại. Đây là mức tốt nhất mà mọi cách "nhận ra rồi chép" có thể đạt, chỉ dùng để chẩn đoán.

Trước khi chạy, F được tính lại và cho đúng các con số của giai đoạn 7 và phần NEXT.

Bảng 4.21. Giai đoạn 8e: mô-đun ý định (F) so với các cách làm cơ sở, chọn đúng trong 5 câu cùng video (%, đoán mò 20%). Cột cuối: hiệu F trừ "Nhận ra rồi chép" [CI 95%], ghép cặp trên cùng các thời điểm.

Bài toán	Mức	F	Không xem video	Nhận ra rồi chép	Chép nhãn đúng	F − Nhận ra rồi chép
Hành động sau H	0,6 s ($H = 2$)	**38,0**	19,9	36,3	85,4	+1,7 [+0,6; +2,9]
(WHAT, gđ. 7)	2,6 s ($H = 8$)	**33,5**	19,7	32,2	41,9	+1,4 [+0,3; +2,4]
	5,1 s ($H = 16$)	29,1	19,9	28,7	35,8	+0,4 [−0,8; +1,6]
	7,7 s ($H = 24$)	27,7	20,2	28,0	30,4	−0,3 [−1,3; +0,7]
	20,5 s ($H = 64$)	24,0	20,1	24,6	26,2	−0,6 [−1,4; +0,3]
Bước tiếp theo	$k = 2$	27,8	19,5	27,6	38,6	+0,2 [−1,8; +2,2]
(NEXT)	$k = 8$	32,1	19,5	31,0	38,6	+1,1 [−0,3; +2,7]

Kết quả. Bảng 4.21 cho thấy ba điều. *Thứ nhất*, không xem video chỉ đạt 19–20%, đúng mức đoán mò, nên các câu ứng viên không có thiên lệch nào giúp đoán đúng; F hơn cách này rõ ở mọi mức (từ +18,2 điểm ở 0,6 s đến +3,9 điểm ở 20,5 s, khoảng tin cậy đều trên 0). *Thứ hai*, F gần như bằng cách nhận ra rồi chép. F chỉ hơn rõ ở $H = 2$ và $H = 8$ (khoảng 1,5 điểm); ở các mức còn lại và ở NEXT, hai cách không phân biệt được. Nghĩa là phần lớn khả năng "đoán trước" của mô-đun đến từ việc nhận ra người đang làm gì, chứ chưa dùng hiểu biết về thứ tự các bước. *Thứ ba*, nếu biết đúng bước hiện tại thì chỉ cần chép cũng đạt 41,9% ở 2,6 s và 38,6% ở NEXT, cao hơn F 6–8 điểm. Khâu nhận ra hiện tại vì vậy là nút thắt: cải thiện nó sẽ cải thiện trực tiếp phần đoán trước. Ở mức xa (20 s), cả ba cách có xem video đều chỉ còn 24–26%.

Cách hai bước kiểu AntGPT. Muốn hơn cách "chép hiện tại" thì cần dùng thứ tự các bước của tác vụ. AntGPT [55] làm việc này theo hai bước: nhận ra các hành động đã xảy ra, rồi cho một mô hình ngôn ngữ đọc chuỗi hành động đó để đoán bước sau. Đồ án thử cách này cho bài toán NEXT: Qwen2.5-VL-3B (chỉ dùng phần chữ, không xem ảnh) đọc câu WHAT của tối đa 5 bước trước và bước hiện tại, rồi chọn bước tiếp theo trong cùng 5 câu NEXT như F. Chuỗi WHAT được lấy theo hai cách: *chuỗi đúng* lấy từ nhãn (chỉ để chẩn đoán), và *chuỗi nhận ra* do F tự nhận ra từ video (các bước trước xem đủ

8 khung, bước hiện tại xem k khung). Mỗi câu hỏi được hỏi hai lần với thứ tự ứng viên đảo ngược, như giai đoạn 8c.

Bảng 4.22. Giai đoạn 8e: đoán bước tiếp theo (NEXT) theo cách hai bước kiểu AntGPT so với F (chọn đúng trong 5 câu, %, 2.503 bước, đoán mò 20%).

Cách làm	k	Chọn đúng (%)	F trừ cách này [CI 95%]
F (đoán thẳng từ ảnh)	2 / 8	27,8 / 32,1	—
AntGPT, chuỗi nhận ra từ video	2	27,3	$+0{,}5$ [$-2{,}0$; $+2{,}8$]
AntGPT, chuỗi nhận ra từ video	8	29,2	$+2{,}9$ [$+0{,}7$; $+4{,}9$]
AntGPT, chuỗi đúng (chẩn đoán)	—	**43,8**	$-11{,}7$ [$-14{,}3$; $-9{,}1$] ($k = 8$)

Bảng 4.22 cho thấy khi được đọc chuỗi hành động *đúng*, mô hình ngôn ngữ đoán bước tiếp theo đúng 43,8%, hơn F 11,7 điểm và hơn cả mức trần 38,4% khi được xem chính bước tiếp theo. Như vậy, hiểu biết về thứ tự các bước có ích thật. Nhưng khi chuỗi hành động do máy tự nhận ra từ video, độ chính xác chỉ còn 27,3–29,2%, bằng hoặc thấp hơn F (F hơn 2,9 điểm ở $k = 8$). Lý do là khâu nhận ra từng hành động còn yếu: chọn đúng câu WHAT của bước hiện tại trong tất cả các bước của video chỉ đạt 4–6%, nên chuỗi đưa cho mô hình ngôn ngữ phần lớn là sai. Kết quả này khẳng định lại nhận định ở trên: nút thắt của việc đoán trước là nhận ra đúng việc đang làm. Kết hợp điểm của F với điểm của cách này (trọng số chọn trong từng lần kiểm tra chéo như giai đoạn 8c) cũng không giúp: 27,4% ở $k = 2$ và 31,0% ở $k = 8$, so với 27,8% và 32,1% của F.

Kết luận giai đoạn 8

Cấu hình F của giai đoạn 3 gần như đã là tốt nhất cho phép chọn 1 trong 5 câu cùng video: chú trọng khung gần nhất, huấn luyện thêm lớp hiệu chỉnh hay dùng Qwen2.5-VL-3B đều không tăng rõ ở mọi k, và huấn luyện thêm còn làm kém đi 2–4 điểm. Có hai cải tiến dùng được. Thứ nhất, cộng thêm một nửa điểm không trừ khung cảnh làm MRR toàn tập tăng 10–21% mà không ảnh hưởng chọn 1/5, khắc phục điểm yếu đã nêu ở Mục 4.14. Thứ hai, khi đã xem hết bước, kết hợp F với Qwen tăng thêm 2,2 điểm. Ngoài ra, cùng mô-đun đoán được bước tiếp theo tốt hơn đoán mò (32,1% ở $k = 8$). Tuy vậy, so với cách làm cơ sở "nhận ra bước hiện tại rồi chép", mô-đun chỉ hơn khoảng 1,5 điểm khi đoán trước dưới 3 giây và ngang bằng khi đoán xa hơn: khả năng đoán trước hiện nay chủ yếu đến từ việc nhận ra việc đang làm. Muốn đoán trước thật sự, mô-đun cần thêm hiểu biết về thứ tự các bước: một mô hình ngôn ngữ đọc chuỗi hành động *đúng* đoán được bước tiếp theo 43,8%, nhưng với chuỗi do máy nhận ra thì chỉ còn 27–29%, nên trước hết cần nhận ra hành động hiện tại tốt hơn.

4.12. Giai đoạn 9: Số khung hình, độ dài đoạn nhìn và khâu nhận ra hành động

Giai đoạn 7 đo theo giây thật, nhưng ở đó số khung và độ dài đoạn nhìn luôn đi cùng nhau: xem 2 giây là 8 khung, xem 4 giây là 16 khung. Vì vậy chưa trả lời được câu hỏi "nếu lấy 12 hay 24 khung thì sao": kết quả thay đổi là do *số khung* hay do *độ dài đoạn nhìn*? Giai đoạn này tách hai yếu tố đó, đồng thời xem lại và thử cải thiện khâu nhận ra hành động hiện tại, nút thắt đã thấy ở giai đoạn 8. Các luật đánh giá được ghi trước khi chạy.

4.12.1. Tách số khung khỏi độ dài đoạn nhìn

Cách làm. Dùng lại các khung đã lấy ở 4 khung/giây của giai đoạn 7, cùng 5.710 thời điểm và cùng 5 câu ứng viên. Cố định độ dài đoạn nhìn $W \in \{2, 4, 8\}$ giây, rồi trong đoạn đó lấy N khung cách đều, luôn gồm khung mới nhất, với N từ 2 đến $4W$ ($N = 4W$ là lấy mọi khung, trùng với giai đoạn 7). Ngoài ra, chạy thêm đúng 12 và 24 khung liền nhau (3 và 6 giây). Phép kiểm tra đầu vào: với $N = 4W$, kết quả phải trùng giai đoạn 7, và đã trùng. Luật đặt trước: số khung được coi là *có ảnh hưởng* nếu, ở một độ dài W nào đó và khi đoán trước không quá 2 giây, hai mức N liền nhau khác nhau rõ từ 1 điểm trở

lên.

Bảng 4.23. Giai đoạn 9a: cố định độ dài đoạn nhìn W, thay số khung N lấy trong đoạn đó. Ô ghi tỉ lệ chọn đúng hành động sắp tới trong 5 câu cùng video khi đoán trước 0,5 / 2 giây (%, 5.710 thời điểm, 26 video, đoán mò 20%).

	Số khung N lấy trong đoạn				
Độ dài đoạn W	2	4	8	16	32
2 giây	36,7 / 34,2	36,3 / 34,5	35,9 / 34,4	—	—
4 giây	**36,8 / 34,7**	36,3 / 34,1	36,0 / 34,1	35,7 / 34,2	—
8 giây	35,9 / 33,6	35,4 / 33,8	34,7 / 33,3	34,3 / 33,2	34,3 / 33,2
Liền nhau: 12 khung (3 giây) 36,0 / 34,5; 24 khung (6 giây) 35,4 / 33,1					

Kết quả. Theo luật đặt trước, *độ dài đoạn nhìn quyết định, số khung thì không*. Trong cùng một đoạn, không có cặp N liền nhau nào khác nhau rõ từ 1 điểm khi đoán trước 0,5–2 giây (Bảng 4.23). Chỉ 2 khung rải trong 4 giây đã đạt 36,8%, ngang với 16 khung (35,7%). Ngược lại, kéo đoạn nhìn từ 4 lên 8 giây làm giảm khoảng 1 điểm ở mọi N. Câu hỏi 12 và 24 khung có câu trả lời trực tiếp: 12 khung cho đúng bằng 8 khung ($+0{,}0$ điểm $[-0{,}9; +0{,}9]$ khi đoán trước 0,5 giây), còn 24 khung kém 16 khung 1,1 điểm $[-2{,}2; -0{,}2]$ khi đoán trước 2 giây. Mức giảm này là do đoạn nhìn dài hơn (6 so với 4 giây), không phải do thêm khung.

Kết quả này khớp với nhận xét gốc của TSN [49]: các khung gần nhau gần như giống hệt nhau, nên lấy thưa là đủ. Với mô-đun lấy trung bình như F, thêm khung trong cùng một đoạn chỉ là lấy trung bình thêm các ảnh gần giống nhau, còn kéo dài đoạn thì trộn thêm các hành động đã qua. Ý nghĩa thực tế cho robot: mỗi lần cập nhật chỉ cần mã hóa vài khung, thay vì hàng chục.

4.12.2. Đo lại khâu nhận ra hành động hiện tại

Giai đoạn 8 thấy F nhận đúng câu WHAT của bước hiện tại, trong tất cả các bước của video, chỉ 4–6%. Cần biết con số này thấp đến đâu so với độ khó của bài. Mỗi video có trung vị 85 câu WHAT khác nhau (ít nhất 17, nhiều nhất 120) trên trung vị 99 bước, nên đoán mò chỉ đúng khoảng 1,2%; 4,0–6,2% (ở $k = 2$ đến 8) là gấp 3–5 lần đoán mò. So theo nội dung câu thay cho theo đúng dòng chỉ tăng khoảng 0,3 điểm, nên con số này không bị đánh giá thấp. Câu đúng nằm trong 5 câu điểm cao nhất của F ở 18,6–23,5% số bước, và trong 10 câu cao nhất ở 31,2–38,8%. Đây cũng là *trần* cho mọi cách chọn

lại trong danh sách rút gọn của F: nếu chỉ xét 5 câu đầu, khâu nhận ra không thể vượt 23,5% ở $k = 8$.

4.12.3. Nhận ra hành động tốt hơn rồi mới đoán bước tiếp theo

Cách làm. Giai đoạn 8 cho thấy mô hình ngôn ngữ đoán bước tiếp theo đúng 43,8% nếu biết chuỗi hành động đúng, nhưng chỉ 29,2% với chuỗi do F nhận ra. Phần này thử sửa đúng khâu nhận ra. Với mỗi bước, F chọn trước 5 câu WHAT khác nhau có điểm cao nhất trong video (danh sách rút gọn). Sau đó Qwen2.5-VL-3B *nhìn* các khung của bước và chọn lại 1 trong 5 câu đó, theo đúng cách hỏi trắc nghiệm của giai đoạn 8c (ảnh 448 điểm, hỏi hai lần với thứ tự đảo ngược). Có hai cách lấy nhãn: lấy câu Qwen chọn (*Qwen chọn lại*), hoặc cộng điểm của F và Qwen sau khi chuẩn hóa, với trọng số chọn trong từng lần kiểm tra chéo ($F + Qwen$). Chuỗi hành động mới được đưa vào đúng cách hỏi AntGPT cũ, không đổi câu hỏi, số bước lịch sử hay 5 câu ứng viên. Hai luật đặt trước: R1, khâu nhận ra phải tốt hơn F rõ ở $k = 8$; A1, dự đoán bước tiếp theo bằng chuỗi mới phải tốt hơn F rõ ở $k = 8$.

Bảng 4.24. Giai đoạn 9c: Qwen2.5-VL-3B chọn lại trong 5 câu đầu của F. Trên: nhận đúng câu WHAT của bước hiện tại trong tất cả các bước của video (%, đoán mò khoảng 1,2%). Dưới: đoán bước tiếp theo trong 5 câu cùng video ở $k = 8$ (%, đoán mò 20%). [ ]: hiệu so với F, khoảng tin cậy 95%.

Nhận ra bước hiện tại		
Cách làm	$k = 2$	$k = 8$
Trần (câu đúng nằm trong 5 câu đầu)	18,6	23,5
F	4,0	6,2
Qwen chọn lại	4,6 (+0,6 [−0,5; +1,5])	8,2 (+2,0 [+0,8; +3,3])
F + Qwen	4,3 (+0,3 [−0,5; +1,2])	**8,3** (+2,1 [+1,0; +3,3])
Đoán bước tiếp theo ($k = 8$)		
Cách làm	Chọn đúng	So với F
F	**32,1**	—
AntGPT, chuỗi cũ do F nhận ra	29,2	−2,9 [−4,9; −0,7]
AntGPT, chuỗi Qwen chọn lại	30,2	−1,8 [−3,5; −0,1]
AntGPT, chuỗi F + Qwen	30,1	−2,0 [−4,1; +0,5]
F + AntGPT (chuỗi F + Qwen)	32,6	+0,5 [−0,9; +1,9]
AntGPT, chuỗi đúng (chẩn đoán)	43,8	+11,7 [+9,1; +14,3]

Kết quả. R1 đạt: khi xem đủ 8 khung, Qwen chọn lại làm khâu nhận ra tăng rõ từ 6,2% lên 8,3% (+2,1 điểm, khoảng tin cậy từ +1,0), tức tăng khoảng một phần ba.

Khi mới xem 2 khung thì không tăng rõ. A1 không đạt: với chuỗi mới, AntGPT đoán bước tiếp theo 30,1–30,2%, hơn chuỗi cũ khoảng 1 điểm nhưng vẫn kém F, và cộng với F cũng chỉ ngang F (32,6% so với 32,1%). Lý do nằm ở khoảng cách còn lại: với 8,3%, hơn 9 trên 10 bước trong chuỗi vẫn bị nhận sai, trong khi mô hình ngôn ngữ chỉ phát huy khi chuỗi gần như đúng (43,8%). Danh sách rút gọn của F cũng đặt trần 23,5%, nên mọi cách chọn lại trong 5 câu đầu, dù hoàn hảo, vẫn để sai hơn ba phần tư số bước. Như vậy, muốn đoán bước tiếp theo nhờ thứ tự các bước, khâu nhận ra cần tốt hơn nhiều lần chứ không chỉ vài điểm; một mô hình thị giác–ngôn ngữ nhỏ dùng nguyên là chưa đủ.

4.12.4. Vì sao không dùng các mô hình video góc nhìn thứ nhất

Một hướng tự nhiên để nhận ra hành động tốt hơn là thay SigLIP bằng mô hình video–chữ học trên video góc nhìn thứ nhất như EgoVLP [26] hoặc LaViLa [56]. Đồ án đã kiểm tra và quyết định *không* dùng, vì một lý do chính. EgoIntent được dựng từ 32 video Ego4D, và mã video của nó chính là mã Ego4D. Cả LaViLa lẫn EgoVLP đều học trước trên Ego4D (LaViLa trên lời tường thuật của Ego4D, EgoVLP trên EgoClip dựng từ Ego4D), và không công bố đã loại những video nào. Như vậy các video của EgoIntent, kể cả tập test riêng, có thể đã được các mô hình này xem cùng lời mô tả khi học trước: kết quả trên EgoIntent sẽ không còn đáng tin. SigLIP học trên ảnh–chú thích lấy từ web, không học trên Ego4D, nên không có rủi ro này. Ngoài ra, cả ba mô hình đều cần phiên bản PyTorch và thư viện cũ (torch 1.10–1.13), không chạy chung môi trường với SmolVLA. Muốn dùng chúng một cách công bằng, trước hết phải đối chiếu 32 mã video của EgoIntent với danh sách video học trước của từng mô hình.

Kết luận giai đoạn 9

Số khung hình không quan trọng bằng độ dài đoạn nhìn. Trong cùng một đoạn, 2, 4, 8 hay 16 khung cho kết quả như nhau, và 12 khung bằng đúng 8 khung. Đoạn nhìn dài hơn 4 giây làm kém đi khoảng 1 điểm. Như vậy, nguyên lý lấy mẫu thưa, cách đều của TSN áp dụng được, và robot chỉ cần mã hóa vài khung cho mỗi lần đoán. Khâu nhận ra hành động hiện tại đạt gấp 3–5 lần đoán mò. Cho Qwen2.5-VL-3B chọn lại trong 5 câu đầu của F làm khâu này tăng rõ từ 6,2% lên 8,3%, nhưng vẫn quá thấp để mô hình ngôn ngữ đoán bước tiếp theo tốt hơn F (30,1% so với 32,1%); và vì chỉ 23,5% số bước có câu đúng trong 5 câu đầu, mọi cách chọn lại trong danh sách này đều bị giới hạn. Các mô hình video học trên Ego4D không được dùng vì có nguy cơ đã thấy chính dữ liệu kiểm tra.

4.13. Tổng hợp các giai đoạn

Bảng 4.25 tóm tắt các giai đoạn. Mạch chung: tự huấn luyện trên dữ liệu nhỏ không đủ (giai đoạn 0–1); dùng mô hình đã liên kết sẵn ảnh với chữ cho tín hiệu rõ (giai đoạn 2); trừ phần khung cảnh chung và dùng bộ mã hóa lớn hơn vượt ngưỡng 30% (giai đoạn 3) và giữ được ưu thế trên video mới (giai đoạn 4); độ chắc chắn cho robot biết khi nào hỏi lại (giai đoạn 5); chỗ cần đưa ý định vào robot là chỗ của câu lệnh (giai đoạn 6); từ 8 khung gần nhất, mô-đun đoán trước được hành động sắp tới, độ chính xác giảm dần đến khoảng 12 giây rồi đi ngang (giai đoạn 7); các cách cải thiện thêm không vượt rõ cấu hình đã chốt, trừ việc kết hợp hai cách tính điểm giúp xếp hạng toàn tập (giai đoạn 8); và độ dài đoạn nhìn, chứ không phải số khung, quyết định kết quả (giai đoạn 9).

4.14. Thảo luận

4.14.1. Vì sao backbone của VLA không đọc được ý định

Giai đoạn 0 và 1 cho cùng một kết quả theo hai cách khác nhau: trên tập nhỏ, không mô hình huấn luyện nào trên đặc trưng SmolVLM2 vượt rõ cách lấy trung bình khung; trên toàn bộ dữ liệu với kiểm tra chéo, lớp đọc chỉ gấp 1,13–1,19 lần mức ngẫu nhiên. Có hai nguyên nhân cùng lúc. Thứ nhất, đặc trưng ảnh trong SmolVLM2 được huấn luyện để *mô hình ngôn ngữ đọc*, không phải để đặt cạnh câu mô tả trong một không gian so sánh được (Mục 2.3); muốn dùng nó phải học thêm một ánh xạ ảnh–chữ. Thứ hai, với khoảng hai nghìn bước và gần như mỗi bước một câu WHY riêng (2.032 câu trên 2.503

bước), dữ liệu không đủ để học ánh xạ đó; các mô hình lớn hơn chỉ học thuộc nhanh hơn (Transformer ở thí nghiệm 0B). SigLIP đã học ánh xạ ảnh–chữ từ hàng trăm triệu cặp [52], nên dùng nguyên đã tốt hơn gấp đôi lớp đọc ở MRR. Kết quả này có ý nghĩa cho thiết kế VLA: không nên giả định backbone của chính sách tự chứa thông tin về ý định người; nguồn ý định nên là một mô-đun riêng, nối vào qua một giao diện hẹp như token ý định.

4.14.2. Vì sao trừ khung cảnh chung có ích, và cái giá của nó

Bằng chứng ở giai đoạn 3 cho thấy bước trừ khung cảnh của các bước trước là một trong hai thành phần chính của cấu hình đề xuất: SigLIP lớn không có bước này chỉ đạt 31,1–33,0% (so với 34,1–38,7%), còn SigLIP cơ bản có thêm bước này đạt 29,1–32,1% (so với 27,5–28,9%). Điều này khớp với phân tích lỗi: ở giai đoạn 0, 81,5% lỗi là nhầm bước trong cùng tác vụ; ở giai đoạn 2, SigLIP cơ bản nhận đúng hoạt động nhào bột nhưng xếp câu đúng xuống cuối. Khi mọi khung của video có chung bàn, chậu, tay và bột, phần chung này lấn át phần khác biệt giữa các bước; trừ nó đi làm phần khác biệt nổi lên, đúng như phân tích về thành phần chung trong không gian biểu diễn [25].

Cái giá là thông tin "đang ở khung cảnh nào" cũng bị trừ đi. Khi xếp hạng giữa câu của nhiều video (MRR toàn tập), thông tin này có ích, nên MRR toàn tập của cấu hình đề xuất không tăng rõ ở kiểm tra chéo và giảm trên tập test riêng. Với robot cộng tác, robot đã biết mình đang ở đâu và người đang làm hoạt động gì; câu hỏi khó là bước nào. Vì vậy đồ án ưu tiên phép chọn 1 trong 5 cùng video. Giai đoạn 8 cho thấy cái giá này lấy lại được: cộng thêm một nửa điểm không trừ khung cảnh làm MRR toàn tập tăng 10–21% mà chọn 1/5 không đổi (Bảng 4.19).

4.14.3. Kết quả trên tập test riêng

Trên tập test riêng, cả cấu hình đề xuất lẫn cấu hình cơ bản đều thấp hơn kiểm tra chéo. Vì cấu hình cơ bản không có tham số nào được chọn trên dữ liệu phát triển mà vẫn giảm 5,7–7,5 điểm, phần lớn mức giảm có vẻ đến từ việc tập test khó hơn, không chỉ do việc chọn cấu hình. Với 4 video, chưa thể tách hai nguyên nhân này. Điều quan trọng là *hiệu* giữa hai cấu hình trên cùng các bước giữ được ở $k = 4, 6, 8$, với khoảng tin cậy trên 0, và phép kiểm tra đổi khung hình cho kết quả cùng chiều. Đây là lý do đồ án báo cáo cả hai con số (kiểm tra chéo và tập test) thay vì chỉ con số tốt hơn.

4.14.4. Ý nghĩa cho robot cộng tác

Độ chính xác 30% nghĩa là nếu trả lời mọi lúc, robot vẫn chọn sai phần lớn các trường hợp. Giai đoạn 5 cho thấy cách dùng thực tế hơn: robot chỉ hành động khi độ chênh đủ lớn, và chờ thêm hoặc hỏi lại trong các trường hợp còn lại. Ở 20% độ phủ, độ chính xác đạt 53–61%; ở 50% độ phủ, tăng 6,9–7,9 điểm so với trả lời mọi lúc. Điểm tin cậy chỉ hữu ích khi bộ mã hóa đủ tốt: với cấu hình cơ bản, mức tăng tương ứng chỉ 2,6–3,5 điểm. Nói cách khác, cải thiện mô-đun ý định không chỉ tăng độ chính xác mà còn làm robot biết mình sai khi nào. Giai đoạn 7 đặt giới hạn cho điều này: độ chênh điểm cho biết lựa chọn nào chắc hơn *ở cùng một khoảng đoán trước*, nhưng không cho biết robot đang đoán quá xa. Với robot thật, điều này gợi ý chỉ dựa vào dự đoán trong khoảng 10 giây tới, và cập nhật liên tục khi có thêm khung hình mới.

Bảng 4.26 gom các kết quả trên thành bốn tình huống mà robot cộng tác sẽ gặp, cùng cách hệ thống nên xử lý và bằng chứng đã có cho từng tình huống.

Tình huống C1 và C2 đã có cơ chế xử lý dựa trên độ chênh điểm. C3 và C4 thì chưa: độ chênh điểm không cho biết mục tiêu đã sai hay đang đoán quá xa. Đây là hai điểm cần giải quyết trước khi dùng mô-đun ý định trên robot thật (Mục 4.14.5).

4.14.5. Những yếu tố có thể ảnh hưởng tới kết luận

- **Câu đồng nghĩa bị tính là sai.** Các câu WHY viết tự do; 44,5% số bước có một câu khác trong cùng video gần như cùng nghĩa (cosine $\geq 0{,}9$ theo MiniLM [39]). Một số lỗi vì vậy không phải lỗi thật, và độ chính xác tuyệt đối bị chặn trên.
- **Số video nhỏ.** 27 video, 13 khung cảnh để phát triển và 4 video để test. Khoảng tin cậy theo video phản ánh điều này, nhưng các kết luận về khung cảnh cụ thể (ví dụ hiên nhà, phòng giặt) dựa trên rất ít video.
- **Một bộ dữ liệu, một ngôn ngữ.** Mọi câu ứng viên là tiếng Anh từ EgoIntent. Chưa kiểm tra trên video tự quay hoặc câu tiếng Việt.
- **Thí nghiệm robot nhỏ.** Một checkpoint, 10 lượt mỗi nhiệm vụ. Hai lần đánh giá cùng checkpoint cho 24/100 và 19/100, đều nằm trong khoảng tin cậy của nhau, nên mọi so sánh phía robot sau này cần cùng vị trí ban đầu và cùng hạt giống như Mục 4.9.2.

Bảng 4.25. Tóm tắt các giai đoạn thực nghiệm. "Chọn 1/5": tỉ lệ chọn đúng mục đích trong 5 câu cùng video (đoán mò 20%).

GĐ	Cách làm	Kết quả chính	Quyết định
0	Nhiều mô hình trên tập nhỏ; sửa lỗi 6 chiều ở LIBERO	Tốt nhất 0,0551–0,0589 MRR (ngẫu nhiên 0,0420); 81,5% lỗi nhầm bước	Dùng toàn bộ dữ liệu, kiểm tra chéo, chọn 1/5
1	Lớp đọc trên SmolVLM2	MRR gấp 1,13–1,19 lần ngẫu nhiên; chọn 1/5: 21,9–23,0%	Thử mô hình đã liên kết ảnh–chữ
2	SigLIP cơ bản, không huấn luyện	Gấp 2,25–2,57 lần; chọn 1/5: 27,5–28,9%	Bỏ khung cảnh chung, thử bộ mã hóa lớn hơn
3	Chọn 1 trong 90 cấu hình	Chọn 1/5: 34,1–38,7%, cùng cấu hình 8/8 lần	Ghi cố định cấu hình
4	Tập test riêng, chạy một lần	30,2% so với 21,4% (8 khung)	Xét độ chắc chắn
5	Trả lời khi đủ chắc	+6,9–7,9 điểm ở 50% độ phủ	Nối vào robot
6	Token ý định trong SmolVLA; LIBERO	7/7 kiểm thử đạt; lệnh đúng 19/100, rỗng 0/100; chỉ token ý định 20/100, ý định sai 0/100	Thay ý định đúng bằng ý định đoán từ video
7	Đoán hành động sau H khung, H từ 0,6 đến 20,5 s	38,0% (0,6 s) xuống 27,7% (7,7 s); theo giây thật đi ngang từ 12 s; xem dài hơn 4 s không giúp; độ chênh gần như không đổi	Ngưỡng hành động phải tính cả khoảng đoán trước
8	Gộp khung, lớp hiệu chỉnh, Qwen2.5-VL-3B, đoán NEXT, so với cách làm cơ sở	Chọn 1/5 không tăng rõ; hiệu chỉnh −2,0–4,0 điểm; MRR +10–21%; NEXT 27,8–32,1%; đoán trước gần bằng "nhận ra rồi chép"	Giữ F, thêm điểm không trừ khung cảnh khi xếp hạng toàn tập
9	Cố định đoạn nhìn, thay số khung; đo lại khâu nhận ra	2–16 khung như nhau (36,8% với 2 khung/4 s); 12 khung = 8 khung; đoạn >4 s kém ∼1 điểm; nhận ra bước hiện tại 4–6% (đoán mò 1,2%), Qwen chọn lại lên 8,3% nhưng NEXT không hơn F (30,1 so với 32,1%)	Chỉ cần vài khung; nhận ra hành động cần tốt hơn nhiều lần; không dùng mô hình học trên Ego4D

Bảng 4.26. Bốn tình huống ý định, cách xử lý đề xuất và bằng chứng trong đồ án (chọn 1 trong 5 câu cùng video, 27 video phát triển).

Tình huống	Dấu hiệu	Robot nên	Bằng chứng
C1. Rõ ràng	Độ chênh điểm cao (20% trường hợp chắc nhất)	Hành động theo ý định đã chọn	Đúng 53,3–60,9%, so với 34,1–38,7% khi trả lời mọi lúc (Bảng 4.11)
C2. Mơ hồ	Độ chênh thấp; câu gần nghĩa với bước khác	Chờ thêm khung hình hoặc hỏi lại người	Nửa ít chắc nhất chỉ đúng khoảng 27–32%; 44,5% số bước có câu gần cùng nghĩa trong cùng video
C3. Ý định sai	Mục tiêu đưa vào robot không khớp việc người đang làm	Không hành động; cần cơ chế phát hiện và sửa	Đổi khung hình sang video khác: 39,6% rơi về 18,8%; SmolVLA với lệnh của nhiệm vụ khác: 0/100 lượt hoàn thành nhiệm vụ đúng (Bảng 4.14)
C4. Đoán xa hoặc người đổi ý	Hành động cần đoán còn ở xa phía trước	Chỉ tin dự đoán trong khoảng 10 giây tới và cập nhật liên tục	Độ chính xác giảm từ 38,0% (0,6 s) xuống 24,0% (20,5 s) nhưng độ chênh gần như không đổi (Bảng 4.16); trường hợp người đổi ý giữa chừng chưa được đo

KẾT LUẬN

Kết quả chính

Đồ án nghiên cứu cách tăng cường khả năng hiểu ý định người dùng cho robot cộng tác dựa trên mô hình VLA, theo hướng bổ sung cho SmolVLA một mô-đun ý định đọc video góc nhìn thứ nhất của người. Qua chín giai đoạn thực nghiệm nối tiếp, đồ án đạt được các kết quả sau:

1. **Xác định được giới hạn của cách tiếp cận huấn luyện trên dữ liệu nhỏ.** Trên tập thử 8 video, hơn mười cấu hình huấn luyện (học tương phản, mô hình theo thời gian, học phụ WHAT/NEXT, dẫn đường bằng WHAT, học từ hai góc nhìn) đều không vượt rõ cách lấy trung bình 8 khung; 81,5% lỗi là nhầm bước trong cùng tác vụ. Kết quả này định hình cách đánh giá của các giai đoạn sau.
2. **Chỉ ra rằng backbone của VLA không đủ để đọc ý định.** Lớp đọc huấn luyện trên đặc trưng SmolVLM2 chỉ gấp 1,13–1,19 lần mức ngẫu nhiên khi kiểm tra chéo theo khung cảnh, với khoảng tin cậy chứa mức ngẫu nhiên.
3. **Xây dựng mô-đun ý định không cần huấn luyện**, dùng SigLIP lớn và trừ khung cảnh của các bước trước. Mô-đun đạt 34,1–38,7% chọn đúng trong 5 câu cùng video khi kiểm tra chéo, được chọn ổn định 8/8 lần, và đạt 30,2% trên tập test riêng chạy một lần (so với 21,4% của cấu hình cơ bản và 20% của đoán mò).
4. **Cho robot cơ chế biết khi nào nên hỏi lại.** Chỉ trả lời một nửa số trường hợp chắc nhất làm độ chính xác tăng 6,9–7,9 điểm; chỉ trả lời 20% thì đạt 53–61%.
5. **Token ý định thay được câu lệnh.** SmolVLA gốc phụ thuộc hoàn toàn vào câu lệnh (19/100 với câu lệnh đúng, 0/100 khi bỏ câu lệnh). Huấn luyện lại với câu lệnh luôn để trống và nhiệm vụ đưa vào qua token ý định, robot đạt 20/100, còn ý định sai cho 0/100.
6. **Đo được robot đoán trước được bao xa.** Chỉ từ 8 khung gần nhất, mô-đun chọn đúng hành động sắp tới 38,0% khi đoán trước 0,6 giây và 27,7% khi đoán trước 7,7 giây. Đo lại theo giây thật (4 khung/giây), độ chính xác đi ngang từ khoảng 12 giây, và cho mô-đun xem đoạn dài hơn 4 giây không giúp. Độ chắc chắn gần như không đổi theo khoảng đoán trước, nên robot cần tính cả khoảng đoán trước khi quyết định hành động.

7. **Kiểm tra được giới hạn của cấu hình đề xuất.** Huấn luyện thêm một lớp hiệu chỉnh với mẫu âm cùng video làm kém đi 2,0–4,0 điểm; Qwen2.5-VL-3B không huấn luyện đạt 30,8% ($k = 2$) và 39,8% ($k = 8$), không hơn rõ cấu hình đề xuất. Cộng thêm điểm không trừ khung cảnh làm MRR toàn tập tăng 10–21% mà không ảnh hưởng chọn 1/5, và cùng mô-đun đoán đúng bước tiếp theo 27,8–32,1% (đoán mò 20%). So với các cách làm cơ sở của bài toán dự đoán hành động, mô-đun hơn rõ cách không xem video nhưng gần bằng cách nhận ra bước hiện tại rồi chép sang, nên khâu nhận ra hiện tại là nút thắt.

Đánh giá kết quả đạt được

So với mục tiêu ở Mục 1.3, mục tiêu thứ nhất (xây dựng mô-đun ý định vượt ngưỡng thực dụng 30%) đã đạt ở kiểm tra chéo với mọi k và đạt đúng ngưỡng trên tập test riêng ở $k = 8$; ở k nhỏ hơn, mô-đun vẫn hơn đoán mò rõ ràng nhưng chưa tới 30%. Mục tiêu thứ hai (nối mô-đun ý định vào VLA) đã hoàn thành: token ý định thay được câu lệnh với tỉ lệ thành công ngang câu lệnh thật; phần còn thiếu là nối đầu ra của mô-đun ý định (đoán từ video người) vào token này. Về phương pháp, mọi con số đều đến từ dữ liệu không dùng để chọn cấu hình, có khoảng tin cậy theo video, và tập test chỉ chạy một lần, nên các kết luận có độ tin cậy cao hơn các kết quả ban đầu trên tập nhỏ. Các kết quả âm (huấn luyện trên dữ liệu nhỏ, học từ hai góc nhìn, dừng sớm, tham khảo láng giềng, cắt vùng tay) cũng được ghi lại đầy đủ vì chúng giải thích vì sao phương pháp cuối cùng có dạng như vậy.

Hạn chế

- **Ý định đưa cho robot vẫn là ý định đúng.** Token ý định thay được câu lệnh, nhưng vector ý định được tạo từ mô tả đúng của nhiệm vụ; chưa thử với ý định do mô-đun đoán từ video, vì LIBERO không có video người tương ứng.
- **Độ chính xác còn thấp.** 30% trên tập test riêng nghĩa là robot vẫn chọn sai phần lớn các trường hợp nếu trả lời mọi lúc.
- **Dữ liệu nhỏ.** 27 video, 13 khung cảnh để phát triển và 4 video để test, nên khoảng tin cậy trên tập test còn rộng.
- **Xếp hạng toàn tập.** Bước trừ khung cảnh chung giúp phân biệt các bước cùng video nhưng làm giảm MRR toàn tập trên tập test. Cách kết hợp hai điểm ở giai đoạn 8 khắc phục được điều này khi kiểm tra chéo, nhưng chưa được kiểm tra trên một tập test mới vì tập test riêng đã dùng hết.

- **Chỉ thử một mô hình ngôn ngữ–thị giác nhỏ.** Qwen2.5-VL-3B với một câu hỏi cố định, ở hai giá trị k; bản 7B không vừa GPU 16 GB.
- **Câu đồng nghĩa bị tính là sai.** 44,5% số bước có một câu khác trong cùng video gần như cùng nghĩa, nên điểm tuyệt đối bị chặn trên.
- **Thí nghiệm LIBERO nhỏ.** Một hạt giống huấn luyện, một checkpoint, 10 lượt mỗi nhiệm vụ, trong mô phỏng; bản token ý định và bản câu lệnh là hai mô hình huấn luyện riêng.
- **Dòng thời gian ở giai đoạn 7 bỏ qua khoảng trống giữa các bước.** Phép đo theo giây thật đã thay cho cách suy thời gian từ độ dài bước, nhưng các đoạn video của từng bước được nối liền nhau, nên khoảng trống giữa hai bước (nếu có) không được tính. Chỉ thử một mật độ gốc 4 khung/giây (lấy thưa hơn trong đó ở giai đoạn 9) và một cách gộp là lấy trung bình.
- **Chưa so với mô hình video học trên Ego4D.** EgoIntent dựng từ video Ego4D, nên LaViLa và EgoVLP có nguy cơ đã thấy dữ liệu kiểm tra khi học trước; việc đối chiếu mã video chưa được làm (Mục 4.12.4).

Hướng phát triển

Bước tiếp theo: nối mô-đun ý định với robot. Giai đoạn 6 cho thấy token ý định thay được câu lệnh khi ý định là đúng. Bước tiếp theo là thay vector ý định "đúng" bằng ý định robot tự chọn từ video người: video $\rightarrow$ mô-đun ý định $\rightarrow$ token ý định $\rightarrow$ hành động. Hai thí nghiệm làm được ngay trên LIBERO: (i) đưa cho robot vector của một câu nói *mục đích* thay cho mô tả nhiệm vụ, để xem robot có hiểu ý định khi người không ra lệnh cụ thể không; (ii) đưa ý định đúng với xác suất bằng độ chính xác của mô-đun, kết hợp với cơ chế hỏi lại của giai đoạn 5, để ước lượng tỉ lệ thành công của cả hệ thống. Về lâu dài, cần dữ liệu có cả video người và nhiệm vụ robot tương ứng, như bộ dữ liệu tự thu dưới đây.

Song song, cải thiện mô-đun ý định (chỉ bằng kiểm tra chéo, không dùng lại tập test riêng):

- Làm cho độ chắc chắn biết theo khoảng đoán trước, vì giai đoạn 7 cho thấy độ chênh điểm gần như không đổi khi phải đoán xa: ví dụ ngưỡng hành động riêng cho từng khoảng đoán trước, hoặc chỉ hành động trong khoảng 10 giây đầu.
- Cải thiện khâu nhận ra hành động hiện tại, vì giai đoạn 8e cho thấy với chuỗi hành động đúng, cách hai bước kiểu AntGPT [55] đạt 43,8% nhưng với chuỗi do máy

nhận ra chỉ còn 27–29%. Giai đoạn 9c cho thấy chọn lại bằng Qwen2.5-VL-3B chỉ nâng khâu này từ 6,2% lên 8,3%, chưa đủ; cần nhận ra tốt hơn nhiều lần, ví dụ bằng mô hình video góc nhìn thứ nhất sau khi đã loại các video trùng với Ego4D, hoặc bằng dữ liệu tự thu có nhãn hành động.

- Cho mô-đun xem đoạn lịch sử dài hơn 8 khung khi đoán bước tiếp theo, vì giai đoạn 8 cho thấy độ chính xác đoán NEXT còn cách mức trần khoảng 6 điểm ở $k = 8$.
- Dùng kết hợp F với mô hình ngôn ngữ–thị giác (giai đoạn 8) như một bước kiểm tra lại khi đã xem hết bước, và thử bản lớn hơn khi có GPU đủ bộ nhớ.
- Không đi tiếp hướng huấn luyện thêm trên SigLIP với dữ liệu hiện có: giai đoạn 0 và 8 đều cho thấy nó làm kém đi; chỉ quay lại khi có thêm dữ liệu.

Dữ liệu tự thu. Đồ án đã thiết kế một bộ dữ liệu nhỏ theo kịch bản "trà chiều cùng robot" (mời robot vào bàn, chọn cốc, chia bánh, sắp xếp bàn, đổi ý giữa chừng, dọn dẹp). Mỗi lần quay, người thực hiện bốc thăm một mục tiêu bí mật; các mục tiêu khác nhau mở đầu bằng cùng một động tác, và mục tiêu không được nói ra. Bộ dữ liệu này sẽ là tập test độc lập mới, và là bước đệm để đánh giá trên robot UR5. [CẦN ĐIỀN: Số người tham gia và số video đã quay, nếu có.]

PHỤ LỤC

Phụ lục A. Các cấu hình tốt nhất trong 90 cấu hình của giai đoạn 3

Bảng PL.1 liệt kê 10 cấu hình có độ chính xác chọn 1 trong 5 trung bình cao nhất trên toàn bộ 2.503 bước. Các số này chỉ để mô tả, không hiệu chỉnh cho việc chọn; con số báo cáo chính thức là kết quả chọn lồng nhau ở Bảng 4.9. Bảng PL.2 lấy trung bình theo từng lựa chọn. Bộ mã hóa và cách xử lý vector ảnh tạo khác biệt lớn nhất; cách gộp khung và câu mẫu gần như không đổi kết quả.

Bảng PL.1. Mười cấu hình đứng đầu theo độ chính xác chọn 1 trong 5 (%), toàn bộ 2.503 bước, không hiệu chỉnh cho việc chọn.

Bộ mã hóa	Gộp	Xử lý	Câu	$k = 2$	$k = 4$	$k = 6$	$k = 8$
SigLIP lớn	Trung bình	Bước trước	Câu mẫu	34,1	34,9	36,2	38,7
SigLIP lớn	Giống nhất	Bước trước	Câu mẫu	33,8	35,2	36,4	37,1
SigLIP lớn	Trung hòa	Bước trước	Câu mẫu	34,0	34,7	36,3	37,6
SigLIP lớn	Trung hòa	Bước trước	Nguyên câu	33,8	33,8	35,3	37,7
SigLIP lớn	Giống nhất	Bước trước	Nguyên câu	34,0	33,8	35,3	36,7
SigLIP lớn	Trung bình	Bước trước	Nguyên câu	33,7	33,8	34,9	37,1
SigLIP base-384	Trung hòa	Bước trước	Câu mẫu	30,4	32,0	33,1	34,9
SigLIP 2 base	Trung hòa	Bước trước	Nguyên câu	31,0	31,4	32,9	34,8
SigLIP 2 base	Trung bình	Bước trước	Câu mẫu	30,4	31,5	33,1	35,0
SigLIP 2 base	Trung bình	Bước trước	Nguyên câu	31,1	31,9	32,8	34,1

Phụ lục B. Kết quả LIBERO-10 theo từng nhiệm vụ

Bảng PL.3 so hai lần đánh giá của cùng checkpoint SmolVLA (hành động 7 chiều, 25.000 bước): lần đánh giá chuẩn đầu tiên (giai đoạn 0) và lần đánh giá với vị trí ban đầu và hạt giống cố định theo lượt (giai đoạn 6).

Phụ lục C. Chi tiết thí nghiệm học từ hai góc nhìn trên ENIGMA-360

Thí nghiệm 0D dùng 5 video huấn luyện (mã 54–58) của ENIGMA-360 [37]. Mỗi đoạn hành động được ánh xạ thành hai mẫu (nhìn thứ nhất, nhìn thứ ba) chung một mã cặp; trường WHAT lấy từ mô tả hành động, còn WHY để trống vì bộ dữ liệu không có nhãn mục đích. Tám khung được lấy đều trong mỗi đoạn và mã hóa bằng SmolVLM2, được 866 mẫu (433 cặp đầy đủ; 94, 222, 242, 74 và 234 mẫu cho từng video), không có

Bảng PL.2. Độ chính xác chọn 1 trong 5 (%) trung bình theo từng lựa chọn, lấy trung bình trên các cấu hình còn lại và trên k.

Thành phần	Lựa chọn	Trung bình
Bộ mã hóa	SigLIP cơ bản (base-224)	29,1
	SigLIP base-384	30,2
	SigLIP 2 base-224	30,6
	SigLIP lớn (so400m-384)	**33,1**
	CLIP ViT-L/14	28,9
Xử lý vector ảnh	Không xử lý	29,3
	Trừ trung bình chung	29,6
	Trừ khung cảnh của các bước trước	**32,2**
Gộp khung	Trung bình	30,3
	Khung giống nhất	30,4
	Trung hòa	30,4
Câu	Nguyên câu	30,3
	Câu mẫu	30,5

giá trị lỗi.

Với đặc trưng gốc, ghép đúng cặp gần như ngẫu nhiên: MRR 0,0181 (thứ nhất sang thứ ba) và 0,0155 (ngược lại), so với 0,0154 của ngẫu nhiên; độ tương đồng trung bình của cặp đúng (0,9819) gần như bằng của cặp sai (0,9818). Sau khi học một lớp chiếu chung nhỏ, với video 54–56 để huấn luyện và 57–58 để kiểm tra, MRR ghép cặp đạt $0{,}096 \pm 0{,}007$ và $0{,}086 \pm 0{,}007$ (ngẫu nhiên 0,036), và MRR theo cùng hành động đạt $0{,}237 \pm 0{,}007$ và $0{,}229 \pm 0{,}022$ (ngẫu nhiên 0,131). Lần huấn luyện dùng làm điểm khởi đầu ở thí nghiệm 0D đạt MRR ghép cặp $0{,}118 \pm 0{,}006$ và $0{,}100 \pm 0{,}010$ trên phần giữ lại. Học ghép hai góc nhìn vì vậy khả thi trên video chưa thấy; nhưng như Mục 4.3 cho thấy, nó không giúp đoán mục đích trên EgoIntent.

Bảng PL.3. Số lượt thành công trên 10 lượt cho từng nhiệm vụ LIBERO-10.

Nhiệm vụ	Câu lệnh	Lần đầu	Lệnh đúng	Lệnh rỗng / sai
0	put both the alphabet soup and the tomato sauce in the basket	0	0	0 / 0
1	put both the cream cheese box and the butter in the basket	0	1	0 / 0
2	turn on the stove and put the moka pot on it	4	3	0 / 0
3	put the black bowl in the bottom drawer of the cabinet and close it	8	7	0 / 0
4	put the white mug on the left plate and put the yellow and white mug on the right plate	0	1	0 / 0
5	pick up the book and place it in the back compartment of the caddy	7	3	0 / 0
6	put the white mug on the plate and put the chocolate pudding to the right of the plate	2	3	0 / 0
7	put both the alphabet soup and the cream cheese box in the basket	0	0	0 / 0
8	put both moka pots on the stove	0	0	0 / 0
9	put the yellow and white mug in the microwave and close it	3	1	0 / 0
	Tổng	24/100	19/100	0/100

Tiếng Anh

TÀI LIỆU THAM KHẢO

[1] I. Alabdulmohsin, X. Zhai, A. Kolesnikov, L. Beyer, "Getting ViT in shape: Scaling laws for compute-optimal model design", *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[2] S. Bai, K. Chen, X. Liu, et al., "Qwen2.5-VL technical report", *arXiv preprint arXiv:2502.13923*, 2025.

[3] K. Black, N. Brown, D. Driess, et al., "π_0: A vision-language-action flow model for general robot control", *arXiv preprint arXiv:2410.24164*, 2024.

[4] X. Bouthillier, P. Delaunay, M. Bronzi, et al., "Accounting for variance in machine learning benchmarks", *Proceedings of Machine Learning and Systems (MLSys)*, 2021.

[5] A. Brohan, N. Brown, J. Carbajal, et al., "RT-1: Robotics Transformer for real-world control at scale", *Robotics: Science and Systems (RSS)*, 2023.

[6] R. Cadene, et al., "LeRobot: An open-source library for end-to-end robot learning", *International Conference on Learning Representations (ICLR)*, 2026.

[7] R. Caruana, "Multitask learning", *Machine Learning*, Vol. 28, No. 1, 1997, pp. 41–75.

[8] G. C. Cawley, N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation", *Journal of Machine Learning Research*, Vol. 11, 2010, pp. 2079–2107.

[9] K. Cho, B. van Merriënboer, C. Gulcehre, et al., "Learning phrase representations using RNN encoder–decoder for statistical machine translation", *Proceedings of EMNLP*, 2014, pp. 1724–1734.

[10] C. K. Chow, "On optimum recognition error and reject tradeoff", *IEEE Transactions on Information Theory*, Vol. 16, No. 1, 1970, pp. 41–46.

[11] Q. Chu, H. Zhang, M. Liu, Y. Feng, H. Shi, L. Nie, "Intention-guided cognitive reasoning for egocentric long-term action anticipation", *Proceedings of the AAAI Conference on Artificial Intelligence*, 2026.

[12] D. Damen, H. Doughty, G. M. Farinella, et al., "Scaling egocentric vision: The EPIC-KITCHENS dataset", *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018, pp. 720–736.

[13] B. Efron, R. J. Tibshirani, *An Introduction to the Bootstrap*, Chapman & Hall, New York, 1993.

[14] EgoIntent, "EgoIntent: An open-ended benchmark for intent understanding at pre-outcome micro-steps in egocentric procedural activities", *Hugging Face dataset card* (`py2279105943/EgoIntent`), 2026.

[15] C. A. Field, A. H. Welsh, "Bootstrapping clustered data", *Journal of the Royal Statistical Society: Series B*, Vol. 69, No. 3, 2007, pp. 369–390.

[16] A. Furnari, G. M. Farinella, "Rolling-unrolling LSTMs for action anticipation from first-

person video", *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 43, No. 11, 2021, pp. 4021–4036.

[17] Y. Geifman, R. El-Yaniv, "Selective classification for deep neural networks", *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[18] K. Grauman, A. Westbury, E. Byrne, et al., "Ego4D: Around the world in 3,000 hours of egocentric video", *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 18995–19012.

[19] K. Grauman, A. Westbury, L. Torresani, et al., "Ego-Exo4D: Understanding skilled human activity from first- and third-person perspectives", *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024, pp. 19383–19400.

[20] A. Holtzman, P. West, V. Shwartz, Y. Choi, L. Zettlemoyer, "Surface form competition: Why the highest probability answer isn't always right", *Proceedings of EMNLP*, 2021, pp. 7038–7051.

[21] K. Kedia, P. Dan, A. Bhardwaj, S. Choudhury, "ManiCast: Collaborative manipulation with cost-aware human forecasting", *Conference on Robot Learning (CoRL)*, 2023.

[22] P. Khosla, P. Teterwak, C. Wang, et al., "Supervised contrastive learning", *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

[23] M. J. Kim, K. Pertsch, S. Karamcheti, et al., "OpenVLA: An open-source vision-language-action model", *Proceedings of the Conference on Robot Learning (CoRL)*, 2024.

[24] Y. Kong, Y. Fu, "Human action recognition and prediction: A survey", *International Journal of Computer Vision*, Vol. 130, No. 5, 2022, pp. 1366–1401.

[25] W. Liang, Y. Zhang, Y. Kwon, S. Yeung, J. Zou, "Mind the gap: Understanding the modality gap in multi-modal contrastive representation learning", *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.

[26] K. Q. Lin, J. Wang, M. Soldan, et al., "Egocentric video-language pretraining", *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.

[27] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel, M. Le, "Flow matching for generative modeling", *International Conference on Learning Representations (ICLR)*, 2023.

[28] B. Liu, Y. Zhu, C. Gao, Y. Feng, Q. Liu, Y. Zhu, P. Stone, "LIBERO: Benchmarking knowledge transfer for lifelong robot learning", *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[29] I. Loshchilov, F. Hutter, "Decoupled weight decay regularization", *International Conference on Learning Representations (ICLR)*, 2019.

[30] D. P. Losey, C. G. McDonald, E. Battaglia, M. K. O'Malley, "A review of intent detection, arbitration, and communication aspects of shared control for physical human–robot interaction", *Applied Mechanics Reviews*, Vol. 70, No. 1, 2018, 010804.

[31] A. Marafioti, O. Zohar, M. Farré, et al., "SmolVLM: Redefining small and efficient multimodal models", *arXiv preprint arXiv:2504.05299*, 2025.

[32] Open X-Embodiment Collaboration, "Open X-Embodiment: Robotic learning datasets and RT-X models", *Proceedings of the IEEE International Conference on Robotics and*

Automation (ICRA), 2024, pp. 6892–6903.

[33] A. van den Oord, Y. Li, O. Vinyals, "Representation learning with contrastive predictive coding", *arXiv preprint arXiv:1807.03748*, 2018.

[34] R. Pope, S. Douglas, A. Chowdhery, et al., "Efficiently scaling transformer inference", *Proceedings of Machine Learning and Systems (MLSys)*, 2023.

[35] A. Radford, J. W. Kim, C. Hallacy, et al., "Learning transferable visual models from natural language supervision", *Proceedings of the International Conference on Machine Learning (ICML)*, PMLR 139, 2021, pp. 8748–8763.

[36] F. Ragusa, R. Leonardi, M. Mazzamuto, et al., "ENIGMA-51: Towards a fine-grained understanding of human behavior in industrial scenarios", *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2024.

[37] F. Ragusa, R. Leonardi, M. Mazzamuto, et al., "ENIGMA-360: An ego-exo dataset for human behavior understanding in industrial scenarios", *arXiv preprint arXiv:2603.09741*, 2026.

[38] N. Rai, H. Chen, J. Ji, et al., "Home Action Genome: Cooperative compositional action understanding", *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.

[39] N. Reimers, I. Gurevych, "Sentence-BERT: Sentence embeddings using Siamese BERT-networks", *Proceedings of EMNLP-IJCNLP*, 2019, pp. 3982–3992.

[40] D. R. Roberts, V. Bahn, S. Ciuti, et al., "Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure", *Ecography*, Vol. 40, No. 8, 2017, pp. 913–929.

[41] J. Robinson, C.-Y. Chuang, S. Sra, S. Jegelka, "Contrastive learning with hard negative samples", *International Conference on Learning Representations (ICLR)*, 2021.

[42] M. S. Ryoo, "Human activity prediction: Early recognition of ongoing activities from streaming videos", *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2011, pp. 1036–1043.

[43] M. Shukor, D. Aubakirova, F. Capuano, et al., "SmolVLA: A vision-language-action model for affordable and efficient robotics", *arXiv preprint arXiv:2506.01844*, 2025.

[44] G. A. Sigurdsson, A. Gupta, C. Schmid, A. Farhadi, K. Alahari, "Actor and observer: Joint modeling of first and third-person videos", *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 7396–7404.

[45] M. Tschannen, A. Gritsenko, X. Wang, et al., "SigLIP 2: Multilingual vision-language encoders with improved semantic understanding, localization, and dense features", *arXiv preprint arXiv:2502.14786*, 2025.

[46] E. Valls Mascaró, H. Ahn, D. Lee, "Intention-conditioned long-term human egocentric action anticipation", *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2023, pp. 6048–6057.

[47] A. Vaswani, N. Shazeer, N. Parmar, et al., "Attention is all you need", *Advances in Neural Information Processing Systems (NeurIPS)*, 2017, pp. 5998–6008.

[48] E. M. Voorhees, “The TREC-8 question answering track report”, *Proceedings of the Eighth Text REtrieval Conference (TREC-8)*, 1999, pp. 77–82.

[49] L. Wang, Y. Xiong, Z. Wang, et al., “Temporal segment networks: Towards good practices for deep action recognition”, *Proceedings of the European Conference on Computer Vision (ECCV)*, 2016, pp. 20–36.

[50] T. Wang, P. Isola, “Understanding contrastive representation learning through alignment and uniformity on the hypersphere”, *Proceedings of the International Conference on Machine Learning (ICML)*, PMLR 119, 2020, pp. 9929–9939.

[51] E. B. Wilson, “Probable inference, the law of succession, and statistical inference”, *Journal of the American Statistical Association*, Vol. 22, No. 158, 1927, pp. 209–212.

[52] X. Zhai, B. Mustafa, A. Kolesnikov, L. Beyer, “Sigmoid loss for language image pre-training”, *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023, pp. 11975–11986.

[53] F. Zhang, V. Bazarevsky, A. Vakunov, et al., “MediaPipe Hands: On-device real-time hand tracking”, *arXiv preprint arXiv:2006.10214*, 2020.

[54] R. Zhang, W. Zhang, R. Fang, et al., “Tip-Adapter: Training-free adaption of CLIP for few-shot classification”, *Proceedings of the European Conference on Computer Vision (ECCV)*, 2022.

[55] Q. Zhao, S. Wang, C. Zhang, et al., “AntGPT: Can large language models help long-term action anticipation from videos?”, *International Conference on Learning Representations (ICLR)*, 2024.

[56] Y. Zhao, I. Misra, P. Krähenbühl, R. Girdhar, “Learning video representations from large language models”, *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023, pp. 6586–6597.

[57] Z. Zhao, E. Wallace, S. Feng, D. Klein, S. Singh, “Calibrate before use: Improving few-shot performance of language models”, *Proceedings of the International Conference on Machine Learning (ICML)*, PMLR 139, 2021, pp. 12697–12706.

[58] B. Zitkovich, T. Yu, S. Xu, et al., “RT-2: Vision-language-action models transfer web knowledge to robotic control”, *Proceedings of the Conference on Robot Learning (CoRL)*, PMLR 229, 2023, pp. 2165–2183.

[59] O. Zohar, M. Farré, A. Marafioti, et al., “SmolVLM2: Bringing video understanding to every device”, *Hugging Face technical blog*, 2025.