ĐẠI HỌC QUỐC GIA HÀ NỘI

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

[CẦN ĐIỀN: Họ và tên sinh viên]

TĂNG CƯỜNG KHẢ NĂNG HIỂU Ý ĐỊNH NGƯỜI DÙNG CHO ROBOT CỘNG TÁC DỰA TRÊN MÔ HÌNH VLA

ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC HỆ CHÍNH QUY

Ngành: [CẦN ĐIỀN: Ngành học]

HÀ NỘI – 2026

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ

[CẦN ĐIỀN: Họ và tên sinh viên]

TĂNG CƯỜNG KHẢ NĂNG HIỂU Ý ĐỊNH NGƯỜI DÙNG CHO ROBOT CỘNG TÁC DỰA TRÊN MÔ HÌNH VLA

ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC HỆ CHÍNH QUY

Ngành: [CẦN ĐIỀN: Ngành học]

Cán bộ hướng dẫn: [CẦN ĐIỀN: Học hàm, học vị, họ tên giảng viên hướng dẫn]

HÀ NỘI – 2026

LỜI CAM ĐOAN

Tôi xin cam đoan đồ án tốt nghiệp "*Tăng cường khả năng hiểu ý định người dùng cho robot cộng tác dựa trên mô hình VLA*" là công trình nghiên cứu của bản thân, được thực hiện dưới sự hướng dẫn của [CẦN ĐIỀN: Học hàm, học vị, họ tên giảng viên hướng dẫn]. Các số liệu và kết quả trình bày trong đồ án được tính trực tiếp từ các tệp kết quả thực nghiệm do tôi thực hiện, chưa từng được công bố trong công trình nào khác. Các nội dung tham khảo đều được trích dẫn đầy đủ trong danh mục tài liệu tham khảo.

Hà Nội, ngày ... tháng ... năm 2026
Sinh viên

[CẦN ĐIỀN: Họ và tên sinh viên]

LỜI CẢM ƠN

[CẦN ĐIỀN: Lời cảm ơn giảng viên hướng dẫn, phòng thí nghiệm, gia đình và bạn bè. Khoảng 5–8 dòng.]

TÓM TẮT

Tóm tắt: Robot cộng tác làm việc cạnh con người sẽ hữu ích hơn nếu đoán được người đó *định làm gì* trước khi hành động kết thúc, thay vì chờ một câu lệnh. Các mô hình Thị giác–Ngôn ngữ–Hành động (VLA) hiện nay như SmolVLA nhận ảnh, câu lệnh và trạng thái robot để sinh hành động, nhưng không có thành phần nào ước lượng ý định của người. Đồ án đề xuất kiến trúc VLIA (Vision–Language–Intention–Action), bổ sung vào SmolVLA một *mô-đun ý định*: mô-đun này xem đoạn đầu video góc nhìn thứ nhất của người dùng, ước lượng mục đích (WHY) của bước thao tác đang diễn ra, rồi đưa kết quả vào SmolVLA dưới dạng một token ý định qua lớp chiếu Intention Adapter.

Chất lượng của mô-đun ý định được đo bằng bài toán *phân định sớm mục tiêu*: chỉ với $k \in \{2, 4, 6, 8\}$ khung hình đầu tiên, mô-đun phải xếp câu mục đích đúng lên trên các câu mục đích khác của cùng video. Thực nghiệm dùng 2.503 bước thao tác từ 27 video, 13 bối cảnh của bộ dữ liệu EgoIntent, đánh giá chéo theo bối cảnh (8 fold) để mô hình luôn được kiểm tra trên bối cảnh chưa từng thấy, và các luật quyết định được chốt trước khi chạy. Kết quả: (i) đầu đọc được huấn luyện trên đặc trưng đóng băng của SmolVLM2 chỉ nhỉnh hơn ngẫu nhiên (MRR gấp 1,13–1,19 lần mức ngẫu nhiên, khoảng tin cậy 95% chứa 1), và về mức ngẫu nhiên trên tập kiểm thử khóa; (ii) thay bằng bộ mã hóa ảnh–văn bản SigLIP dùng *zero-shot*, không huấn luyện thêm, MRR tăng lên 2,25–2,57 lần mức ngẫu nhiên với khoảng tin cậy nằm hoàn toàn trên 1, và tăng dần khi quan sát thêm khung hình (+0,0094 MRR từ 2 lên 8 khung, khoảng tin cậy không chứa 0); tuy vậy độ chính xác chọn-1-trong-5 cao nhất là 28,9%, chưa đạt ngưỡng 30% đã chốt trước. Phía VLA, Intention Adapter và cơ chế chèn token ý định vào SmolVLA đã vượt qua các kiểm thử cài đặt, nhưng đồ án chưa đánh giá việc ý định có cải thiện hành vi robot hay không. Đồ án vì vậy đóng góp một quy trình đánh giá chặt chẽ cho mô-đun ý định, một bằng chứng rằng căn chỉnh ảnh–văn bản quan trọng hơn việc huấn luyện đầu đọc trên dữ liệu nhỏ, và một giao diện đã kiểm thử để nối mô-đun ý định với chính sách VLA.

Từ khóa: robot cộng tác, dự đoán ý định, mô hình VLA, video góc nhìn thứ nhất, SmolVLA, SigLIP, phân định mục tiêu sớm.

ABSTRACT

Abstract: A collaborative robot is more useful when it can anticipate what a person *intends* to do before the action is finished, instead of waiting for an explicit command. Current Vision–Language–Action (VLA) models such as SmolVLA map images, an instruction and the robot state to actions, but contain no component that estimates the human partner's intention. This thesis proposes VLIA (Vision–Language–Intention–Action), which adds an *intention module* to SmolVLA: the module observes the beginning of a first-person (egocentric) video of the user, estimates the purpose (WHY) of the ongoing manipulation step, and passes it to SmolVLA as one intention token through a linear Intention Adapter.

The intention module is evaluated on *early goal disambiguation*: given only the first $k \in \{2, 4, 6, 8\}$ frames, it must rank the correct purpose above the other purposes of the same video. Experiments use 2,503 manipulation steps from 27 videos and 13 scenes of the EgoIntent dataset, with 8-fold scene-grouped cross-validation (every test scene is unseen) and decision rules fixed before running. (i) A readout trained on frozen SmolVLM2 features is only marginally above chance (MRR 1.13–1.19× chance, 95% intervals include 1) and returns to chance on a locked test split. (ii) A zero-shot SigLIP image–text encoder, without any training, reaches 2.25–2.57× chance MRR with intervals entirely above 1, and improves as more frames are observed (+0.0094 MRR from 2 to 8 frames, interval excluding 0); its best 5-way accuracy, 28.9%, nonetheless misses the pre-registered 30% threshold. On the VLA side, the Intention Adapter and the intention-token injection into SmolVLA pass implementation tests, but whether intention improves robot behaviour is not evaluated. The thesis therefore contributes a rigorous evaluation protocol for the intention module, evidence that pretrained image–text alignment matters more than training a readout on small data, and a tested interface connecting the intention module to a VLA policy.

Keywords: collaborative robots, intention prediction, vision–language–action models, egocentric video, SmolVLA, SigLIP, early goal disambiguation.

MỤC LỤC

Lời cam đoan **i**

Lời cảm ơn **ii**

Tóm tắt **iii**

Abstract **iv**

Danh sách hình vẽ **viii**

Danh sách bảng **ix**

Danh mục từ viết tắt và thuật ngữ **x**

1 Giới thiệu **1**

1.1 Bối cảnh 1

1.2 Vấn đề: cùng một động tác, nhiều mục đích 1

1.3 Mục tiêu và phạm vi của đồ án 2

1.4 Câu hỏi nghiên cứu 2

1.5 Đóng góp 2

1.6 Cấu trúc đồ án 3

2 Kiến thức nền tảng và nghiên cứu liên quan **4**

2.1 Video góc nhìn thứ nhất và ý định 4

2.2 Dự đoán hành động và ý định từ video 4

2.3 Mô hình Thị giác–Ngôn ngữ–Hành động và SmolVLA 5

2.3.1 Ý tưởng chung 5

2.3.2 SmolVLA 5

2.4 Học tương phản và bộ mã hóa ảnh–văn bản 5

2.4.1 Trực giác 5

2.4.2 Học tương phản 6

2.4.3 CLIP và SigLIP 6

2.5 Đánh giá bằng xếp hạng 6

2.6 Khoảng tin cậy bằng bootstrap theo video 7

2.7 Vị trí của đồ án 7

3 Phương pháp **8**
3.1 Phát biểu bài toán . . . 8
3.2 Kiến trúc tổng thể VLIA . . . 8
3.3 Phương án 1: đầu đọc huấn luyện trên đặc trưng SmolVLM2 . . . 8
3.4 Phương án 2: căn chỉnh ảnh–văn bản zero-shot bằng SigLIP . . . 9
3.5 Tích hợp ý định vào SmolVLA . . . 10
3.5.1 Intention Adapter . . . 10
3.5.2 Chèn token ý định vào tiền tố . . . 10
3.6 Công cụ quan sát vùng tương tác tay–vật . . . 10

4 Dữ liệu và thiết lập thực nghiệm **11**
4.1 Bộ dữ liệu EgoIntent . . . 11
4.2 Đánh giá chéo theo bối cảnh . . . 12
4.3 Tập ứng viên và mức ngẫu nhiên . . . 12
4.4 Luật quyết định chốt trước . . . 12
4.5 Tập kiểm thử khóa . . . 13
4.6 Tập dữ liệu tự thu . . . 13
4.7 Cài đặt . . . 13

5 Kết quả và thảo luận **14**
5.1 Đầu đọc trên tập chia cố định và tập kiểm thử khóa . . . 14
5.2 RQ1: Đầu đọc trên đặc trưng SmolVLM2 với đánh giá chéo . . . 14
5.3 RQ2: Căn chỉnh ảnh–văn bản zero-shot . . . 15
5.4 RQ3: Ảnh hưởng của lượng quan sát . . . 16
5.5 Phân tích lỗi . . . 16
5.5.1 Giới hạn do câu đồng nghĩa . . . 16
5.5.2 Một ví dụ thất bại . . . 17
5.5.3 Lỗi cùng tác vụ . . . 17
5.6 Cổng phát hiện bàn tay . . . 17
5.7 RQ4: Tích hợp vào SmolVLA . . . 17
5.8 Thảo luận chung . . . 18

6 Kết luận và hướng phát triển **19**
6.1 Kết luận . . . 19
6.2 Hạn chế . . . 19
6.3 Hướng phát triển . . . 19

Tài liệu tham khảo **21**

DANH SÁCH HÌNH VẼ

1.1 Ví dụ về tính nhập nhằng sớm: cùng một hành động quan sát được có thể dẫn tới nhiều mục đích khác nhau. Robot muốn hỗ trợ đúng lúc cần phân biệt các mục đích này trước khi hành động kết thúc. 1

2.1 Sơ đồ đơn giản hóa của SmolVLA. Mọi đầu vào được biến thành token 960 chiều và đi qua backbone SmolVLM2; action expert sinh khối hành động bằng flow matching. . . 5

3.1 Kiến trúc VLIA. Mô-đun ý định (trên) tạo vector ý định từ phần đầu video góc nhìn thứ nhất; vector này được chiếu thành một token và chèn vào tiền tố của SmolVLA (dưới). 9

4.1 Tám khung hình của một bước thao tác trong EgoIntent (bối cảnh bếp, hoạt động nhào bột). Nhãn WHAT: "grasping basin"; nhãn WHY: "positioning basin". Khung xanh lá là bàn tay do MediaPipe phát hiện, khung xanh dương là vùng HOI ước lượng; các khung 5 và 6 không phát hiện được tay. Ảnh do công cụ hiển thị của đồ án tạo ra. . . 11

5.1 Lift MRR theo số khung quan sát. Thanh sai số là khoảng tin cậy 95% bootstrap theo video (vẽ cho SigLIP và `smolvlm_pca`). Đường nét đứt xám là mức ngẫu nhiên. 15

DANH SÁCH BẢNG

4.1 Thống kê dữ liệu dùng trong đánh giá chính (phần train + val của EgoIntent). 11

5.1 Đầu đọc phương án 1 trên tập kiểm định cố định và tập kiểm thử khóa (MRR, trung bình ± độ lệch chuẩn qua 3 seed). 14

5.2 Phương án 1 (đầu đọc huấn luyện trên đặc trưng SmolVLM2 đóng băng), đánh giá chéo 8 fold theo bối cảnh, 2.503 mẫu. Mức ngẫu nhiên: MRR 0,0298; chọn-1-trong-5 là 0,20. 15

5.3 Phương án 2 (SigLIP zero-shot, không huấn luyện) trên cùng 8 fold theo bối cảnh, 2.503 mẫu. 15

5.4 Hiệu ghép cặp khi tăng số khung quan sát (sau trừ trước), cùng 2.503 mẫu, CI 95% bootstrap theo video. 16

5.5 Tỉ lệ khung hình phát hiện được bàn tay theo bối cảnh (MediaPipe Hands). 17

5.6 Kiểm thử cài đặt phần tích hợp ý định vào SmolVLA. 18

DANH MỤC TỪ VIẾT TẮT VÀ THUẬT NGỮ

Viết tắt / Thuật ngữ	Ý nghĩa
VLA	Vision–Language–Action: mô hình nhận ảnh và câu lệnh, sinh ra hành động cho robot
VLM	Vision–Language Model: mô hình hiểu đồng thời ảnh và văn bản
VLIA	Vision–Language–Intention–Action: kiến trúc đề xuất, VLA có thêm thông tin ý định
Egocentric	Góc nhìn thứ nhất: video quay từ camera gắn trên đầu hoặc ngực người thực hiện
WHAT	Hành động con đang quan sát được (ví dụ "cầm cái bát")
WHY	Mục đích của bước thao tác hiện tại (ví dụ "đặt bát vào chỗ để nhào bột")
Tiền tố k khung	k khung hình đầu tiên của đoạn video, phần mô hình được phép thấy
Zero-shot	Dùng mô hình có sẵn để làm nhiệm vụ mới mà không huấn luyện thêm
SigLIP	Bộ mã hóa ảnh–văn bản được huấn luyện để ảnh và câu mô tả đúng nằm gần nhau
MRR	Mean Reciprocal Rank: trung bình nghịch đảo thứ hạng của đáp án đúng
Lift	Tỉ số giữa kết quả của mô hình và kết quả của đoán ngẫu nhiên (1 = ngang ngẫu nhiên)
K-way	Bài toán chọn đáp án đúng trong K ứng viên
CI	Confidence interval: khoảng tin cậy (ở đây 95%, ước lượng bằng bootstrap)
HOI	Hand–Object Interaction: tương tác bàn tay–vật thể
LIBERO	Bộ bài kiểm tra mô phỏng cho robot thao tác

CHƯƠNG 1

GIỚI THIỆU

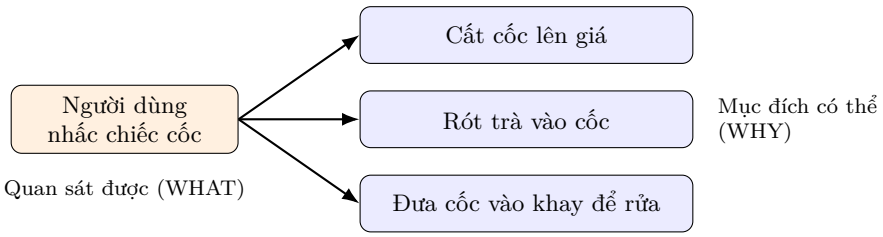
1.1 Bối cảnh

Robot công nghiệp truyền thống làm việc trong lồng an toàn, lặp lại một chuỗi động tác đã lập trình sẵn. *Robot cộng tác* (collaborative robot, cobot) thì khác: nó làm việc cùng không gian với con người, chẳng hạn đưa dụng cụ cho thợ, giữ chi tiết khi người lắp ráp, hay dọn bàn cùng người dùng. Muốn phối hợp nhịp nhàng, robot không thể chỉ phản ứng sau khi người đã làm xong hoặc đã ra lệnh; nó cần đoán được người đó *đang định làm gì* từ sớm.

Trong vài năm gần đây, các mô hình *Thị giác–Ngôn ngữ–Hành động* (Vision–Language–Action, VLA) như RT-2 [2] hay SmolVLA [4] trở thành hướng tiếp cận phổ biến cho robot thao tác. Một mô hình VLA nhận ảnh từ camera, một câu lệnh bằng ngôn ngữ tự nhiên (ví dụ "đặt cái cốc lên khay") và trạng thái các khớp của robot, rồi sinh ra chuỗi lệnh điều khiển. Điểm mạnh của VLA là tận dụng tri thức của các mô hình ngôn ngữ–thị giác lớn đã học từ Internet. Tuy nhiên, VLA giả định rằng mục tiêu đã được nói rõ trong câu lệnh. Khi cộng tác thật, con người hiếm khi nói hết mọi ý định; robot phải tự suy ra từ những gì nhìn thấy.

1.2 Vấn đề: cùng một động tác, nhiều mục đích

Khó khăn chính của việc đoán ý định là *tính nhập nhằng ở giai đoạn đầu*. Một động tác ban đầu thường phù hợp với nhiều mục đích khác nhau, và chỉ khi hành động tiến triển thêm thì mục đích thật mới lộ ra (Hình 1.1).



Hình 1.1. Ví dụ về tính nhập nhằng sớm: cùng một hành động quan sát được có thể dẫn tới nhiều mục đích khác nhau. Robot muốn hỗ trợ đúng lúc cần phân biệt các mục đích này trước khi hành động kết thúc.

Nếu đoán đúng sớm, robot có thể chuẩn bị trước: mở sẵn khay, nhường đường tới giá, hoặc đưa ấm trà lại gần. Nếu đoán sai mà vẫn hành động, robot sẽ gây cản trở. Do đó, câu hỏi thực tế không chỉ là "mục đích là gì" mà còn là "với lượng quan sát hiện có, có đủ căn cứ để phân biệt các mục đích hay chưa".

1.3 Mục tiêu và phạm vi của đồ án

Tên đề tài, "Tăng cường khả năng hiểu ý định người dùng cho robot cộng tác dựa trên mô hình VLA", được cụ thể hóa thành hai việc:

1. **Xây dựng mô-đun ý định cho một kiến trúc VLA.** Đồ án đề xuất kiến trúc VLIA, trong đó SmolVLA đóng vai trò chính sách điều khiển robot và nhận thêm một *token ý định* do mô-đun ý định tạo ra.
2. **Đo xem mô-đun ý định hiểu ý định tốt đến đâu.** Khả năng "hiểu ý định" được đo bằng một bài toán kỹ thuật cụ thể là *phân định sớm mục tiêu*: từ phần đầu video góc nhìn thứ nhất, xếp mục đích đúng lên trên các mục đích khác của cùng hoạt động.

Trong đồ án, chữ "tăng cường" được hiểu là *cải thiện chất lượng của mô-đun ý định* khi so sánh các phương án thiết kế dưới cùng một quy trình đánh giá. Đồ án **không** khẳng định rằng ý định đã làm robot thao tác tốt hơn, vì thí nghiệm hành vi khép kín trên robot nằm ngoài thời gian thực hiện. Phần VLA được kiểm chứng ở mức kiến trúc và kiểm thử cài đặt; giới hạn này được nêu rõ ở Chương 6.

1.4 Câu hỏi nghiên cứu

RQ1 Một đầu đọc nhỏ được huấn luyện trên đặc trưng thị giác đóng băng của chính backbone SmolVLA (SmolVLM2) có phân định được mục tiêu tốt hơn đoán ngẫu nhiên trên bối cảnh chưa thấy không?

RQ2 Một bộ mã hóa đã được căn chỉnh sẵn giữa ảnh và văn bản (SigLIP), dùng zero-shot, có làm tốt hơn đầu đọc đó không?

RQ3 Khi quan sát thêm khung hình, khả năng phân định mục tiêu có tăng lên không?

RQ4 Thông tin ý định có thể được đưa vào SmolVLA theo cách đúng về mặt cài đặt mà không phá vỡ chính sách gốc không?

1.5 Đóng góp

1. **Kiến trúc VLIA**: một mô-đun ý định tách rời, nối vào SmolVLA qua Intention Adapter và một token ý định chèn vào tiền tố đa phương thức. Kiến trúc cho phép thay bộ mã hóa ý định mà không sửa chính sách.
2. **Quy trình đánh giá chặt chẽ cho bài toán phân định sớm mục tiêu**: chỉ dùng khung hình trong tiền tố, đánh giá chéo theo bối cảnh, ứng viên nhiễu lấy từ cùng video, mức ngẫu nhiên tính chính xác, khoảng tin cậy bootstrap theo video và luật quyết định chốt trước.
3. **Bằng chứng thực nghiệm**: đầu đọc huấn luyện trên dữ liệu nhỏ gần như ngang ngẫu nhiên, trong khi căn chỉnh ảnh–văn bản zero-shot cho tín hiệu rõ và tăng theo lượng quan sát. Các kết quả âm (ngưỡng 30% không đạt, cổng phát hiện bàn tay không đạt) được báo cáo đầy đủ.
4. **Giao diện tích hợp đã kiểm thử**: Intention Adapter và đường chèn token ý định trong SmolVLA vượt qua bộ kiểm thử cài đặt, sẵn sàng cho thí nghiệm hành vi sau này.

1.6 Cấu trúc đồ án

Chương 2 trình bày các kiến thức nền cần thiết cho người đọc chưa quen lĩnh vực: video góc nhìn thứ nhất, mô hình VLA, học tương phản và các độ đo xếp hạng. Chương 3 mô tả kiến trúc VLIA và hai phương án cho mô-đun ý định. Chương 4 trình bày dữ liệu và quy trình đánh giá. Chương 5 báo cáo và phân tích kết quả. Chương 6 tổng kết, nêu hạn chế và hướng phát triển.

CHƯƠNG 2

KIẾN THỨC NỀN TẢNG VÀ NGHIÊN CỨU LIÊN QUAN

Chương này giới thiệu các khái niệm mà phần còn lại của đồ án sử dụng. Mỗi khái niệm được giải thích bằng trực giác trước, sau đó mới là định nghĩa.

2.1 Video góc nhìn thứ nhất và ý định

Video góc nhìn thứ nhất (egocentric video) được quay từ camera gắn trên đầu, kính hoặc ngực của người đang làm việc. Khác với camera đặt cố định trong phòng, loại video này cho thấy đúng những gì người đó nhìn: bàn tay, vật đang cầm và vùng làm việc phía trước. Vì robot cộng tác cũng quan tâm tới vùng làm việc đó, video góc nhìn thứ nhất là nguồn dữ liệu tự nhiên để học ý định. Các bộ dữ liệu lớn như Ego4D [10] và Ego-Exo4D [11] đã thúc đẩy mạnh hướng nghiên cứu này.

Đồ án phân biệt ba mức thông tin, theo cách gán nhãn của bộ dữ liệu EgoIntent [12]:

- **WHAT** – hành động con đang diễn ra và quan sát được, ví dụ "cầm cái bát".
- **WHY** – mục đích của bước thao tác hiện tại, ví dụ "đặt bát vào vị trí để nhào bột". Đây là thứ đồ án gọi là *ý định*.
- **NEXT** – bước tiếp theo trong quy trình.

WHAT thường nhìn thấy được trực tiếp, còn WHY phải suy ra. Hai bước thao tác có thể có WHAT gần giống nhau nhưng WHY khác nhau, và đó chính là tình huống nhập nhằng ở Hình 1.1.

Ý định khác gì với nhiệm vụ và hành động?

Nhiệm vụ là mục tiêu chung của cả hoạt động ("làm bánh mì"). *Ý định* (WHY) là mục đích của bước hiện tại trong nhiệm vụ đó ("chuẩn bị nhào bột"). *Hành động* của robot là lệnh điều khiển cụ thể cho từng khớp. Đồ án ước lượng ý định của *người*, rồi đưa nó cho robot như một thông tin bổ sung.

2.2 Dự đoán hành động và ý định từ video

Bài toán gần nhất với đồ án trong thị giác máy tính là *dự đoán hành động tương lai* (action anticipation): từ đoạn video đã thấy, đoán các hành động sắp tới. Valls Mascaro và cộng sự [13] mô hình hóa ý định như một biến ẩn điều kiện hóa chuỗi hành động tương lai. AntGPT [14] dùng mô hình ngôn ngữ lớn để suy ra mục tiêu rồi lập kế hoạch hành động. INSIGHT [15] kết hợp suy luận ý định với dự đoán dài hạn. Các công trình này chủ yếu đoán *chuỗi nhãn hành động kế tiếp*. Đồ án tập trung vào câu hỏi hẹp hơn nhưng sát với robot cộng tác hơn: *phân biệt các mục đích cạnh tranh* khi mới thấy một phần nhỏ của bước thao tác.

2.3 Mô hình Thị giác–Ngôn ngữ–Hành động và SmolVLA

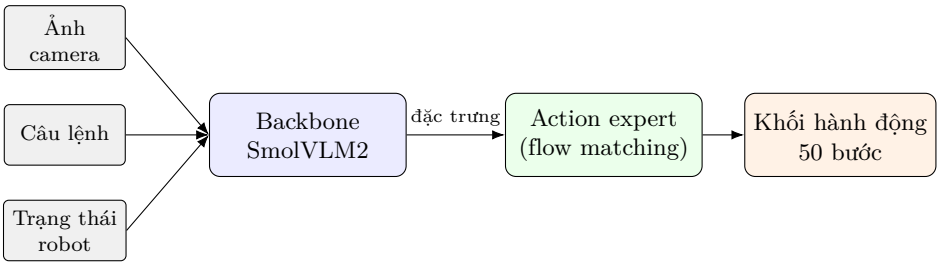
2.3.1 Ý tưởng chung

Một mô hình VLA gồm hai phần. Phần thứ nhất là một *mô hình ngôn ngữ–thị giác* (VLM) đọc ảnh và câu lệnh, biến chúng thành một dãy vector đặc trưng. Phần thứ hai là một *bộ sinh hành động*, nhận các vector đó cùng trạng thái robot và sinh ra một đoạn lệnh điều khiển. RT-1 [1], RT-2 [2] và Open X-Embodiment [3] cho thấy cách làm này khái quát được qua nhiều nhiệm vụ và nhiều loại robot.

2.3.2 SmolVLA

SmolVLA [4] là một VLA mã nguồn mở, cỡ nhỏ, được xây dựng trong thư viện LeRobot [5]. Đồ án chọn SmolVLA vì nó chạy được trên một GPU thông thường và có mã nguồn đầy đủ để sửa đổi. Luồng xử lý của SmolVLA như sau (Hình 2.1):

1. Ảnh camera, câu lệnh và trạng thái robot được biến thành các *token*, tức các vector cùng kích thước 960 chiều, rồi ghép thành một dãy gọi là *tiền tố đa phương thức*.
2. Tiền tố đi qua backbone SmolVLM2 [7, 8], một VLM cỡ 500 triệu tham số.
3. Một *action expert* nhỏ hơn đọc kết quả qua cơ chế chú ý chéo (cross-attention) và sinh ra một khối 50 bước hành động bằng phương pháp *flow matching* [6]: bắt đầu từ nhiễu ngẫu nhiên, sau khoảng 10 bước tinh chỉnh sẽ thu được chuỗi hành động.



Hình 2.1. Sơ đồ đơn giản hóa của SmolVLA. Mọi đầu vào được biến thành token 960 chiều và đi qua backbone SmolVLM2; action expert sinh khối hành động bằng flow matching.

Điều quan trọng cho đồ án là: SmolVLA **không có thành phần nào ước lượng ý định của người**. Mục đích chỉ đến từ câu lệnh. Đây là chỗ kiến trúc VLIA bổ sung.

2.4 Học tương phản và bộ mã hóa ảnh–văn bản

2.4.1 Trực giác

Để so sánh một đoạn video với một câu mô tả mục đích, cần đưa cả hai về cùng một không gian vector, sao cho video và câu mô tả *đúng* của nó nằm gần nhau, còn các câu sai nằm xa. Mức độ gần thường đo bằng *độ tương đồng cosine*:

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \, \|\mathbf{v}\|} \in [-1, 1]. \tag{2.1}$$

2.4.2 Học tương phản

Học tương phản (contrastive learning) huấn luyện mô hình bằng cách kéo các cặp đúng lại gần và đẩy các cặp sai ra xa. Hàm mất mát InfoNCE cho một truy vấn $\mathbf{z}$ với đáp án đúng $\mathbf{t}^+$ và các đáp án sai $\{\mathbf{t}_j^-\}$ là

$$\mathcal{L}_{\text{InfoNCE}} = -\log \frac{\exp(\cos(\mathbf{z}, \mathbf{t}^+)/\tau)}{\exp(\cos(\mathbf{z}, \mathbf{t}^+)/\tau) + \sum_j \exp(\cos(\mathbf{z}, \mathbf{t}_j^-)/\tau)}, \tag{2.2}$$

trong đó τ là "nhiệt độ" điều chỉnh độ sắc của phân phối. Khi trong một lô có nhiều mẫu cùng đáp án, phiên bản *nhiều mẫu dương* coi tất cả các mẫu đó là đúng.

2.4.3 CLIP và SigLIP

CLIP [16] áp dụng học tương phản trên hàng trăm triệu cặp ảnh–chú thích từ Internet, tạo ra hai bộ mã hóa (một cho ảnh, một cho văn bản) có chung không gian vector. SigLIP [17] thay hàm softmax của CLIP bằng hàm sigmoid trên từng cặp, giúp huấn luyện hiệu quả hơn. Vì đã học được rất nhiều khái niệm, các bộ mã hóa này dùng được *zero-shot*: chỉ cần mã hóa ảnh và các câu ứng viên rồi chọn câu có cosine cao nhất, không cần huấn luyện thêm. Backbone SmolVLM2 của SmolVLA cũng dùng một tháp thị giác thuộc họ SigLIP, nhưng đã được tinh chỉnh cho nhiệm vụ khác và không còn tháp văn bản đi kèm; đồ án dùng một checkpoint SigLIP riêng có đủ cả hai tháp (Mục 3.4).

2.5 Đánh giá bằng xếp hạng

Đồ án không bắt mô hình *viết ra* câu mục đích, mà cho mô hình *xếp hạng* một tập câu ứng viên. Cách làm này tránh việc phải chấm điểm câu tự do, vốn rất khó công bằng.

Các độ đo dùng trong đồ án

- **Thứ hạng** r: vị trí của câu đúng trong danh sách đã sắp theo điểm của mô hình (1 là tốt nhất).
- **MRR** (Mean Reciprocal Rank): trung bình của $1/r$ trên mọi truy vấn. Đúng ở vị trí 1 được 1 điểm, vị trí 2 được 0,5, vị trí 10 được 0,1.
- **Top-n**: tỉ lệ truy vấn có câu đúng nằm trong n vị trí đầu.
- **Chọn-1-trong-K** (K-way): cho câu đúng và $K-1$ câu sai lấy từ *cùng video*, mô hình phải chọn đúng. Đoán ngẫu nhiên đạt $1/K$, tức 20% với $K = 5$.
- **Mức ngẫu nhiên** và **lift**: mức ngẫu nhiên là kết quả kỳ vọng nếu xếp hạng ngẫu nhiên. Lift = kết quả của mô hình chia cho mức ngẫu nhiên. Lift bằng 1 nghĩa là không hơn đoán mò; lift bằng 2 nghĩa là tốt gấp đôi.

Lift quan trọng vì giá trị tuyệt đối của MRR phụ thuộc vào kích thước tập ứng viên. Ví dụ, khi có vài trăm câu ứng viên, MRR 0,07 nghe có vẻ thấp nhưng có thể gấp 2,5 lần đoán ngẫu nhiên.

2.6 Khoảng tin cậy bằng bootstrap theo video

Các mẫu trong cùng một video không độc lập với nhau: chúng có chung người, chung bối cảnh, chung ánh sáng. Nếu tính khoảng tin cậy như thể mọi mẫu độc lập, khoảng sẽ hẹp một cách giả tạo. Đồ án dùng *bootstrap theo cụm*: lấy mẫu có hoàn lại *cả video* (không phải từng mẫu), tính lại độ đo 10.000 lần, rồi lấy phân vị 2,5% và 97,5% làm khoảng tin cậy 95%. Khi so sánh hai cấu hình trên cùng các mẫu (ví dụ 2 khung và 8 khung), đồ án dùng *hiệu ghép cặp*: tính hiệu trên từng mẫu rồi mới bootstrap, giúp loại bỏ phần biến thiên chung.

2.7 Vị trí của đồ án

So với các công trình dự đoán hành động, đồ án đánh giá trực tiếp khả năng phân biệt các mục đích cạnh tranh trong cùng một hoạt động, với ràng buộc chỉ thấy phần đầu video. So với các mô hình VLA, đồ án bổ sung một nguồn thông tin mà chúng chưa có là ý định của người cộng tác. Đồ án không đề xuất một mạng nơ-ron mới để đạt kết quả tốt nhất trên một benchmark, mà tập trung vào câu hỏi thiết kế: *mô-đun ý định nên lấy biểu diễn từ đâu* để có tín hiệu thật trên bối cảnh chưa thấy.

CHƯƠNG 3

PHƯƠNG PHÁP

3.1 Phát biểu bài toán

Một video được chia thành nhiều *bước thao tác*. Bước thứ i có đoạn video V_i, nhãn hành động con WHAT_i và nhãn mục đích $y_i = \text{WHY}_i$ (một câu tiếng Anh ngắn). Từ V_i lấy đều 8 khung hình theo thời gian $(x_{i,1}, \ldots, x_{i,8})$. Với tiền tố độ dài $k \in \{2, 4, 6, 8\}$, mô hình chỉ được thấy $x_{i,1:k}$.

Mô-đun ý định gồm một hàm mã hóa quan sát f và một hàm mã hóa câu mục đích g, cho điểm

$$s(i, c) = \cos\big(f(x_{i,1:k}),\, g(c)\big) \tag{3.1}$$

với mỗi câu ứng viên c. Mô-đun được đánh giá bằng thứ hạng của câu đúng y_i trong một tập ứng viên $\mathcal{C}_i$, theo hai cách:

- **Xếp hạng trên toàn bộ tập**: $\mathcal{C}_i$ gồm mọi câu WHY của các mẫu trong cùng fold kiểm tra (vài trăm câu).
- **Chọn-1-trong-K**: $\mathcal{C}_i$ gồm y_i và $K - 1$ câu WHY *khác* của cùng video. Đây là dạng khó và sát với robot cộng tác nhất, vì các ứng viên cùng bối cảnh, cùng đồ vật và thường mở đầu bằng động tác giống nhau.

Nguyên tắc nhân quả. Đặc trưng của tiền tố k chỉ được tính từ k khung đầu, không dùng thông tin của các khung sau. Mọi phương án trong đồ án đều tuân theo nguyên tắc này.

3.2 Kiến trúc tổng thể VLIA

Kiến trúc VLIA (Hình 3.1) gồm hai khối nối tiếp:

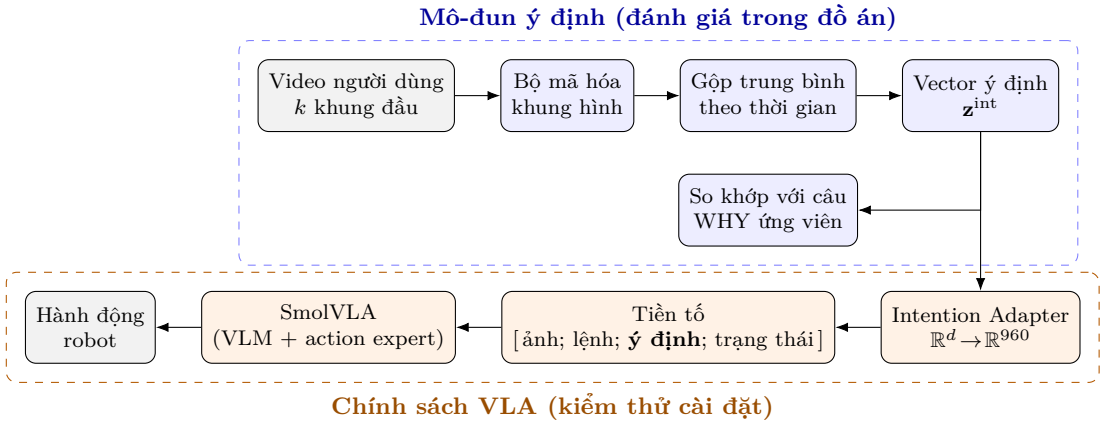
1. **Mô-đun ý định** đọc tiền tố video góc nhìn thứ nhất của người và tạo ra vector ý định $\mathbf{z}^{\text{int}}$.
2. **Chính sách SmolVLA** nhận $\mathbf{z}^{\text{int}}$ qua Intention Adapter dưới dạng một token, cùng với ảnh camera robot, câu lệnh và trạng thái, rồi sinh hành động.

Hai khối giao tiếp với nhau chỉ qua vector $\mathbf{z}^{\text{int}}$. Nhờ vậy có thể thay bộ mã hóa ý định (Mục 3.3 and 3.4) mà không sửa SmolVLA, chỉ cần đổi kích thước đầu vào của adapter.

3.3 Phương án 1: đầu đọc huấn luyện trên đặc trưng SmolVLM2

Phương án đầu tiên tận dụng chính backbone của SmolVLA, với ý tưởng "nếu VLA đã hiểu ảnh thì đặc trưng của nó đủ để đoán ý định".

Mã hóa khung hình. Mỗi khung hình đi qua SmolVLM2-500M-Video-Instruct [8] ở chế độ đóng băng (không cập nhật trọng số), cho một vector 960 chiều. Kết quả là một tensor $\mathbf{X}_i \in \mathbb{R}^{8\times 960}$ được lưu sẵn.



Hình 3.1. Kiến trúc VLIA. Mô-đun ý định (trên) tạo vector ý định từ phần đầu video góc nhìn thứ nhất; vector này được chiếu thành một token và chèn vào tiền tố của SmolVLA (dưới).

Đầu đọc. Lấy trung bình k khung đầu, rồi đưa qua một mạng perceptron hai lớp (lớp ẩn 512 chiều) để ra vector dự đoán:

$$\mathbf{z}_i = \text{MLP}\Big(\tfrac{1}{k}\textstyle\sum_{j=1}^{k} \mathbf{X}_{i,j}\Big). \tag{3.2}$$

Phép gộp trung bình được chọn vì trong các thử nghiệm sơ bộ, mạng hồi quy GRU và Transformer theo thời gian đều không tốt hơn trung bình trên dữ liệu nhỏ.

Biểu diễn câu đích. Đồ án so sánh hai cách biểu diễn câu WHY:

- `sentence`: vector của một bộ mã hóa câu có sẵn (all-MiniLM-L6-v2 [18]), không huấn luyện.
- `smolvlm_pca`: đặc trưng văn bản của SmolVLM2, giảm xuống 256 chiều bằng PCA.

Huấn luyện. Hàm mất mát là InfoNCE nhiều mẫu dương (công thức (2.2)) với $\tau = 0{,}07$, cộng thêm $0{,}1\times$ mất mát cosine giữa dự đoán và câu đích. Bộ tối ưu AdamW, tốc độ học 10^{-3}, weight decay 10^{-4}, tối đa 100 epoch, cắt gradient ở 1,0. Số epoch được chọn trên một phần bối cảnh tách ra *từ tập huấn luyện*, không bao giờ nhìn fold kiểm tra (Mục 4.2). Mỗi cấu hình chạy 3 seed.

3.4 Phương án 2: căn chỉnh ảnh–văn bản zero-shot bằng SigLIP

Phương án thứ hai xuất phát từ nhận xét rằng đầu đọc ở Mục 3.3 phải *tự học* mối liên hệ giữa ảnh và câu mục đích từ khoảng hai nghìn mẫu, trong khi các bộ mã hóa ảnh–văn bản đã học mối liên hệ đó từ hàng trăm triệu cặp. Phương án này dùng checkpoint `google/siglip-base-patch16-224` [17] như sau:

1. Mã hóa từng khung hình bằng tháp ảnh, chuẩn hóa độ dài vector (768 chiều).
2. Lấy trung bình k khung đầu và chuẩn hóa lại, được $f(x_{i,1:k})$.
3. Mã hóa mỗi câu WHY ứng viên bằng tháp văn bản (độ dài tối đa 64 token; không câu nào bị cắt), được $g(c)$.
4. Xếp hạng ứng viên theo công thức (3.1).

Phương án này **không có tham số nào được huấn luyện** trên dữ liệu của đồ án, nên không có nguy cơ quá khớp vào tập nhỏ, và các fold chỉ dùng để chia tập ứng viên giống hệt phương án 1.

Vì sao SigLIP vẫn nằm trong khung "dựa trên VLA"

SigLIP chỉ thay *bộ mã hóa của mô-đun ý định*. Chính sách điều khiển robot vẫn là SmolVLA, và vector ý định 768 chiều vẫn đi vào SmolVLA qua Intention Adapter như ở Hình 3.1. Backbone SmolVLM2 của SmolVLA vốn dùng tháp thị giác họ SigLIP; điểm khác là checkpoint đồ án dùng còn giữ tháp văn bản đã căn chỉnh, cho phép so khớp trực tiếp với câu mục đích.

3.5 Tích hợp ý định vào SmolVLA

3.5.1 Intention Adapter

Vector ý định $\mathbf{z}^{\text{int}} \in \mathbb{R}^d$ (với $d = 256$ cho phương án 1 và $d = 768$ cho phương án 2) được chiếu tuyến tính sang không gian ẩn 960 chiều của SmolVLA:

$$\mathbf{e}^{\text{int}} = \mathbf{W}\mathbf{z}^{\text{int}} + \mathbf{b}, \qquad \mathbf{W} \in \mathbb{R}^{960 \times d}. \tag{3.3}$$

3.5.2 Chèn token ý định vào tiền tố

Token $\mathbf{e}^{\text{int}}$ được chèn vào tiền tố đa phương thức ngay trước token trạng thái robot:

$$P_{\text{VLIA}} = \left[\, E_{\text{ảnh}};\ E_{\text{lệnh}};\ \mathbf{e}^{\text{int}};\ E_{\text{trạng thái}} \,\right]. \tag{3.4}$$

Tiền tố dài thêm đúng một token. Vì tiền tố chỉ được tính một lần và lưu trong bộ nhớ đệm khóa–giá trị (KV cache) trước các bước flow matching, token ý định không làm tăng đáng kể chi phí sinh hành động. Khi tắt cờ ý định, mô hình quay về đúng SmolVLA gốc. Thiết kế này cho phép so sánh công bằng "có ý định" và "không có ý định" trên cùng chính sách trong các thí nghiệm sau này.

3.6 Công cụ quan sát vùng tương tác tay–vật

Để kiểm tra trực quan dữ liệu và kết quả, đồ án xây dựng một công cụ hiển thị ngoại tuyến. Công cụ phát hiện bàn tay trong từng khung bằng MediaPipe Hands [19], vẽ khung bao bàn tay và một vùng tương tác tay–vật (HOI) ước lượng quanh tay, hiển thị nhãn WHAT/WHY và điểm số của các câu ứng viên (Hình 4.1). Vùng HOI ở đây là một hình chữ nhật hình học quanh bàn tay, không phải kết quả của bộ phát hiện vật thể. Dự định ban đầu là thử dùng vùng HOI làm đầu vào cho mô-đun ý định, nhưng phương án này chỉ được thực hiện nếu bàn tay được phát hiện đủ thường xuyên (Mục 5.6).

CHƯƠNG 4

DỮ LIỆU VÀ THIẾT LẬP THỰC NGHIỆM

4.1 Bộ dữ liệu EgoIntent

EgoIntent [12] được xây dựng từ video Ego4D [10]. Mỗi video là một hoạt động (ví dụ nhào bột, sửa xe đạp, hái quả) được chia thành các bước thao tác ngắn, mỗi bước kết thúc *trước* khi kết cục xảy ra và có nhãn WHAT, WHY và NEXT. Hình 4.1 minh họa một bước thao tác.



Hình 4.1. Tám khung hình của một bước thao tác trong EgoIntent (bối cảnh bếp, hoạt động nhào bột). Nhãn WHAT: "grasping basin"; nhãn WHY: "positioning basin". Khung xanh lá là bàn tay do MediaPipe phát hiện, khung xanh dương là vùng HOI ước lượng; các khung 5 và 6 không phát hiện được tay. Ảnh do công cụ hiển thị của đồ án tạo ra.

Đồ án dùng phần huấn luyện và kiểm định của bản đầy đủ, tổng cộng 2.503 bước thao tác (Bảng 4.1). Phần kiểm thử của bộ dữ liệu được khóa lại và chỉ được dùng một lần cho thí nghiệm ở Mục 5.1.

Bảng 4.1. Thống kê dữ liệu dùng trong đánh giá chính (phần train + val của EgoIntent).

Thuộc tính	Giá trị
Số bước thao tác (mẫu)	2.503
Số video nguồn	27
Số bối cảnh (scene)	13
Số câu WHY khác nhau	2.032
Số câu WHAT khác nhau	2.144
Số mẫu mỗi video	19 – 125
Số khung lấy đều mỗi mẫu	8

Các bối cảnh gồm: xưởng mộc, bếp, gara, trang trại, phòng khách, phòng ngủ, xưởng vẽ, tủ quần áo, hiên nhà, hành lang, phòng giặt, sân và không gian ngoài trời. Gần như mọi câu WHY là duy nhất, nên mô hình không thể học thuộc một danh sách nhãn cố định mà phải so khớp ngữ nghĩa

giữa video và câu.

4.2 Đánh giá chéo theo bối cảnh

Một mô hình đoán ý định cho robot phải dùng được ở nơi nó chưa từng thấy. Vì vậy, đồ án chia dữ liệu theo *bối cảnh* thay vì theo mẫu:

- 13 bối cảnh được chia thành 8 fold sao cho số mẫu các fold gần bằng nhau. Mỗi video chỉ thuộc một fold.
- Với mỗi fold, mô hình được huấn luyện trên 7 fold còn lại và kiểm tra trên fold đó. Như vậy mỗi mẫu được đánh giá đúng một lần, trên bối cảnh mô hình chưa thấy.
- Số epoch được chọn trên khoảng 15% bối cảnh tách ra từ tập huấn luyện của fold, sau đó mô hình được huấn luyện lại trên toàn bộ tập huấn luyện với số epoch đó.

So với một tập kiểm định cố định chỉ có 4 video, cách chia này dùng toàn bộ 27 video để đánh giá và tránh việc chọn mô hình trên chính tập dùng để báo cáo.

4.3 Tập ứng viên và mức ngẫu nhiên

Xếp hạng toàn tập. Với mỗi mẫu, tập ứng viên là toàn bộ câu WHY trong fold kiểm tra. Các mẫu có cùng câu WHY đều được tính là đúng. Mức ngẫu nhiên của MRR, Top-1 và Top-3 được tính chính xác theo kích thước fold và số đáp án đúng của từng mẫu; trung bình MRR ngẫu nhiên là 0,0298.

Chọn-1-trong-K. Với $K = 5$ và $K = 10$, mỗi truy vấn có $K - 1$ câu nhiễu lấy ngẫu nhiên từ *cùng video*, khác câu đúng. Bộ câu nhiễu được cố định bằng hạt giống tính từ mã mẫu, nên giống hệt nhau giữa các phương án, các độ dài tiền tố và các seed. Cả 2.503 truy vấn đều có đủ ứng viên.

4.4 Luật quyết định chốt trước

Khi thử nhiều cấu hình trên dữ liệu nhỏ, rất dễ vô tình chọn cấu hình đẹp nhất rồi báo cáo như phát hiện. Để tránh điều này, các luật sau được ghi vào kho mã *trước* khi chạy thí nghiệm tương ứng và không thay đổi sau khi thấy số liệu:

R1 Đầu đọc (phương án 1) được coi là *trên mức ngẫu nhiên* nếu cận dưới khoảng tin cậy 95% của lift lớn hơn 1.

R2 Biểu diễn `sentence` chỉ được chọn thay cho `smolvlm_pca` nếu cận dưới khoảng tin cậy của hiệu ghép cặp lớn hơn 0 ở ít nhất 2/4 độ dài tiền tố.

G1 Phương án SigLIP *đạt* nếu, ở mọi độ dài tiền tố: cận dưới CI của lift MRR > 1, cận dưới CI của lift chọn-1-trong-5 > 1, **và** độ chính xác chọn-1-trong-5 $\geq 0{,}30$.

Cổng HOI

Nhánh dùng vùng HOI chỉ được đánh giá nếu tỉ lệ khung phát hiện được bàn tay $\geq 60\%$ trên toàn bộ dữ liệu **và** $\geq 30\%$ ở mọi bối cảnh.

4.5 Tập kiểm thử khóa

Ngoài đánh giá chéo, đồ án còn một phép thử độc lập trên phần kiểm thử của EgoIntent cho đầu đọc phương án 1. Một video của phần này từng xuất hiện trong tập kiểm định thử nghiệm ban đầu nên bị loại trước khi khóa giao thức, còn lại 407 mẫu từ 4 video, 2 bối cảnh. Giao thức (mô hình, epoch, độ đo) được khóa trước, và tập này chỉ được chạy một lần. Lưu ý rằng tập kiểm thử này tách theo video nhưng không tách theo bối cảnh.

4.6 Tập dữ liệu tự thu

Để có tình huống nhập nhằng sát với robot cộng tác hơn EgoIntent, đồ án thiết kế một tập dữ liệu nhỏ theo kịch bản "trà chiều cùng robot": sáu cảnh (mời robot vào bàn, chọn cốc, chia bánh, sắp xếp bàn, đổi ý giữa chừng, dọn dẹp). Mỗi lần quay, người thực hiện bốc thăm một thẻ mục tiêu bí mật; các mục tiêu khác nhau mở đầu bằng cùng một động tác, và mục tiêu không được nói ra trước khi tay bắt đầu di chuyển. Mỗi video có nhãn `observation_end` (thời điểm kết thúc phần được quan sát) và `outcome_start` (thời điểm kết cục bắt đầu, sau `observation_end` ít nhất 0,5 giây), cùng nhãn WHAT/WHY. Một công cụ kiểm tra tự động từ chối các nhãn vi phạm quy tắc thời gian này.

[CẦN ĐIỀN: Số người tham gia, số video đã quay, số mục tiêu mỗi cảnh, và kết quả định tính nếu có. Nếu chưa có kết quả, giữ mục này như mô tả giao thức và chuyển sang Hướng phát triển.]

4.7 Cài đặt

Mã nguồn viết bằng Python và PyTorch, dựa trên thư viện LeRobot [5] và Hugging Face Transformers. Đặc trưng khung hình được trích xuất một lần và lưu đệm. Thí nghiệm chạy trên một máy trạm Dell Precision 3680 với một GPU NVIDIA. [CẦN ĐIỀN: Tên GPU và dung lượng bộ nhớ.] Toàn bộ mã, cấu hình và tệp kết quả của các bảng trong đồ án nằm trong kho mã của đề tài[1]; các bảng được sinh tự động từ tệp kết quả, không nhập tay.

[1] `https://github.com/sgdfgnhmjnfd/vlia-uet`

CHƯƠNG 5

KẾT QUẢ VÀ THẢO LUẬN

Chương này trả lời lần lượt bốn câu hỏi nghiên cứu. Mọi số liệu được lấy từ các tệp kết quả trong kho mã. Trong các bảng, "±" là độ lệch chuẩn giữa 3 seed, còn khoảng trong ngoặc vuông là khoảng tin cậy 95% bootstrap theo video.

5.1 Đầu đọc trên tập chia cố định và tập kiểm thử khóa

Trước khi chuyển sang đánh giá chéo, đầu đọc phương án 1 (biểu diễn đích `smolvlm_pca`) được đánh giá theo cách chia gốc của bộ dữ liệu: huấn luyện trên 2.091 mẫu (23 video), chọn epoch trên tập kiểm định 412 mẫu (4 video), sau đó chạy một lần trên tập kiểm thử khóa (Bảng 5.1).

Bảng 5.1. Đầu đọc phương án 1 trên tập kiểm định cố định và tập kiểm thử khóa (MRR, trung bình ± độ lệch chuẩn qua 3 seed).

	Kiểm định (412 mẫu, 4 video)		Kiểm thử khóa (407 mẫu, 4 video)	
Số khung k	MRR	Top-1	MRR	Top-1
2	0,0440 ± 0,0064	0,0162	0,0290 ± 0,0028	0,0057
4	0,0448 ± 0,0072	0,0162	0,0288 ± 0,0033	0,0082
6	0,0474 ± 0,0010	0,0218	0,0294 ± 0,0045	0,0090
8	0,0429 ± 0,0053	0,0146	0,0314 ± 0,0035	0,0098
Mức ngẫu nhiên	0,0249	0,0047	0,0318	0,0071

Trên tập kiểm định, MRR cao hơn mức ngẫu nhiên khoảng 1,7–1,9 lần, nhưng con số này lạc quan vì epoch được chọn trên chính tập đó. Trên tập kiểm thử khóa, MRR cao nhất (0,0314 ở 8 khung) xấp xỉ mức ngẫu nhiên 0,0318. Nói cách khác, **đầu đọc không cho thấy khả năng khái quát sang video mới**. Kết quả này là lý do đồ án chuyển sang đánh giá chéo theo bối cảnh (dùng được nhiều video hơn để đánh giá) và thử phương án 2.

5.2 RQ1: Đầu đọc trên đặc trưng SmolVLM2 với đánh giá chéo

Bảng 5.2 cho kết quả đánh giá chéo theo bối cảnh của phương án 1 với hai cách biểu diễn câu đích.

Trả lời RQ1

Đầu đọc huấn luyện trên đặc trưng SmolVLM2 chỉ nhỉnh hơn ngẫu nhiên rất ít. Theo luật R1, lift MRR **không** vượt ngẫu nhiên ở độ dài tiền tố nào (cận dưới CI luôn < 1) với cả hai biểu diễn đích. Ở bài toán chọn-1-trong-5, `smolvlm_pca` có cận dưới CI > 1 ở cả 4 độ dài, nhưng độ chính xác chỉ 21,9–23,0% so với 20% của đoán mò. Theo luật R2, không có căn cứ để chọn `sentence` thay cho `smolvlm_pca` (hiệu ghép cặp có cận dưới CI > 0 ở 0/4 độ dài).

Bảng 5.2. Phương án 1 (đầu đọc huấn luyện trên đặc trưng SmolVLM2 đóng băng), đánh giá chéo 8 fold theo bối cảnh, 2.503 mẫu. Mức ngẫu nhiên: MRR 0,0298; chọn-1-trong-5 là 0,20.

Biểu diễn đích	k	MRR	Lift MRR [CI 95%]	Chọn 1/5	Lift 1/5 [CI 95%]
`sentence`	2	0,0335	1,13 [0,86; 1,43]	0,216	1,08 [1,00; 1,16]
	4	0,0345	1,16 [0,88; 1,48]	0,215	1,07 [1,00; 1,16]
	6	0,0353	1,18 [0,90; 1,52]	0,212	1,06 [0,98; 1,16]
	8	0,0347	1,17 [0,87; 1,51]	0,219	1,10 [1,01; 1,20]
`smolvlm_pca`	2	0,0340	1,14 [0,95; 1,36]	0,219	1,09 [1,02; 1,17]
	4	0,0338	1,14 [0,94; 1,35]	0,222	1,11 [1,03; 1,19]
	6	0,0346	1,16 [0,95; 1,39]	0,223	1,12 [1,04; 1,20]
	8	0,0354	1,19 [0,98; 1,42]	0,230	1,15 [1,07; 1,23]

Kết quả cũng không đồng đều giữa các video: với `sentence`, có 8–12 trên 27 video có lift MRR dưới 1 tùy độ dài tiền tố. Điều này cho thấy tín hiệu yếu không đến từ vài video "khó" riêng lẻ mà phổ biến trên toàn bộ dữ liệu.

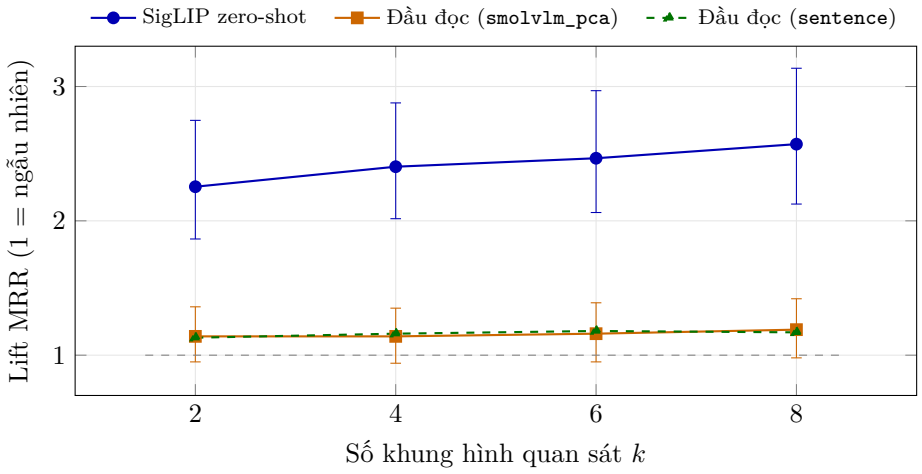
5.3 RQ2: Căn chỉnh ảnh–văn bản zero-shot

Bảng 5.3 cho kết quả của SigLIP zero-shot trên đúng cùng fold, cùng tập ứng viên.

Bảng 5.3. Phương án 2 (SigLIP zero-shot, không huấn luyện) trên cùng 8 fold theo bối cảnh, 2.503 mẫu.

k	MRR	Lift MRR [CI 95%]	Chọn 1/5	Lift 1/5 [CI 95%]	Chọn 1/10
2	0,0671	2,25 [1,87; 2,75]	0,277	1,39 [1,23; 1,56]	0,157
4	0,0715	2,40 [2,02; 2,88]	0,275	1,38 [1,22; 1,55]	0,161
6	0,0734	2,47 [2,06; 2,97]	0,281	1,40 [1,24; 1,58]	0,167
8	0,0765	2,57 [2,13; 3,14]	0,289	1,44 [1,27; 1,62]	0,177

Hình 5.1 đặt hai phương án cạnh nhau. Lift MRR của SigLIP khoảng gấp đôi đầu đọc ở mọi độ dài tiền tố, và các khoảng tin cậy của hai phương án không chồng lên nhau.



Hình 5.1. Lift MRR theo số khung quan sát. Thanh sai số là khoảng tin cậy 95% bootstrap theo video (vẽ cho SigLIP và `smolvlm_pca`). Đường nét đứt xám là mức ngẫu nhiên.

Trả lời RQ2

Có. Không huấn luyện tham số nào, SigLIP đạt lift MRR 2,25–2,57 với cận dưới CI từ 1,87 trở lên, và độ chính xác chọn-1-trong-5 là 27,5–28,9%. Tuy vậy, theo luật G1 đã chốt trước, phương án này **không đạt**: hai điều kiện về khoảng tin cậy thỏa mãn ở 4/4 độ dài, nhưng điều kiện độ chính xác chọn-1-trong-5 $\geq 30\%$ thỏa mãn ở 0/4 độ dài.

Kết quả cho thấy nút thắt của phương án 1 nằm ở *mối liên hệ giữa ảnh và ngôn ngữ*, không phải ở bản thân thông tin thị giác: hai nghìn mẫu không đủ để một đầu đọc học lại mối liên hệ mà SigLIP đã có sẵn từ dữ liệu quy mô Internet. Đây là cơ sở để đồ án coi phương án 2 là bộ mã hóa ý định ưu tiên trong VLIA, đồng thời ghi rõ rằng nó chưa đạt ngưỡng chất lượng đã đặt.

5.4 RQ3: Ảnh hưởng của lượng quan sát

Câu hỏi "quan sát thêm có giúp ích không" được trả lời bằng hiệu ghép cặp trên cùng các mẫu (Bảng 5.4).

Bảng 5.4. Hiệu ghép cặp khi tăng số khung quan sát (sau trừ trước), cùng 2.503 mẫu, CI 95% bootstrap theo video.

Phương án, độ đo	2 → 8 khung	6 → 8 khung
SigLIP, MRR	+0,0094 [+0,0053; +0,0141]	+0,0031 [+0,0002; +0,0060]
SigLIP, chọn 1/5	+0,0112 [+0,0014; +0,0211]	+0,0076 [0,0000; +0,0156]
Đầu đọc `sentence`, MRR	+0,0012 [−0,0014; +0,0039]	−0,0006 [−0,0021; +0,0010]
Đầu đọc `smolvlm_pca`, MRR	+0,0014 [−0,0016; +0,0043]	+0,0008 [−0,0010; +0,0027]
Đầu đọc `smolvlm_pca`, chọn 1/5	+0,0109 [+0,0023; +0,0198]	+0,0064 [−0,0023; +0,0151]

Trả lời RQ3

Với SigLIP, MRR tăng đều khi quan sát thêm: từ 2 lên 8 khung tăng +0,0094 (khoảng 14% tương đối) và khoảng tin cậy không chứa 0. Với đầu đọc, hiệu MRR nhỏ và mọi khoảng tin cậy đều chứa 0, tức không phát hiện được lợi ích của việc quan sát thêm. Như vậy chỉ khi biểu diễn đã căn chỉnh tốt, thêm bằng chứng thị giác mới chuyển thành khả năng phân định mục tiêu tốt hơn.

Mức tăng này vẫn nhỏ so với khoảng cách tới một hệ thống dùng được: ở 8 khung, câu đúng chỉ đứng đầu trong 28,9% số lần chọn-1-trong-5. Điều này phù hợp với bản chất của bài toán, vì nhiều bước thao tác kết thúc trước khi mục đích lộ rõ.

5.5 Phân tích lỗi

5.5.1 Giới hạn do câu đồng nghĩa

Các câu WHY được viết tự do, nên cùng một video thường có những câu gần nghĩa nhau. Theo bộ mã hóa câu all-MiniLM-L6-v2, 66,6% truy vấn có ít nhất một câu WHY khác trong cùng video với cosine $\geq 0{,}8$, và 44,5% có câu với cosine $\geq 0{,}9$. Vì đánh giá chỉ coi câu trùng khớp chính xác là đúng, các câu đồng nghĩa bị tính là sai, làm điểm số tuyệt đối bị chặn trên. Hai chẩn đoán phụ đã được chốt trước để ước lượng ảnh hưởng này. Thứ nhất, khi chỉ lấy câu nhiễu có cosine $< 0{,}8$ với câu đúng

và với nhau (bài toán chọn-1-trong-5 "sạch"), độ chính xác của SigLIP ở 8 khung tăng từ 28,9% lên 30,8%. Thứ hai, khi coi các câu có cosine $\geq 0{,}9$ với câu đúng cũng là đúng, MRR tăng lên 0,112 với lift 2,13 [1,71; 2,66]. Các con số này chỉ là chẩn đoán và **không** được dùng để đổi kết luận G1.

5.5.2 Một ví dụ thất bại

Với bước thao tác ở Hình 4.1 (nhãn WHY "positioning basin"), SigLIP ở 8 khung xếp các ứng viên theo thứ tự: "prepare to knead dough" (cosine 0,101), "developing dough consistency" (0,085), "forming cohesive dough" (0,072), "cleaning the table surface" (0,056), và câu đúng "positioning basin" đứng cuối (0,020). Mô hình nhận ra đúng *hoạt động chung* (nhào bột), nhưng không phân biệt được *bước* cụ thể trong hoạt động đó. Đây là kiểu lỗi đặc trưng của bài toán: các ứng viên cùng video chia sẻ đồ vật và bối cảnh, chỉ khác nhau ở mục đích của bước.

5.5.3 Lỗi cùng tác vụ

Trên tập kiểm thử khóa, khi đầu đọc chọn sai ở Top-1, 46–53% số lỗi là chọn nhầm sang một câu WHY *của cùng hoạt động*. Con số này cần đọc kèm mức ngẫu nhiên tương ứng, vì tỉ lệ ứng viên cùng hoạt động trong tập xếp hạng khác nhau giữa các tập chia.

5.6 Cổng phát hiện bàn tay

MediaPipe phát hiện được bàn tay trong 58,2% khung hình (11.652/20.024). Tỉ lệ rất khác nhau giữa các bối cảnh (Bảng 5.5): cao ở tủ quần áo (88,8%) và hành lang (84,5%), nhưng rất thấp ở hiên nhà (10,3%), phòng giặt (15,3%), sân (15,9%) và không gian ngoài trời (24,8%).

Bảng 5.5. Tỉ lệ khung hình phát hiện được bàn tay theo bối cảnh (MediaPipe Hands).

Bối cảnh	Tỉ lệ	Bối cảnh	Tỉ lệ
Tủ quần áo	88,8%	Gara	61,8%
Hành lang	84,5%	Xưởng vẽ	61,8%
Xưởng mộc	76,2%	Trang trại	32,2%
Bếp	71,6%	Không gian ngoài trời	24,8%
Phòng ngủ	67,2%	Sân	15,9%
Phòng khách	61,9%	Phòng giặt	15,3%
		Hiên nhà	10,3%
Toàn bộ: 58,2%		Cổng yêu cầu: $\geq 60\%$ và mỗi bối cảnh $\geq 30\%$	

Cổng HOI **không đạt** ở cả hai điều kiện, nên theo luật đã chốt, nhánh dùng vùng HOI không được đánh giá. Đồ án vì vậy **không có kết luận** về việc tập trung vào vùng tay–vật có giúp mô-đun ý định hay không. Công cụ hiển thị vẫn được giữ để quan sát dữ liệu.

5.7 RQ4: Tích hợp vào SmolVLA

Bảng 5.6 liệt kê các kiểm thử cài đặt cho Intention Adapter và đường chèn token ý định trong SmolVLA.

Bảng 5.6. Kiểm thử cài đặt phần tích hợp ý định vào SmolVLA.

Thành phần	Nội dung kiểm tra	Kết quả
Intention Adapter	Gradient truyền ngược được qua adapter	Đạt
Chèn tiền tố	Độ dài tiền tố tăng đúng 1 token	Đạt
Vị trí token	Token ý định nằm ngay trước token trạng thái	Đạt
KV cache	Token ý định có mặt trong bộ nhớ đệm khi suy luận	Đạt
Hàm mất mát	Mất mát flow matching hữu hạn; forward/backward nhất quán	Đạt
Tắt ý định	Mô hình quay về đúng SmolVLA gốc khi tắt cờ	Đạt
Lưu/tải	Lưu và tải lại checkpoint không mất trọng số	Đạt

Các kiểm thử trên được chạy với vector ý định 256 chiều của phương án 1. [CẦN ĐIỀN: Kết quả chạy lại các kiểm thử với vector 768 chiều của SigLIP; nếu chưa chạy, ghi "chưa kiểm thử".]

Bên cạnh đó, đồ án huấn luyện lại SmolVLA *không có ý định* trên LIBERO-10 [9] với cấu hình hành động 7 chiều đúng chuẩn, đạt tỉ lệ thành công 24% trên 100 lượt chạy. Hai lượt huấn luyện trước đó bị loại vì cấu hình sai (hành động 6 chiều, thiếu camera rỗng). Con số này chỉ là mốc kỹ thuật cho thấy đường huấn luyện và đánh giá chạy được, không phải kết quả cạnh tranh trên LIBERO.

Trả lời RQ4

Có, ở mức cài đặt: thông tin ý định đi vào SmolVLA đúng vị trí, có gradient, và không phá vỡ mô hình gốc khi tắt. Đồ án **chưa** đo việc token ý định có làm robot hành động tốt hơn hay không.

5.8 Thảo luận chung

Điều gì đã được chứng minh. Trên bối cảnh chưa thấy, một bộ mã hóa ảnh–văn bản đã căn chỉnh sẵn phân định mục tiêu tốt gấp khoảng hai lần đầu đọc được huấn luyện trên đặc trưng của backbone VLA, và hưởng lợi từ việc quan sát thêm. Kết luận này đứng vững dưới đánh giá chéo theo bối cảnh và khoảng tin cậy theo video.

Điều gì chưa được chứng minh. Chất lượng tuyệt đối còn thấp (28,9% chọn-1-trong-5 so với 20% ngẫu nhiên) và chưa đạt ngưỡng đã đặt. Tác động của ý định lên hành vi robot chưa được đo. Kết quả đến từ 27 video, 13 bối cảnh, nên chưa đủ để khẳng định khái quát rộng.

Ý nghĩa cho thiết kế VLIA. Kết quả gợi ý rằng mô-đun ý định nên dựa trên biểu diễn đã căn chỉnh ảnh–ngôn ngữ, và việc huấn luyện thêm (nếu có) nên ở dạng nhẹ trên biểu diễn đó thay vì học từ đầu trên dữ liệu nhỏ.

CHƯƠNG 6

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1 Kết luận

Đồ án nghiên cứu cách tăng cường khả năng hiểu ý định người dùng cho robot cộng tác dựa trên mô hình VLA. Các kết quả chính:

1. Đề xuất kiến trúc VLIA, bổ sung cho SmolVLA một mô-đun ý định tách rời và một token ý định trong tiền tố đa phương thức; phần tích hợp vượt qua bộ kiểm thử cài đặt.
2. Xây dựng quy trình đánh giá mô-đun ý định qua bài toán phân định sớm mục tiêu, với đánh giá chéo theo bối cảnh, ứng viên nhiễu cùng video, mức ngẫu nhiên chính xác, bootstrap theo video và luật quyết định chốt trước.
3. Chỉ ra rằng đầu đọc huấn luyện trên đặc trưng đóng băng của SmolVLM2 gần như ngang ngẫu nhiên (lift MRR 1,13–1,19, CI chứa 1; ngang ngẫu nhiên trên tập kiểm thử khóa).
4. Chỉ ra rằng SigLIP zero-shot tăng lift MRR lên 2,25–2,57 (CI hoàn toàn trên 1) và cải thiện khi quan sát thêm khung hình, nhưng chưa đạt ngưỡng 30% chọn-1-trong-5 đã chốt trước.

6.2 Hạn chế

- **Chưa có thí nghiệm hành vi.** Chưa đo việc token ý định cải thiện thao tác của robot, trên mô phỏng hay robot thật (UR5).
- **Dữ liệu nhỏ.** 27 video, 13 bối cảnh; khoảng tin cậy theo video chỉ mô tả tập này.
- **Đánh giá theo câu trùng khớp.** Câu đồng nghĩa bị tính là sai, làm điểm tuyệt đối bị chặn trên.
- **Chưa có tập kiểm thử độc lập cho SigLIP.** Kết quả SigLIP được tính trên phần train + val (không có tham số nào được huấn luyện, nhưng các lựa chọn thiết kế được đưa ra khi đã biết dữ liệu này).
- **Lưu trữ đặc trưng.** Đặc trưng SigLIP lưu ở dạng float16; khi tái tạo, độ chính xác chọn-1-trong-5 lệch 1 truy vấn trên 2.503 ở $k = 2$ và $k = 4$.
- **Phép thử backbone VLA tự chấm điểm.** Thử nghiệm dùng chính SmolVLM2 chấm xác suất câu WHY bị lỗi cài đặt (che sai phần token ảnh) nên kết quả bị loại; chưa có kết luận về khả năng tự phân định mục tiêu của backbone.

6.3 Hướng phát triển

- Đánh giá giá trị của thông tin mục tiêu với SmolVLA trên LIBERO bằng cách thay câu lệnh đúng, sai và rỗng, sau đó thay bằng token ý định dự đoán.

- Dùng điểm tin cậy của mô-đun ý định để quyết định *khi nào* robot nên hành động sớm và khi nào nên chờ (dự đoán hoặc hoãn), đo bằng đường rủi ro–độ phủ.
- Thử các bộ mã hóa căn chỉnh lớn hơn và adapter nhẹ trên embedding SigLIP, với lựa chọn lồng nhau (chọn cấu hình chỉ trên các fold huấn luyện).
- Hoàn thiện tập dữ liệu tự thu theo kịch bản trà chiều và đánh giá trên robot UR5.

TÀI LIỆU THAM KHẢO

[1] A. Brohan *et al.*, "RT-1: Robotics Transformer for real-world control at scale," *arXiv:2212.06817*, 2022.

[2] B. Zitkovich *et al.*, "RT-2: Vision-language-action models transfer web knowledge to robotic control," in *Proc. Conference on Robot Learning (CoRL)*, PMLR 229, 2023, pp. 2165–2183.

[3] Open X-Embodiment Collaboration, "Open X-Embodiment: Robotic learning datasets and RT-X models," in *Proc. IEEE Int. Conf. Robotics and Automation (ICRA)*, 2024, pp. 6892–6903.

[4] M. Shukor *et al.*, "SmolVLA: A vision-language-action model for affordable and efficient robotics," *arXiv:2506.01844*, 2025.

[5] R. Cadene *et al.*, "LeRobot: An open-source library for end-to-end robot learning," in *Proc. Int. Conf. Learning Representations (ICLR)*, 2026.

[6] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel, and M. Le, "Flow matching for generative modeling," in *Proc. ICLR*, 2023.

[7] A. Marafioti *et al.*, "SmolVLM: Redefining small and efficient multimodal models," *arXiv:2504.05299*, 2025.

[8] O. Zohar, M. Farre, A. Marafioti *et al.*, "SmolVLM2: Bringing video understanding to every device," Hugging Face technical blog, 2025.

[9] B. Liu, Y. Zhu, C. Gao, Y. Feng, Q. Liu, Y. Zhu, and P. Stone, "LIBERO: Benchmarking knowledge transfer for lifelong robot learning," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.

[10] K. Grauman *et al.*, "Ego4D: Around the world in 3,000 hours of egocentric video," in *Proc. IEEE/CVF CVPR*, 2022, pp. 18995–19012.

[11] K. Grauman *et al.*, "Ego-Exo4D: Understanding skilled human activity from first- and third-person perspectives," in *Proc. IEEE/CVF CVPR*, 2024, pp. 19383–19400.

[12] "EgoIntent: An open-ended benchmark for intent understanding at pre-outcome micro-steps in egocentric procedural activities," Hugging Face dataset card (`py2279105943/EgoIntent`), 2026.

[13] E. Valls Mascaro, H. Ahn, and D. Lee, "Intention-conditioned long-term human egocentric action anticipation," in *Proc. IEEE/CVF WACV*, 2023, pp. 6048–6057.

[14] Q. Zhao *et al.*, "AntGPT: Can large language models help long-term action anticipation from videos?" in *Proc. ICLR*, 2024.

[15] Q. Chu, H. Zhang, M. Liu, Y. Feng, H. Shi, and L. Nie, "Intention-guided cognitive reasoning for egocentric long-term action anticipation," in *Proc. AAAI Conf. Artificial Intelligence*, 2026.

[16] A. Radford *et al.*, "Learning transferable visual models from natural language supervision," in *Proc. Int. Conf. Machine Learning (ICML)*, PMLR 139, 2021, pp. 8748–8763.

[17] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer, "Sigmoid loss for language image pre-training," in *Proc. IEEE/CVF ICCV*, 2023, pp. 11975–11986.

[18] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence embeddings using Siamese BERT-networks," in *Proc. EMNLP-IJCNLP*, 2019, pp. 3982–3992.

[19] F. Zhang *et al.*, "MediaPipe Hands: On-device real-time hand tracking," *arXiv:2006.10214*, 2020.